

概率论与数理统计

Probability Theory and Mathematical Statistics

第二版

432 正文主线 · 数学结构理解 · 扩展阅读

基于茆诗松《概率论与数理统计》整理

概率统计方向考研备考笔记

修订日期：2026 年 7 月 10 日

目录

全书导论	1
0.1 研究对象与全书主线	1
0.2 对象角色与符号约定	2
0.3 四类常用推导工具	3
 第一部分 概率论公理化基础	 5
第 1 章 随机事件与概率	6
1.1 随机事件及其运算	6
1.2 概率的定义及其确定方法	8
1.3 概率的性质与连续性	9
1.4 条件概率、全概率与贝叶斯公式	10
1.5 独立性与指示变量	12
1.6 章末总结与 432 训练	14
 第 2 章 随机变量及其分布	 16
2.1 随机变量与分布函数	16
2.2 数学期望、方差与概率界	18
2.3 常用离散分布	20
2.4 常用连续分布	23
2.5 随机变量函数的分布	25
2.6 矩、偏度、峰度与分位数	26
2.7 章末总结与 432 训练	27
 第 3 章 多维随机变量及其分布	 29
3.1 联合分布与支撑集	29
3.2 边缘分布、条件分布与独立性	31
3.3 多维随机变量函数的分布	34
3.4 协方差、相关系数与协方差矩阵	37
3.5 章末总结与 432 训练	38

第二部分 极限定理	40
第 4 章 大数定律与中心极限定理	41
4.1 随机变量序列的收敛方式	42
4.2 特征函数	44
4.3 大数定律	45
4.4 中心极限定理与正态近似	47
4.5 章末总结与 432 训练	50
第三部分 数理统计初步	53
第 5 章 统计量及其分布	54
5.1 总体与样本	54
5.2 样本数据的整理与显示	56
5.3 统计量及其分布	57
5.4 三大抽样分布	60
5.5 充分统计量	64
5.6 备考指导	65
第四部分 统计推断与模型优化	67
第 6 章 参数估计	68
6.1 估计问题与评价标准 (B)	69
6.2 矩估计 (A)	70
6.3 最大似然估计 (A)	71
6.4 估计量的改进 (C)	73
6.5 贝叶斯估计 (A, 扩展)	76
6.6 区间估计与样本量 (D)	78
6.7 备考指导	81
第 7 章 假设检验	84
7.1 假设检验的基本思想与概念	84
7.2 正态总体参数假设检验	87
7.3 其他分布参数的假设检验	89
7.4 似然比检验与分布拟合检验	90
7.5 正态性检验	92

7.6	非参数检验	93
7.7	备考指导	94
第 8 章	方差分析与回归分析	97
8.1	方差分析 (ANOVA)	97
8.2	多重比较	101
8.3	方差齐性检验	102
8.4	一元线性回归	104
8.5	一元非线性回归	108
8.6	备考指导	109
附录 A	常用分布卡	111
A.1	离散分布	111
A.2	连续分布	112
A.3	统计推断中的三个分布	113
附录 B	常用枢轴量	115
B.1	单个总体	115
B.2	两个总体	116
附录 C	统计推断决策表	119
C.1	先判断数据结构, 再选择方法	119
C.2	正态总体八类标准检验卡	120
C.3	比例、分类数据与样本量	123
附录 D	高频反例	124
D.1	事件与随机变量	124
D.2	收敛与近似	125
D.3	估计与检验	125
D.4	方差分析与回归	126
附录 E	432 题型索引	127
E.1	概率模型与分布计算	127
E.2	极限定理、样本与点估计	129
E.3	区间估计与假设检验	130
E.4	方差分析与回归	131
E.5	考场作答检查表	131

全书导论

从随机性到可检验结论

概率论从一个已给定的随机机制出发，研究事件、随机变量及其分布；数理统计则从有限样本出发，反推产生数据的总体规律。二者的共同语言是分布，连接两者的关键对象是统计量及其抽样分布。

0.1 研究对象与全书主线

一次统计分析可概括为

$$(\Omega, \mathcal{F}, \mathbb{P}) \longrightarrow X \longrightarrow F_X \longrightarrow (X_1, \dots, X_n) \longrightarrow T \longrightarrow \text{估计、检验与预测}.$$

前两步回答“随机性如何被数学化”，中间两步回答“样本携带什么信息”，最后一步回答“如何给出带有误差控制的结论”。

层次	核心问题	本书位置
432 正文主线	定义、适用条件、标准推导、 计算链与常见题型	第 1–8 章及附录 E
数学结构理解	为什么结论成立，多个方法为 何具有同一代数或几何结构	各章“结构与证明”框
扩展阅读	测度概率、信息论、EM、 PCA 与一般线性模型等后续 联系	各章“扩展阅读”框

两条阅读路径

首次学习时按章节顺序完成定义、定理和例题，暂时跳过扩展框；复习时从附录 E 的题型索引进入，先由方法选择表定位条件，再回到相应章节补足推导。任何公式都应同时记住“条件”和“结论”，不把分布名称当作孤立口诀。

0.2 对象角色与符号约定

0.2.1 概率模型中的对象

符号	含义
Ω, ω	样本空间与一次试验的基本结果。
$\mathcal{F}, A, B$	事件域与其中的事件；事件直接写作 $A \in \mathcal{F}$ 。
$\mathbb{P}$	定义在 $(\Omega, \mathcal{F})$ 上且满足 $\mathbb{P}(\Omega) = 1$ 的概率测度。
X, Y	从样本空间到实数空间的随机变量。
$F_X(x)$	分布函数 $\mathbb{P}(X \leq x)$ 。
$f_X(x), f_{X,Y}(x, y)$	连续型随机变量的密度与联合密度；离散型情形使用概率质量函数。
$\mathbb{E}X, \text{Var}(X), \text{Cov}(X, Y)$	期望、方差与协方差。

0.2.2 统计推断中的对象

符号	含义
$X_1, \dots, X_n$	随机样本；观测实现写作 $x_1, \dots, x_n$ 。
$\bar{X}, S^2$	样本均值与无偏样本方差，其中 $S^2 = (n-1)^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。
Θ, θ	参数空间与其中的未知参数。
$L(\theta; x), \ell(\theta; x)$	似然函数与对数似然， $\ell = \log L$ 。
$\hat{\theta}, \hat{\theta}(x)$	估计量及其在给定样本上的估计值；上下文中应明确区分。
q_p	下侧 p 分位数， $q_p = \inf\{x : F_X(x) \geq p\}$ 。

本书的 Gamma 分布统一采用 *rate* 参数 λ ：

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x > 0, \quad \mathbb{E}X = \frac{\alpha}{\lambda}.$$

临界值采用上侧概率约定。例如 z_α 满足 $\mathbb{P}(Z > z_\alpha) = \alpha$ ， $\chi_\alpha^2(\nu)$ 与 $F_\alpha(m, n)$ 的含义相同。使用其他教材时，应先核对其上下侧约定。

符号不能替代条件

Z, t, χ^2, F 只说明某个统计量在特定假设下的分布。总体分布、样本独立性、方差是否已知以及样本量条件一旦改变，统计量和自由度也可能改变。

0.3 四类常用推导工具

0.3.1 分割、示性变量与条件化

对互不相交且并为样本空间的事件组 $B_1, B_2, \dots$, 先作分割再求和:

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A | B_i) \mathbb{P}(B_i).$$

计数问题常写成 $N = \sum_i \mathbf{1}_{A_i}$, 于是 $\mathbb{E}N = \sum_i \mathbb{P}(A_i)$, 这一结论不要求事件相互独立。处理分层随机性时, 优先使用

$$\mathbb{E}X = \mathbb{E}[\mathbb{E}(X | Y)], \quad \text{Var}(X) = \mathbb{E}[\text{Var}(X | Y)] + \text{Var}(\mathbb{E}[X | Y]).$$

0.3.2 标准化、变量变换与卷积

线性标准化把位置和尺度剥离, 例如 $Z = (X - \mu)/\sigma$ 。连续变量作一一变换 $Y = g(X)$ 时, 密度需乘逆变换的导数绝对值; 多维情形使用

$$f_{U,V}(u, v) = f_{X,Y}(x(u, v), y(u, v)) \left| \frac{\partial(x, y)}{\partial(u, v)} \right|.$$

独立随机变量之和的密度由卷积得到。计算前必须先确定变换后的支撑, 不能只写 Jacobian。

0.3.3 生成函数与极限近似

特征函数把独立和转化为乘积, 并可用于识别极限分布。大数定律控制样本均值与总体均值的距离, 中心极限定理描述标准化误差的近似分布; 二者的研究对象和缩放方式不同。使用近似时应说明样本量、尾部位置以及连续性修正等条件。

0.3.4 枢轴量、似然与平方和分解

参数推断通常沿三条链展开:

$$\begin{aligned} \text{枢轴量} &\longrightarrow \text{区间估计} \longleftrightarrow \text{假设检验}, \\ L(\theta; x) &\longrightarrow \ell(\theta; x) \longrightarrow \text{得分与信息} \longrightarrow \text{点估计及渐近分布}, \\ \text{总变异} &= \text{模型解释变异} + \text{随机误差变异} \longrightarrow t \text{ 或 } F \text{ 检验}. \end{aligned}$$

附录 B 汇总常用枢轴量, 附录 C 按条件给出推断方法选择, 附录 D 集中列出不能反向使用的命题。

统一视角

条件期望、最小二乘和正态样本平方和分解都可以理解为投影；充分统计量与似然原则都在回答“样本中哪些信息与参数有关”。这些结构有助于组织证明，但 432 主线仍以可验证的条件、统计量及分布结论为准。

后续学习边界

测度论为条件期望与收敛定理提供严格基础，线性代数解释协方差矩阵、PCA 与一般线性模型，信息论解释似然和 KL 散度，EM 处理含隐变量的似然优化。这些联系用于加深理解，不替代正文中的有限样本推导。

第一部分

概率论公理化基础

第 1 章

随机事件与概率

章首路线

本章解决三个问题：随机试验的结果怎样组织成数学对象；怎样在这些对象上赋予概率；获得新信息后怎样更新概率。阅读主线为

$$\omega \in \Omega \longrightarrow A \in \mathcal{F} \longrightarrow P: \mathcal{F} \rightarrow [0, 1] \longrightarrow P(\cdot | B) \longrightarrow \text{独立性}.$$

完成本章后，应能严格区分结果、事件与事件域，能判断条件概率公式的适用条件，并能用全概率、贝叶斯公式和独立性解决标准计算题。

1.1 随机事件及其运算

1.1.1 随机现象与样本空间

随机现象是指在相同条件下重复试验时，可能出现不同结果的现象。一次试验的一个可能结果记为 ω ，所有可能结果组成的集合称为**样本空间**，记为 Ω 。

1.1.2 随机事件

定义 1.1.1 (随机事件). 设 $\mathcal{F}$ 是样本空间 Ω 上指定的事件域。若 $A \in \mathcal{F}$ ，则称 A 为一个**随机事件**。当试验结果 $\omega \in A$ 时，称事件 A 发生。

这里必须保留对象层级： ω 是结果， A 是结果的集合， $\mathcal{F}$ 是允许讨论概率的事件所组成的集合族。在有限或可数样本空间中通常取 $\mathcal{F} = \mathcal{P}(\Omega)$ ；在连续空间中，一般只取适当的可测集合族。

1.1.3 事件间的关系与运算

事件关系对应集合关系：

- 包含: $A \subseteq B$, 即 A 发生必然导致 B 发生;
- 相等: $A = B$;
- 互不相容 (互斥): $A \cap B = \emptyset$;
- 对立事件: $A^c = \Omega \setminus A$;
- 和事件: $A \cup B$; 积事件: $A \cap B$; 差事件: $A \setminus B$ 。

德·摩根律为

$$(A \cup B)^c = A^c \cap B^c, \quad (A \cap B)^c = A^c \cup B^c.$$

例 1.1.1 (事件运算). 掷一枚骰子, 令 $A = \{2, 4, 6\}$ 表示“出现偶数”, $B = \{4, 5, 6\}$ 表示“点数至少为 4”。则

$$A \cap B = \{4, 6\}, \quad A \cup B = \{2, 4, 5, 6\}, \quad A \setminus B = \{2\}.$$

事件“既非偶数也不小于 4”为 $(A \cup B)^c = \{1, 3\}$ 。

1.1.4 事件域 (σ -代数)

为什么需要事件域

事件运算至少应允许取补、有限并与有限交; 而概率论还要研究事件列的极限, 因此必须对可数并封闭。这正是 σ -代数三条条件的来源。

定义 1.1.2 (σ -代数 (事件域)). 设 $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ 。若

1. $\Omega \in \mathcal{F}$;
2. $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$;
3. $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$,

则称 $\mathcal{F}$ 为 Ω 上的 σ -代数或**事件域**, 称 $(\Omega, \mathcal{F})$ 为可测空间。由德·摩根律, $\mathcal{F}$ 也对可数交封闭。

扩展阅读: 为什么连续空间不能任取所有子集

在 $\mathbb{R}^n$ 等连续空间中, 若同时要求可数可加性以及长度、平移等几何结构相容, 就会出现不能赋予一致测度的集合。因此实际工作通常采用 Borel σ -代数或其完备化。Vitali 集、Banach–Tarski 现象可作为进一步了解不可测集的索引, 但不影响本章的计算主线。

1.2 概率的定义及其确定方法

1.2.1 概率的公理化定义

定义 1.2.1 (概率空间). 设 $(\Omega, \mathcal{F})$ 为可测空间, 映射 $P: \mathcal{F} \rightarrow [0, 1]$ 若满足

1. 非负性: $P(A) \geq 0$;
2. 规范性: $P(\Omega) = 1$;
3. 可数可加性: 若 $A_1, A_2, \dots$ 两两互斥, 则

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n),$$

则称 P 为概率测度, 称 $(\Omega, \mathcal{F}, P)$ 为**概率空间**。

结构理解

概率是总质量为 1 的测度。公理只规定概率必须满足什么性质；具体模型中的概率数值，还要由等可能性、密度模型、经验数据或先验信息确定。

1.2.2 确定概率的常用方法

模型先行

- **古典概型**: 仅在有限个基本结果等可能时, $P(A) = |A|/|\Omega|$;
- **几何概型**: 若总体区域 Ω 具有有限正测度且按该测度均匀取点, 则

$$P(A) = \frac{m(A)}{m(\Omega)};$$

- **频率方法**: 用大量重复试验中的相对频率估计概率;
- **主观概率**: 用先验信息刻画不确定性, 并随数据更新。

公式之前必须先确认模型条件; “计数比”并不适用于不等可能结果。

排列与组合中

$$A_n^k = \frac{n!}{(n-k)!}, \quad \binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

例 1.2.1 (古典概型的完整计算). 同时掷两枚均匀骰子, 求点数和不少于 10 的概率。以有序对 (i, j) 为基本结果, 共有 36 个等可能结果。满足 $i + j \geq 10$ 的结果数为 $3 + 2 + 1 = 6$, 故

$$P(i + j \geq 10) = \frac{6}{36} = \frac{1}{6}.$$

若把不同点数和误当成等可能结果, 会得到错误答案。

1.3 概率的性质与连续性

1.3.1 基本性质

概率的基本性质

条件 在概率空间 $(\Omega, \mathcal{F}, P)$ 上, $A, B, A_i \in \mathcal{F}$ 。

结论

$$P(\emptyset) = 0, \quad P(A^c) = 1 - P(A),$$

$$A \subseteq B \Rightarrow P(A) \leq P(B),$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

若 $A_1, \dots, A_n$ 两两互斥, 则 $P(\bigcup_i A_i) = \sum_i P(A_i)$ 。

用途 化简并、交、补事件的概率, 并为容斥公式和后续条件概率计算提供基础。

边界 有限可加公式要求事件两两互斥; 一般并事件必须扣除重复部分。

对有限个事件, 容斥公式为

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \cdots + (-1)^{n-1} P\left(\bigcap_{i=1}^n A_i\right).$$

1.3.2 概率的连续性

若 $A_1 \subseteq A_2 \subseteq \cdots$, 记 $A_n \uparrow A$, 其中 $A = \bigcup_n A_n$; 若 $A_1 \supseteq A_2 \supseteq \cdots$, 记 $A_n \downarrow A$, 其中 $A = \bigcap_n A_n$ 。

概率的连续性

条件 A_n 必须是单调事件列: $A_n \uparrow A$ 或 $A_n \downarrow A$ 。

结论

$$A_n \uparrow A \Rightarrow P(A_n) \rightarrow P(A), \quad A_n \downarrow A \Rightarrow P(A_n) \rightarrow P(A).$$

用途 计算无限并、无限交的概率, 并证明分布函数的连续性性质。

1.4 条件概率、全概率与贝叶斯公式

边界 它不是“任意事件列都可把极限移入概率号”的结论；非单调事件列必须另行分析。

证明. 以下连续性为例. 令 $B_1 = A_1$, $B_n = A_n \setminus A_{n-1}$ ($n \geq 2$). 则 B_n 两两互斥, 且 $A_N = \bigcup_{n=1}^N B_n$, $A = \bigcup_{n=1}^{\infty} B_n$. 故

$$P(A) = \sum_{n=1}^{\infty} P(B_n) = \lim_{N \rightarrow \infty} \sum_{n=1}^N P(B_n) = \lim_{N \rightarrow \infty} P(A_N).$$

若 $A_n \downarrow A$, 则 $A_1 \setminus A_n \uparrow A_1 \setminus A$, 应用下连续性并取差即得上连续性。□

例 1.3.1 (“最终至少成功一次”). 独立重复进行成功概率为 $p > 0$ 的试验, 令 A_n 表示“前 n 次至少成功一次”. 则 $A_n \uparrow A$, 其中 A 表示“最终至少成功一次”, 并且

$$P(A_n) = 1 - (1 - p)^n.$$

由下连续性, $P(A) = \lim_n P(A_n) = 1$. 该结论依赖事件列单调递增, 而不是一般的极限交换。

1.4 条件概率、全概率与贝叶斯公式

1.4.1 条件概率与乘法公式

定义 1.4.1 (条件概率). 若 $B \in \mathcal{F}$ 且 $P(B) > 0$, 则对任意 $A \in \mathcal{F}$, 定义

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

固定 B 后, $A \mapsto P(A | B)$ 仍是 $\mathcal{F}$ 上的概率测度。

信息更新

条件 B 把注意力限制到 B 内部, 再用 $P(B)$ 归一化。若把样本空间改为 B , 相应事件域为 $\mathcal{F}_B = \{A \cap B : A \in \mathcal{F}\}$ 。

乘法公式

条件 所出现的条件概率分母均为正; 例如 $P(A_1 \cap \cdots \cap A_{n-1}) > 0$ 。

结论

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1) \prod_{k=2}^n P\left(A_k \mid \bigcap_{j=1}^{k-1} A_j\right).$$

用途 把联合发生概率分解成逐步发生的条件概率。

边界 任何条件事件概率为零时，相应比值形式无定义，不能机械套用。

1.4.2 全概率公式

定义 1.4.2 (完备事件组). 若 $A_1, A_2, \dots$ 两两互斥, $\bigcup_i A_i = \Omega$, 且所用条件概率满足 $P(A_i) > 0$, 则称其为一个完备事件组。

全概率公式

条件 $\{A_i\}$ 为有限或可数完备事件组, 且 $P(A_i) > 0$ 。

结论 对任意 $B \in \mathcal{F}$,

$$P(B) = \sum_i P(A_i)P(B | A_i).$$

用途 按互斥原因、来源、阶段或状态拆分复杂事件。

边界 分组必须互斥且穷尽样本空间；漏项或重叠都会导致错误。

例 1.4.1 (首次到达的全概率递推). 赌徒资金为 $k \in \{0, 1, \dots, N\}$ 。每局以概率 $0 < p < 1$ 赢一元, 以概率 $q = 1 - p$ 输一元; 到达 0 或 N 时停止。令 u_k 为从 k 出发先到达 N 的概率。按第一局输赢分组,

$$u_k = pu_{k+1} + qu_{k-1}, \quad u_0 = 0, \quad u_N = 1.$$

解得

$$u_k = \begin{cases} \frac{k}{N}, & p = q = \frac{1}{2}, \\ \frac{1 - (q/p)^k}{1 - (q/p)^N}, & p \neq q. \end{cases}$$

全概率公式在这里体现为“先看第一步, 再递推余下过程”。

1.4.3 贝叶斯公式

贝叶斯公式

条件 $\{A_i\}$ 为完备事件组, $P(A_i) > 0$, 并且 $P(B) > 0$ 。

结论

$$P(A_i | B) = \frac{P(A_i)P(B | A_i)}{\sum_j P(A_j)P(B | A_j)}.$$

用途 由“原因导致结果”的概率反推“观察到结果后原因成立”的概率。

边界 后验概率不是只看灵敏度；必须同时计入先验概率和其他来源产生该结果的概率。

例 1.4.2 (医学检测与基础率). 某病患病率为 1%。检测灵敏度为 95%，特异度为 90%。记 D 为患病， $+$ 为阳性，则

$$P(D) = 0.01, \quad P(+ | D) = 0.95, \quad P(+ | D^c) = 0.10.$$

阳性者真正患病的概率为

$$P(D | +) = \frac{0.01 \times 0.95}{0.01 \times 0.95 + 0.99 \times 0.10} \approx 0.0876.$$

尽管灵敏度很高，低患病率仍使单次阳性的后验患病概率不足 9%；这正是忽略基础率的典型陷阱。

扩展阅读：贝叶斯更新

在统计推断中， $P(A_i)$ 、 $P(B | A_i)$ 、 $P(A_i | B)$ 分别对应先验、似然和后验的离散原型。这里保留结构联系即可；连续参数的贝叶斯估计将在参数估计章节结合损失函数讨论。

1.5 独立性与指示变量

1.5.1 两个事件的独立性

定义 1.5.1 (两个事件的独立性). 若

$$P(A \cap B) = P(A)P(B),$$

则称 A 与 B 相互独立。若 $P(B) > 0$ ，该条件等价于 $P(A | B) = P(A)$ 。

互斥不等于独立

互斥表示两个事件不能同时发生；独立表示一个事件是否发生不改变另一个事件的概率。若 $A \cap B = \emptyset$ 且 $P(A), P(B) > 0$ ，则 $P(A \cap B) = 0 \neq P(A)P(B)$ ，所以二者反而不独立。只有当至少一个事件概率为 0 时，互斥事件才可能同时独立。

1.5.2 多个事件的独立性

定义 1.5.2 (相互独立). 事件 $A_1, \dots, A_n$ 称为相互独立, 若对任意 $2 \leq k \leq n$ 和任意不同指标 $i_1, \dots, i_k$, 都有

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = \prod_{j=1}^k P(A_{i_j}).$$

只验证所有二元交集称为**两两独立**, 它一般弱于相互独立。

例 1.5.1 (两两独立但不相互独立). 均匀随机选取 $\{00, 01, 10, 11\}$ 中的一个二进制对 (U, V) 。令

$$A = \{U = 1\}, \quad B = \{V = 1\}, \quad C = \{U = V\}.$$

三事件概率均为 $1/2$, 任意两事件交集的概率均为 $1/4$, 故两两独立; 但

$$P(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C),$$

所以三者不相互独立。

若两个随机试验相互独立, 严格含义是: 由第一个试验结果确定的任意事件与由第二个试验结果确定的任意事件都独立。

1.5.3 指示变量: 通向随机变量的桥

定义 1.5.3 (事件的指示变量). 对事件 $A \in \mathcal{F}$, 定义

$$I_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

则 $\{I_A = 1\} = A$, 且

$$I_{A^c} = 1 - I_A, \quad I_{A \cap B} = I_A I_B, \quad I_{A \cup B} = I_A + I_B - I_A I_B.$$

指示变量把集合运算翻译成代数运算。下一章的伯努利随机变量正是事件指示变量的分布模型。

1.6 章末总结与 432 训练

知识关系图

随机结果 $\rightarrow$ 事件与 σ -代数 $\rightarrow$ 概率公理 $\rightarrow$ 概率性质
 $\rightarrow$ 条件概率 $\rightarrow$ 全概率/贝叶斯 $\rightarrow$ 独立性

全概率是“由原因到结果”的加权分解，贝叶斯是“观察结果后反推原因”，独立性则说明条件化后概率不变。

方法选择表

题目特征	首选方法
有限等可能结果	先确定基本结果，再用计数比
出现“至少一个”	优先计算对立事件
多事件并集	容斥公式
按来源、状态或第一步分类	全概率公式
由观察结果反推原因	贝叶斯公式
多阶段联合发生	条件概率乘法公式
声称事件互不影响	检查 $P(A \cap B) = P(A)P(B)$

易错清单

1. 事件是 $\mathcal{F}$ 中的集合，不是任意子集，也不是单个结果；
2. 古典概型必须先确认基本结果等可能；
3. 概率连续性只直接适用于单调事件列；
4. $P(A | B)$ 要求 $P(B) > 0$ ；
5. 完备事件组必须互斥且穷尽；
6. 互斥不等于独立，两两独立不推出相互独立。

432 常见题型

事件运算与容斥、条件概率乘法、全概率分类、贝叶斯反推、独立性判定，以及利用第一步分析建立递推式。

A 级：直接计算

题目：从 $1, 2, \dots, 10$ 中等可能取一个数。令 $A =$ “偶数”， $B =$ “大于 6”。求 $P(A \cup B)$ 。

简解： $|A| = 5$ ， $|B| = 4$ ， $|A \cap B| = 2$ ，故 $P(A \cup B) = (5 + 4 - 2)/10 = 7/10$ 。

B 级：条件与反推

题目：两台机器分别生产 60%、40% 的产品，次品率分别为 1%、3%。抽到一件次品，求其来自第二台机器的概率。

简解：

$$\frac{0.4 \times 0.03}{0.6 \times 0.01 + 0.4 \times 0.03} = \frac{2}{3}.$$

C 级：结构与反例

题目：证明两个概率均为正的互斥事件不可能独立，并构造三个两两独立但不相互独立的事件。

简解：前者由 $0 = P(A \cap B) \neq P(A)P(B)$ 得证；后者可直接使用本章二进制对 (U, V) 的例子。

第 2 章

随机变量及其分布

章首路线

随机变量把抽象结果映射到实轴，分布则描述这些数值的概率规律。本章路线为

$$\text{随机变量} \rightarrow F_X \rightarrow \begin{cases} \text{离散型} \\ \text{连续型} \\ \text{混合型} \end{cases} \rightarrow \text{期望与方差}$$

$\rightarrow$ 常用分布 $\rightarrow$ 函数分布 $\rightarrow$ 矩与分位数

学习时先问“取值范围是什么”，再选择分布列、密度或分布函数作为计算工具。

2.1 随机变量与分布函数

2.1.1 随机变量

定义 2.1.1 (随机变量). 设 $(\Omega, \mathcal{F}, P)$ 为概率空间。若映射 $X: \Omega \rightarrow \mathbb{R}$ 满足

$$\{\omega : X(\omega) \leq x\} = X^{-1}((-\infty, x]) \in \mathcal{F}, \quad \forall x \in \mathbb{R},$$

则称 X 为实值随机变量。

扩展阅读：可测映射与前推测度

随机变量是从 $(\Omega, \mathcal{F})$ 到 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 的可测映射。它把 P 前推为实轴上的分布 $P_X: P_X(B) = P(X \in B)$ 。这解释了为什么两个定义在不同概率空间上的随机变量仍可能同分布。

2.1.2 分布函数

定义 2.1.2 (分布函数). 随机变量 X 的分布函数定义为

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

分布函数的充要条件

条件 $F: \mathbb{R} \rightarrow [0, 1]$ 。

结论 F 是某个随机变量的分布函数, 当且仅当它单调不减、右连续, 并满足

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

用途 判断给定函数能否作为分布函数, 并由跳跃量、导数或区间增量提取概率。

边界 分布函数一般不连续、也不一定可导; 不能把所有分布都写成一个普通密度。

特别地,

$$P(a < X \leq b) = F_X(b) - F_X(a), \quad P(X = x) = F_X(x) - F_X(x-).$$

右连续性. 固定 x , 令 $A_n = \{X \leq x + 1/n\}$, 则 $A_n \downarrow \{X \leq x\}$ 。由概率的上连续性,

$$F_X(x) = \lim_{n \rightarrow \infty} F_X\left(x + \frac{1}{n}\right).$$

再由单调性即可得到 $\lim_{t \downarrow x} F_X(t) = F_X(x)$ 。□

2.1.3 离散型、连续型与混合型

定义 2.1.3 (离散型随机变量). 若 X 的可能取值至多可数, 记为 $x_1, x_2, \dots$, 则其分布列为

$$p_k = P(X = x_k), \quad p_k \geq 0, \quad \sum_k p_k = 1.$$

定义 2.1.4 (连续型随机变量). 若存在非负可积函数 f_X , 使

$$F_X(x) = \int_{-\infty}^x f_X(t) \, dt, \quad \int_{-\infty}^{+\infty} f_X(x) \, dx = 1,$$

则称 X 为连续型随机变量, f_X 为其概率密度。

密度不是概率

连续型随机变量满足 $P(X = x) = 0$ ，但 $f_X(x)$ 可以大于 1。概率必须对区间积分：

$$P(a < X \leq b) = \int_a^b f_X(x) \, dx.$$

单点概率为零也不表示该点“不可能取到”；它只表示该单点没有概率质量。

例 2.1.1 (混合型分布). 设 $0 < p < 1$ ，随机变量 X 以概率 p 取 0，其余概率质量在 $(0, 1)$ 上均匀分布。则

$$F_X(x) = \begin{cases} 0, & x < 0, \\ p + (1-p)x, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

F_X 在 0 处跳跃 p ，而在 $(0, 1)$ 上有连续密度 $1-p$ 。因此 X 既不是离散型，也不是连续型。这同时说明“没有全局密度”不等于“离散”。

2.2 数学期望、方差与概率界

2.2.1 数学期望

定义 2.2.1 (数学期望). 若 $E|X| < \infty$ ，则称 X 可积，并定义

$$E[X] = \begin{cases} \sum x_k P(X = x_k), & X \text{ 离散}, \\ \int_{-\infty}^{+\infty} x f_X(x) \, dx, & X \text{ 连续}. \end{cases}$$

统一地， $E[X] = \int_{\Omega} X \, dP = \int_{\mathbb{R}} x \, dF_X(x)$ 。

期望的线性性与 LOTUS

条件 X, Y 可积；涉及 $g(X)$ 时要求 $E|g(X)| < \infty$ 。

结论

$$E[aX + bY + c] = aE[X] + bE[Y] + c.$$

并且

$$E[g(X)] = \int_{\mathbb{R}} g(x) \, dF_X(x),$$

离散型化为求和，连续型化为 $\int g(x)f_X(x) dx$ 。若 X, Y 独立且相应乘积可积，则 $E[XY] = E[X]E[Y]$ 。

用途 直接计算随机变量函数的期望，无需先求 $g(X)$ 的分布。

边界 若绝对可积性不成立，不能任意拆分或交换无穷求和、积分。

例 2.2.1 (LOTUS 直接求函数期望). 设 $X \sim U(0, 1)$, $Y = X(1 - X)$ 。不必先求 Y 的密度，直接有

$$E[Y] = \int_0^1 x(1-x) dx = \frac{1}{6}.$$

由于 $0 \leq Y \leq 1/4$ ，结果也通过了取值范围检查。

2.2.2 方差与标准差

定义 2.2.2 (方差). 若 $E[X^2] < \infty$ ，则

$$\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2,$$

标准差为 $\sigma_X = \sqrt{\text{Var}(X)}$ 。

方差的运算性质

条件 所涉及随机变量具有有限二阶矩。

结论

$$\text{Var}(aX + b) = a^2 \text{Var}(X),$$

以及

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

若 X, Y 独立，则协方差为零，从而方差可加。

用途 计算线性组合的波动，并为切比雪夫不等式和大数定律准备条件。

边界 方差可加只需不相关；若未验证协方差为零，不能直接相加。

2.2.3 马尔可夫与切比雪夫不等式

马尔可夫不等式

条件 $X \geq 0$ 且 $E[X] < \infty$, $a > 0$ 。

结论

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

用途 只知道非负随机变量的均值时控制右尾概率。

边界 要求非负, 且通常只给出较粗上界。

切比雪夫不等式

条件 $E[X]$ 与 $\text{Var}(X)$ 有限, $\varepsilon > 0$ 。

结论

$$P(|X - E[X]| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}.$$

用途 未知具体分布时控制偏离均值的概率, 并证明依概率收敛。

边界 它不利用分布形状, 所得界可能明显偏松。

例 2.2.2 (仅由均值和方差给概率界). 已知 $E[X] = 10$, $\text{Var}(X) = 4$ 。则

$$P(|X - 10| < 3) \geq 1 - \frac{4}{9} = \frac{5}{9}.$$

这是对所有满足该均值、方差的分布都成立的保证, 而不是精确概率。

2.3 常用离散分布

统一分布卡的阅读顺序

每个分布依次确认: 产生机制、参数范围、支撑集、概率函数、期望方差、典型关系。支撑集和参数化属于公式的一部分, 不能只背中间的表达式。

2.3.1 伯努利与二项分布

定义 2.3.1 (伯努利分布 $\text{Bern}(p)$). 一次试验成功记为 1、失败记为 0, 其中 $0 \leq p \leq 1$:

$$P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}.$$

其期望为 p , 方差为 $p(1-p)$ 。事件指示变量 I_A 服从 $\text{Bern}(P(A))$ 。

定义 2.3.2 (二项分布 $B(n, p)$). 若 X 是 n 次独立同分布伯努利试验的成功次数, 则

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

其中 $n \in \mathbb{N}_+$ 、 $0 \leq p \leq 1$, 且 $E[X] = np$ 、 $\text{Var}(X) = np(1-p)$ 。

2.3.2 泊松分布

定义 2.3.3 (泊松分布 $\text{Pois}(\lambda)$). 若 $\lambda > 0$, 且

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots,$$

则记 $X \sim \text{Pois}(\lambda)$ 。参数 λ 是给定区间内的平均发生次数, $E[X] = \text{Var}(X) = \lambda$ 。

泊松极限定理

条件 $X_n \sim B(n, p_n)$, $n \rightarrow \infty$ 、 $p_n \rightarrow 0$ 且 $np_n \rightarrow \lambda > 0$ 。

结论 对每个固定的非负整数 k ,

$$P(X_n = k) \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}.$$

用途 近似大量独立机会中少量稀有事件的发生次数。

边界 若单次概率不小或试验机会并非近似独立, 泊松近似可能很差。

2.3.3 超几何分布

定义 2.3.4 (超几何分布). 总体含 N 个个体, 其中 M 个具有某特征; 不放回抽取 n 个, 令 X 为抽中特征个体数。则

$$P(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}},$$

其中

$$k = \max\{0, n - (N - M)\}, \dots, \min\{n, M\},$$

并要求 $0 \leq M, n \leq N$ 。此外

$$E[X] = n \frac{M}{N}, \quad \text{Var}(X) = n \frac{M}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1} \quad (N > 1).$$

二项还是超几何

有放回抽样或可视为独立重复试验时用二项分布；有限总体不放回抽样时，各次抽取相关，应使用超几何分布。

2.3.4 几何与负二项分布

定义 2.3.5 (几何分布). 独立伯努利试验中，首次成功所需试验次数 T 满足

$$P(T = k) = (1 - p)^{k-1} p, \quad k = 1, 2, \dots,$$

其中 $0 < p \leq 1$ 。其期望与方差为

$$E[T] = \frac{1}{p}, \quad \text{Var}(T) = \frac{1-p}{p^2}.$$

定义 2.3.6 (负二项分布：第 r 次成功的试验次数). 令 T_r 为第 r 次成功出现时的总试验次数，其中 $r \in \mathbb{N}_+$ 、 $0 < p \leq 1$ 。则

$$P(T_r = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots,$$

且

$$E[T_r] = \frac{r}{p}, \quad \text{Var}(T_r) = \frac{r(1-p)}{p^2}.$$

不同教材也可能把“第 r 次成功前的失败数”定义为负二项变量，使用前必须核对支撑集。

2.4 常用连续分布

2.4.1 正态分布

定义 2.4.1 (正态分布 $N(\mu, \sigma^2)$). 参数满足 $\mu \in \mathbb{R}$ 、 $\sigma > 0$ ，密度为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \quad x \in \mathbb{R}.$$

其期望为 μ 、方差为 σ^2 ，并且

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1), \quad P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right).$$

扩展阅读：正态分布的结构地位

在具有给定均值和方差的绝对连续分布中，正态分布使微分熵达到最大；在独立同分布、有限非零方差的标准化和中，正态分布又是中心极限定理的极限。这两条结论都带有明确条件，不能简化为“任何叠加都会正态”。

2.4.2 均匀分布

定义 2.4.2 (均匀分布 $U(a, b)$). 若 $a < b$ 且

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{其他}, \end{cases}$$

则 $X \sim U(a, b)$ 。其期望为 $(a+b)/2$ ，方差为 $(b-a)^2/12$ 。

2.4.3 指数分布

定义 2.4.3 (指数分布 $\text{Exp}(\lambda)$). 若 $\lambda > 0$ ，且

$$f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{\{x>0\}},$$

则 $X \sim \text{Exp}(\lambda)$ 。其分布函数在 $x > 0$ 时为 $1 - e^{-\lambda x}$ ，期望为 $1/\lambda$ ，方差为 $1/\lambda^2$ 。

指数分布的无记忆性

条件 $X \sim \text{Exp}(\lambda)$, $s, t \geq 0$ 。

结论

$$P(X > s + t \mid X > s) = P(X > t).$$

用途 描述“已经等待多久不影响剩余等待时间”的连续寿命模型。

边界 在非负、非退化且具有适当连续性的分布中，指数分布才是唯一无记忆模型；一般寿命分布不具备该性质。

2.4.4 Gamma 分布

定义 2.4.4 (Gamma 分布: rate 参数化). 本书固定采用形状参数 $\alpha > 0$ 、率参数 $\lambda > 0$:

$$X \sim \Gamma(\alpha, \lambda) \iff f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbf{1}_{\{x>0\}}.$$

其期望和方差为

$$E[X] = \frac{\alpha}{\lambda}, \quad \text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

若教材采用尺度参数 $\theta = 1/\lambda$, 则密度中的 $e^{-\lambda x}$ 改写为 $e^{-x/\theta}$ 。

当 $\alpha = 1$ 时得到 $\text{Exp}(\lambda)$; 当 $\alpha = n \in \mathbb{N}_+$ 时, $\Gamma(n, \lambda)$ 可解释为速率为 λ 的泊松过程中等待第 n 个事件的时间。非整数形状参数没有“第 α 个事件”这一字面解释。此外 $\Gamma(\nu/2, 1/2) = \chi^2(\nu)$ 。

2.4.5 Beta 分布

定义 2.4.5 (Beta 分布 $\text{Beta}(a, b)$). 若 $a, b > 0$, 且

$$f_X(x) = \frac{x^{a-1}(1-x)^{b-1}}{B(a, b)} \mathbf{1}_{\{0 < x < 1\}},$$

其中 $B(a, b) = \Gamma(a)\Gamma(b)/\Gamma(a+b)$, 则

$$E[X] = \frac{a}{a+b}, \quad \text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}.$$

Beta 分布常用于描述 $[0, 1]$ 上的比例或概率参数。


扩展阅读：Beta-二项联系

以 $\text{Beta}(a, b)$ 作为伯努利成功概率 p 的先验，观察成功、失败次数后，后验仍为 Beta 分布。这是共轭结构的典型例子，具体推断将在参数估计章展开。

2.5 随机变量函数的分布

四个先问

已知 X ，求 $Y = g(X)$ 的分布时，依次问：

**方法选择表**

情形	首选方法
离散随机变量	列出 $g(x_k)$ ，合并同值概率
一维单调变换	反函数及 $ (d/dy)g^{-1}(y) $
一维非单调变换	分布函数法，或对各原像分支求和
分段函数、有界支撑	先写 Y 的范围，再分段求 F_Y
只求 $E[g(X)]$	LOTUS，不必先求 Y 的分布

2.5.1 离散变量的函数

例 2.5.1 (合并相同像点). 设 X 在 $\{-2, -1, 1, 2\}$ 上等可能，令 $Y = X^2$ 。则

$$P(Y = 1) = P(X = -1) + P(X = 1) = \frac{1}{2},$$

$$P(Y = 4) = P(X = -2) + P(X = 2) = \frac{1}{2}.$$

不能把四个原像直接当成 Y 的四个不同取值。

2.5.2 单调变换

若 g 在 X 的支撑上严格单调且反函数可微，则在变换后的支撑上

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

例 2.5.2 (均匀变量生成指数变量). 设 $X \sim U(0, 1)$, 令 $Y = -\ln X$ 。由于 $y > 0$ 且 $x = e^{-y}$,

$$f_Y(y) = 1 \cdot \left| \frac{d}{dy} e^{-y} \right| = e^{-y}, \quad y > 0.$$

故 $Y \sim \text{Exp}(1)$, 并且 $\int_0^\infty e^{-y} dy = 1$ 。

2.5.3 非单调变换

例 2.5.3 (平方变换与多原像). 设 $X \sim U(-1, 1)$, $Y = X^2$ 。当 $0 \leq y \leq 1$ 时,

$$F_Y(y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = \sqrt{y}.$$

因此

$$f_Y(y) = \frac{1}{2\sqrt{y}}, \quad 0 < y < 1.$$

同一个 y 有 $x = \pm\sqrt{y}$ 两个原像; 只保留一个分支会漏掉一半概率质量。

2.6 矩、偏度、峰度与分位数

2.6.1 矩

定义 2.6.1 (原点矩与中心矩). 在相应期望存在时, k 阶原点矩和中心矩分别为

$$\mu'_k = E[X^k], \quad \mu_k = E[(X - E[X])^k].$$

偏度通常用 $\gamma_1 = \mu_3/\mu_2^{3/2}$; 超额峰度用 $\gamma_2 = \mu_4/\mu_2^2 - 3$ 。

峰度不等于“尾厚”

峰度由标准化四阶矩决定, 既受尾部极端值影响, 也受概率质量在中心附近的集中方式影响。两个分布可以有相同峰度而尾部行为不同, 因此不能只凭峰度给出严格的尾厚排序。

2.6.2 分位数

定义 2.6.2 (p 分位数). 对 $0 < p < 1$, 本书统一定义下侧 p 分位数为

$$q_p = \inf\{x \in \mathbb{R} : F_X(x) \geq p\}.$$

该定义同时适用于连续、离散和混合分布。对连续且严格递增的 F_X , 它退化为 $F_X(q_p) = p$ 。

若使用“上侧 α 分位点”, 本书记为 $q_{1-\alpha}$; 连续情形下 $P(X > q_{1-\alpha}) = \alpha$ 。离散情形通常只能保证相应尾概率不超过或跨过目标值, 不能机械写成等号。

2.7 章末总结与 432 训练

分布关系图

$$\begin{aligned} \text{Bern}(p) &\xrightarrow{\text{独立求和}} B(n, p) \xrightarrow[p \rightarrow 0]{np \rightarrow \lambda} \text{Pois}(\lambda), \\ \text{Exp}(\lambda) &\xrightarrow{\text{独立等待时间求和}} \Gamma(n, \lambda), \quad N(\mu, \sigma^2) \xrightarrow{\text{标准化}} N(0, 1). \end{aligned}$$

“分布类型”由概率质量的结构决定; “常用分布”由具体产生机制决定; “函数分布”则研究映射怎样搬运概率质量。

计算检查表

1. 先写参数范围和支撑集;
2. 检查分布列求和或密度积分是否为 1;
3. 求函数分布先确定值域和原像数;
4. 只求期望时优先 LOTUS;
5. 用近似分布前先核对近似条件。

易错清单

1. 密度不是概率, 密度可以大于 1;
2. 随机变量不只分为离散型和连续型;
3. 超几何支撑下界不一定为 0;
4. Gamma 的 rate 与 scale 参数化不能混用;
5. 非整数形状参数不能解释为“等待第 α 个事件”;

6. 非单调变换必须累计所有原像分支；
7. 一般分位数用广义逆定义，峰度不等同于尾厚。

432 常见题型

由分布函数求区间概率、识别分布类型、常用分布参数反求、期望方差计算、概率不等式、随机变量函数分布及分位数查表。

A 级：直接计算

题目：设 $X \sim \text{Pois}(2)$ ，求 $P(X \leq 1)$ 。

简解：

$$P(X \leq 1) = e^{-2}(1 + 2) = 3e^{-2}.$$

B 级：条件判断与变换

题目：设 $X \sim U(0, 1)$ ， $Y = X/(1 - X)$ ，求 Y 的密度。

简解： $y > 0$ ，反函数 $x = y/(1 + y)$ ，故

$$f_Y(y) = \frac{1}{(1 + y)^2}, \quad y > 0.$$

C 级：反例与结构

题目：构造一个既非离散型也非连续型的分布，并求其期望。

简解：采用本章混合例： $P(X = 0) = p$ ，其余质量在 $(0, 1)$ 上均匀，则

$$E[X] = (1 - p) \int_0^1 x \, dx = \frac{1 - p}{2}.$$

第 3 章

多维随机变量及其分布

章首路线

多维概率的核心问题是：概率质量怎样分布在平面或高维空间中，又怎样被切片、投影与变换。本章路线为

联合分布 $\rightarrow$ 支撑集 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布
 $\rightarrow$ 独立性 $\rightarrow$ 函数分布 $\rightarrow$ 协方差与条件期望

连续型计算的第一步不是写积分，而是确定支撑区域及积分边界。

3.1 联合分布与支撑集

3.1.1 多维随机变量

定义 3.1.1 (n 维随机向量). 若 $X_1, \dots, X_n$ 定义在同一概率空间上，则

$$\mathbf{X} = (X_1, \dots, X_n)^T$$

称为 n 维随机向量。

3.1.2 联合分布函数、分布列与密度

定义 3.1.2 (联合分布函数). 二维随机向量 (X, Y) 的联合分布函数为

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y), \quad (x, y) \in \mathbb{R}^2.$$

离散情形用联合分布列

$$p_{ij} = P(X = x_i, Y = y_j), \quad p_{ij} \geq 0, \quad \sum_i \sum_j p_{ij} = 1$$

3.1 联合分布与支撑集

描述。

定义 3.1.3 (联合密度). 若存在非负可积函数 $f_{X,Y}$, 使

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) \, dv \, du,$$

且 $\iint_{\mathbb{R}^2} f_{X,Y}(x, y) \, dx \, dy = 1$, 则称 $f_{X,Y}$ 为联合密度。

积分变量必须与边界匹配

在

$$\int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) \, dv \, du$$

中, 内层变量 v 的上界是 y , 外层变量 u 的上界是 x 。交换积分次序时, 积分限也必须按支撑区域重新书写。

3.1.3 贯穿本章的三角形密度

例 3.1.1 (先检查支撑与归一化). 以后反复使用

$$f_{X,Y}(x, y) = \begin{cases} 2, & 0 < y < x < 1, \\ 0, & \text{其他.} \end{cases}$$

支撑集是单位正方形内直线 $y = x$ 下方的开三角形:

$$D = \{(x, y) : 0 < x < 1, 0 < y < x\} = \{(x, y) : 0 < y < 1, y < x < 1\}.$$

归一化检查为

$$\int_0^1 \int_0^x 2 \, dy \, dx = \int_0^1 2x \, dx = 1.$$

两种等价写法分别适合先对 y 或先对 x 积分。

3.1.4 二维正态分布

定义 3.1.4 (非退化二维正态分布). 记

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix},$$

3.2 边缘分布、条件分布与独立性

其中 $\sigma_X, \sigma_Y > 0$ 、 $|\rho| < 1$ 。记

$$Q(x, y) = \frac{(x - \mu_X)^2}{\sigma_X^2} - \frac{2\rho(x - \mu_X)(y - \mu_Y)}{\sigma_X \sigma_Y} + \frac{(y - \mu_Y)^2}{\sigma_Y^2}.$$

若

$$f_{X,Y}(x, y) = \frac{\exp[-Q(x, y)/(2(1 - \rho^2))]}{2\pi\sigma_X\sigma_Y\sqrt{1 - \rho^2}},$$

则记 $(X, Y)^\top \sim N_2(\boldsymbol{\mu}, \Sigma)$ 。

其边缘分布仍为正态，且

$$Y \mid X = x \sim N\left(\mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X), \sigma_Y^2(1 - \rho^2)\right).$$

在联合正态条件下， $\rho = 0$ 等价于 X, Y 独立；一般分布中这一结论不成立。

3.2 边缘分布、条件分布与独立性

3.2.1 边缘分布

联合分布通过“消去另一个变量”得到边缘分布：

$$F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y), \quad F_Y(y) = \lim_{x \rightarrow +\infty} F_{X,Y}(x, y).$$

离散型和连续型分别为

$$P(X = x_i) = \sum_j p_{ij}, \quad f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) \, dy,$$

$$P(Y = y_j) = \sum_i p_{ij}, \quad f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) \, dx.$$

例 3.2.1 (三角形密度的边缘分布). 利用支撑的两种写法，

$$f_X(x) = \int_0^x 2 \, dy = 2x, \quad 0 < x < 1,$$

$$f_Y(y) = \int_y^1 2 \, dx = 2(1 - y), \quad 0 < y < 1.$$

两个边缘密度都积分为 1，可作为边界设置的反向检查。

扩展阅读：联合分布不由边缘唯一确定

联合分布能唯一确定边缘分布，反向一般不成立。相同的两个边缘可以由不同依赖结构耦合。Copula 是描述这种依赖结构的一类工具，宜在掌握边缘、条件与独立性的主干计算后再学习。

3.2.2 条件分布：先离散，后连续

离散型条件分布为

$$P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)}, \quad P(X = x_i) > 0.$$

例 3.2.2 (离散二维表的条件分布). 设联合分布列为

	$Y = 0$	$Y = 1$	P_X
$X = 0$	0.1	0.2	0.3
$X = 1$	0.3	0.4	0.7
P_Y	0.4	0.6	1

则

$$P(Y = 1 | X = 1) = \frac{0.4}{0.7} = \frac{4}{7}, \quad E[Y | X = 1] = \frac{4}{7}.$$

条件化相当于取 $X = 1$ 这一行，再除以该行总概率 0.7。

定义 3.2.1 (连续型条件密度). 若 $f_X(x) > 0$ ，则

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

对固定 x ，它是关于 y 的密度；其支撑是联合支撑在竖线 $X = x$ 上的截面。

例 3.2.3 (三角形密度的条件切片). 由 $f_X(x) = 2x$,

$$f_{Y|X}(y | x) = \frac{2}{2x} = \frac{1}{x}, \quad 0 < y < x < 1.$$

因此给定 $X = x$ 后， Y 在 $(0, x)$ 上均匀分布，并且

$$E[Y | X = x] = \int_0^x y \frac{1}{x} dy = \frac{x}{2}.$$

3.2.3 条件期望、全期望与全方差

定义 3.2.2 (条件期望). 在离散或具有条件密度的情形, 先定义

$$m(x) = E[Y | X = x].$$

把 x 换回随机变量 X , 得到

$$E[Y | X] = m(X),$$

它是 X 的函数, 因而通常仍是随机变量, 而不是常数。

全期望与全方差公式

条件 全期望要求 Y 可积; 全方差要求 $E[Y^2] < \infty$ 。

结论

$$E[Y] = E[E[Y | X]],$$

$$\text{Var}(Y) = E[\text{Var}(Y | X)] + \text{Var}(E[Y | X]).$$

用途 先按 X 分层计算局部均值与局部波动, 再汇总为总体量。该分解也是 Rao-Blackwell 改进和 ANOVA 平方和分解的概率原型。

边界 条件期望是随机变量; 不能把 $E[Y | X]$ 当作某个固定数直接移出期望。

例 3.2.4 (用三角形密度核对两条公式). 前面得到 $E[Y | X] = X/2$, 而 $f_X(x) = 2x$, 故

$$E[E[Y | X]] = \frac{1}{2}E[X] = \frac{1}{2} \int_0^1 x(2x) dx = \frac{1}{3} = E[Y].$$

给定 $X = x$ 时, $Y \sim U(0, x)$, 所以

$$E[\text{Var}(Y | X)] = E\left[\frac{X^2}{12}\right] = \frac{1}{24},$$

$$\text{Var}(E[Y | X]) = \text{Var}(X/2) = \frac{1}{72}.$$

二者之和为 $1/18$, 正好等于由边缘密度 $f_Y(y) = 2(1 - y)$ 算得的 $\text{Var}(Y)$ 。

扩展阅读：条件期望是 L^2 投影

若 $Y \in L^2$ ，则所有平方可积的 $\sigma(X)$ -可测随机变量构成 L^2 中的闭子空间。 $E[Y | X]$ 是 Y 在该子空间上的正交投影，并满足

$$E[(Y - E[Y | X])h(X)] = 0$$

对所有平方可积的 $h(X)$ 成立。因此

$$E[(Y - h(X))^2] = E[(Y - E[Y | X])^2] + E[(E[Y | X] - h(X))^2].$$

3.2.4 随机变量的独立性

定义 3.2.3 (独立性). X, Y 独立，当且仅当

$$F_{X,Y}(x, y) = F_X(x)F_Y(y), \quad \forall x, y.$$

离散型等价于 $p_{ij} = p_i p_j$ ；连续型等价于

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) \quad \text{几乎处处.}$$

先看支撑能否分解

三角形密度的支撑 $0 < y < x < 1$ 不是一个直积区域。虽然 $f_X(x)f_Y(y) = 4x(1-y)$ 在正方形内部通常为正，联合密度却在三角形外为零，因此 X, Y 不独立。仅比较几个矩或只看密度公式中的常数，不能判定独立。

3.3 多维随机变量函数的分布

连续型函数分布固定流程

1. 画出或用不等式写清联合支撑；
2. 写目标事件，例如 $\{X + Y \leq z\}$ ；
3. 画辅助边界，找出与支撑边界的交点；
4. 按交点分段积分；
5. 检查所得分布函数单调、端点正确，或密度积分为 1。

3.3.1 最大值与最小值

独立变量最大值与最小值的分布

条件 $X_1, \dots, X_n$ 相互独立, 分布函数分别为 F_i 。

结论

$$F_{\max}(z) = \prod_{i=1}^n F_i(z), \quad F_{\min}(z) = 1 - \prod_{i=1}^n [1 - F_i(z)].$$

用途 次序统计量、系统寿命与极值题。

边界 乘积形式依赖独立性; 相关变量必须回到联合分布计算。

3.3.2 和的分布与卷积

若 X, Y 独立且具有密度, $Z = X + Y$ 的密度为

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx.$$

不独立时应使用联合密度:

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(x, z-x) dx,$$

积分范围由 $(x, z-x)$ 落在联合支撑内确定。

例 3.3.1 (三角形密度中 $X+Y$ 的分布). 令 $S = X+Y$ 。约束 $0 < s-x < x < 1$ 给出

$$\frac{s}{2} < x < \min\{s, 1\}.$$

因此

$$f_S(s) = \begin{cases} \int_{s/2}^s 2 dx = s, & 0 < s < 1, \\ \int_{s/2}^1 2 dx = 2-s, & 1 \leq s < 2, \\ 0, & \text{其他.} \end{cases}$$

两个分段在 $s=1$ 处衔接, 且总积分为 1。

3.3.3 二维变量变换与 Jacobian

二维一一变量变换

条件 在支撑区域 D 上, 变换 $(u, v) = T(x, y)$ 一一、连续可微, $\det DT(x, y) \neq 0$, 并有连续可微反变换 $(x, y) = h(u, v)$ 。

结论 对 $(u, v) \in T(D)$,

$$f_{U,V}(u, v) = f_{X,Y}(h(u, v)) \left| \frac{\partial(x, y)}{\partial(u, v)} \right| = \frac{f_{X,Y}(x, y)}{\left| \frac{\partial(x, y)}{\partial(u, v)} \right|}.$$

在 $T(D)$ 外密度为零。

用途 把复杂函数分布化为坐标变换; 用反变换时乘反 Jacobian, 用正变换时除正 Jacobian。

边界 若变换非一一, 必须先分支, 再把各原像贡献相加; 不能漏掉变换后的支撑。

为什么要乘反 Jacobian

反变换把 (u, v) 平面中的小面积 $du dv$ 映为

$$dx dy = \left| \frac{\partial(x, y)}{\partial(u, v)} \right| du dv.$$

概率质量保持不变, 所以新密度等于原密度乘这个反变换面积因子。正、反 Jacobian 满足

$$\left| \frac{\partial(x, y)}{\partial(u, v)} \right| = \frac{1}{\left| \frac{\partial(u, v)}{\partial(x, y)} \right|}.$$

例 3.3.2 (三角形密度中比值的分布). 令 $U = X$ 、 $R = Y/X$ 。反变换为 $x = u$ 、 $y = ur$, 且

$$\left| \frac{\partial(x, y)}{\partial(u, r)} \right| = u.$$

原支撑 $0 < y < x < 1$ 变为 $0 < u < 1$ 、 $0 < r < 1$, 故

$$f_{U,R}(u, r) = 2u, \quad 0 < u < 1, \quad 0 < r < 1.$$

边缘化得到

$$f_R(r) = \int_0^1 2u du = 1, \quad 0 < r < 1,$$

所以 $Y/X \sim U(0, 1)$ 。

3.4 协方差、相关系数与协方差矩阵

3.4.1 协方差与相关系数

定义 3.4.1 (协方差). 若 X, Y 具有有限二阶矩, 则

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y].$$

定义 3.4.2 (相关系数). 若 $0 < \text{Var}(X), \text{Var}(Y) < \infty$, 定义

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.$$

由 Cauchy-Schwarz 不等式, $|\rho_{XY}| \leq 1$ 。

中心化随机变量空间中的几何

在 L^2 中,

$$\text{Cov}(X, Y) = \langle X - E[X], Y - E[Y] \rangle_{L^2}.$$

因此相关系数是两个中心化随机变量夹角的余弦。独立且二阶矩有限可推出不相关, 但不相关只排除了线性关系, 通常不能推出独立。

例 3.4.1 (不相关但不独立). 设 $X \sim U(-1, 1)$, $Y = X^2$ 。由对称性,

$$\text{Cov}(X, Y) = E[X^3] - E[X]E[X^2] = 0.$$

但 Y 完全由 X 决定, 所以二者不独立。

3.4.2 协方差矩阵与 PCA

定义 3.4.3 (协方差矩阵). 对 $\mathbf{X} = (X_1, \dots, X_n)^\top$, 定义

$$\Sigma = (\sigma_{ij})_{n \times n}, \quad \sigma_{ij} = \text{Cov}(X_i, X_j).$$

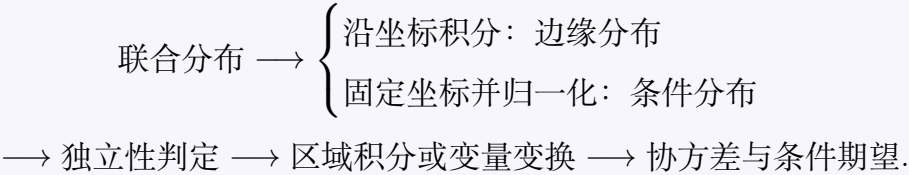
Σ 为实对称半正定矩阵。

扩展阅读: PCA 只保证去相关

协方差矩阵的正交对角化给出主成分方向。变换后的各主成分两两不相关, 并可按方差大小做降维; 一般情况下这不意味着主成分独立或“完全解耦”。只有联合正态等特殊模型中, 不相关才进一步推出独立。

3.5 章末总结与 432 训练

知识关系图



区域积分与变换决策表

目标	首选方法
边缘密度	沿另一个坐标方向在支撑上积分
条件密度	联合密度除以相应边缘密度
独立性	检查支撑直积性及密度能否分解
和、差	事件区域积分；独立时可用卷积
最大值、最小值	分布函数法
二维 $\longleftrightarrow$ 变换	反变换、变换后支撑、反 Jacobian
非一一变换	分区使其一一，再求和

易错清单

1. 不画支撑就写积分限，最容易造成分段遗漏；
2. 联合分布决定边缘，边缘一般不决定联合；
3. $E[Y | X = x]$ 是关于 x 的函数， $E[Y | X]$ 是随机变量；
4. 不相关不等于独立，PCA 一般也不产生独立分量；
5. Jacobian 要分清正变换与反变换；
6. 相关系数要求两个方差均严格为正。

432 常见题型

由联合求边缘与条件分布、独立性判定、和与极值分布、区域分段积分、二维 Jacobian、协方差相关系数、全期望与全方差。

A 级：边缘与条件

题目：对本章三角形密度，求 $P(Y < X/2 | X = x)$ 。

简解：给定 $X = x$ 时 $Y \sim U(0, x)$ ，故概率为 $1/2$ 。

B 级：卷积

题目：若 X, Y 独立且均服从 $\text{Exp}(\lambda)$ ，求 $S = X + Y$ 的密度。

简解：

$$f_S(s) = \int_0^s \lambda e^{-\lambda x} \lambda e^{-\lambda(s-x)} dx = \lambda^2 s e^{-\lambda s}, \quad s > 0.$$

即 $S \sim \Gamma(2, \lambda)$ 。

C 级：结构与反例

题目：证明 $E[Y | X]$ 是均方误差意义下预测 Y 的最优 X -函数，并说明不相关为何不足以保证独立。

简解：使用本章 L^2 正交分解；第二问可用 $X \sim U(-1, 1)$ 、 $Y = X^2$ 的反例。

第二部分

极限定理

第 4 章

大数定律与中心极限定理

章首路线

本章区分三个问题：

1. 随机变量序列以什么意义收敛；
2. 样本均值为什么接近总体均值；
3. 误差按 $\sqrt{n}$ 放大后为什么常出现正态形状。

主线为

收敛方式 $\rightarrow$ 特征函数 $\rightarrow$ 大数定律 $\rightarrow$ 中心极限定理 $\rightarrow$ 正态近似.

四个容易混淆的结论

理论	研究对象	典型结论
大数定律	样本均值 $\bar{X}_n$	$\bar{X}_n \xrightarrow{P} \mu$
中心极限定理	标准化均值误差	$\sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{d} N(0, 1)$
相合性	一般估计量 $\hat{\theta}_n$	$\hat{\theta}_n \xrightarrow{P} \theta$
渐近正态性	标准化估计误差	$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, V)$

大数定律说明“误差趋零”，中心极限定理说明“适当放大后的误差形状”；二者不能互相替代。

4.1 随机变量序列的收敛方式

4.1.1 几乎必然收敛

定义 4.1.1 (几乎必然收敛). 若 X_n, X 定义在同一概率空间上, 且

$$P\{\omega : X_n(\omega) \rightarrow X(\omega)\} = 1,$$

则称 X_n 几乎必然收敛于 X , 记作 $X_n \xrightarrow{\text{a.s.}} X$ 。

例 4.1.1 (逐条样本路径最终稳定). 设 $U \sim U(0, 1)$, $X_n = \mathbf{1}_{\{U \leq 1/n\}}$ 。对每个 $U(\omega) > 0$, 当 n 足够大时 $1/n < U(\omega)$, 于是 $X_n(\omega) = 0$ 。故

$$X_n \xrightarrow{\text{a.s.}} 0.$$

4.1.2 依概率收敛

定义 4.1.2 (依概率收敛). 若对任意 $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0,$$

则称 X_n 依概率收敛于 X , 记作 $X_n \xrightarrow{P} X$ 。

它表示“大偏差发生的概率趋于零”, 是统计量相合性的基本语言。

4.1.3 依分布收敛

定义 4.1.3 (依分布收敛). 设 F_n, F 分别是 X_n, X 的分布函数。若在 F 的每个连续点 x 都有

$$F_n(x) \rightarrow F(x),$$

则称 X_n 依分布收敛于 X , 记作 $X_n \xrightarrow{d} X$ 或 $X_n \Rightarrow X$ 。

依分布收敛只比较概率分布, 不要求 X_n 与 X 定义在同一概率空间。

例 4.1.2 (依分布不推出依概率). 设 $X \sim N(0, 1)$, 并令每个 $X_n = -X$ 。则 X_n 与 X 同分布, 故 $X_n \xrightarrow{d} X$; 但

$$|X_n - X| = 2|X|$$

不依概率趋于 0, 所以 $X_n \not\xrightarrow{P} X$ 。

4.1.4 收敛关系与反例边界

常用收敛关系

条件 涉及依概率或几乎必然收敛时，随机变量定义在可比较的同一概率空间上。

结论

$$X_n \xrightarrow{\text{a.s.}} X \implies X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X.$$

若 $X_n \xrightarrow{d} c$ ，其中 c 为常数，则 $X_n \xrightarrow{P} c$ 。若 $E[(X_n - X)^2] \rightarrow 0$ ，则 $X_n \xrightarrow{P} X$ 。

用途 在证明中选择更容易验证的强收敛方式，并把结论传递到较弱方式。

边界 反向蕴含一般不成立；只有“依分布收敛到常数”这一特殊情形可反推依概率收敛。

扩展阅读：依概率但不几乎必然

在 $[0, 1]$ 上按二进区间依次扫描的“打字机序列”指示函数，其取值为 1 的区间长度趋于 0，故依概率收敛到 0；但几乎每个点会无限多次落入扫描区间，样本路径不收敛。该例说明依概率收敛不能反推几乎必然收敛。

Slutsky 定理

条件 $X_n \xrightarrow{d} X$ ， $Y_n \xrightarrow{P} c$ ，其中 c 为常数。商的结论还要求 $c \neq 0$ 。

结论

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX,$$

且当 $c \neq 0$ 时

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}.$$

用途 用相合估计量替代未知常数，建立统计量的渐近分布。

边界 若 Y_n 的极限不是常数，或分母极限为零，不能直接套用上述形式。

4.2 特征函数

4.2.1 定义与基本性质

定义 4.2.1 (特征函数). 随机变量 X 的特征函数为

$$\varphi_X(t) = E[e^{itX}] = \int_{\mathbb{R}} e^{itx} dF_X(x), \quad t \in \mathbb{R}.$$

由于 $|e^{itX}| = 1$, 任意概率分布的特征函数都存在。

特征函数的基本性质

条件 $a, b, t \in \mathbb{R}$; 求 k 阶导数时要求 $E|X|^k < \infty$ 。

结论

$$\varphi_X(0) = 1, \quad |\varphi_X(t)| \leq 1,$$

$$\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at), \quad \varphi_X^{(k)}(0) = i^k E[X^k].$$

若 X, Y 独立, 则

$$\varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t).$$

用途 把独立和的卷积转化为乘法, 并通过极限识别分布。

边界 乘法法则需要独立性; 矩不存在时不能用原点导数公式求该阶矩。

4.2.2 三个标准算例

例 4.2.1 (正态分布). 若 $X \sim N(\mu, \sigma^2)$, 配方或标准化可得

$$\varphi_X(t) = \exp\left(i\mu t - \frac{\sigma^2 t^2}{2}\right).$$

特别地, 标准正态的特征函数为 $e^{-t^2/2}$ 。

例 4.2.2 (泊松分布). 若 $X \sim \text{Pois}(\lambda)$, 则

$$\begin{aligned} \varphi_X(t) &= \sum_{k=0}^{\infty} e^{itk} e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \exp\{\lambda(e^{it} - 1)\}. \end{aligned}$$

4.3 大数定律

例 4.2.3 (独立泊松变量之和). 若 $X \sim \text{Pois}(\lambda_1)$ 、 $Y \sim \text{Pois}(\lambda_2)$ 且独立, 则

$$\varphi_{X+Y}(t) = \exp\{(\lambda_1 + \lambda_2)(e^{it} - 1)\}.$$

由特征函数唯一性, $X + Y \sim \text{Pois}(\lambda_1 + \lambda_2)$ 。

4.2.3 唯一性与连续性定理

Lévy 连续性定理

条件 φ_n 是 X_n 的特征函数。

结论 若 $X_n \xrightarrow{d} X$, 则 $\varphi_n(t) \rightarrow \varphi_X(t)$ 。反之, 若 $\varphi_n(t)$ 逐点收敛到函数 $\varphi(t)$, 且 φ 在 0 处连续, 则 φ 是某个分布的特征函数, 且 X_n 依分布收敛到该分布。

用途 把分布函数的弱收敛转化为特征函数的逐点收敛, 是 CLT 证明的核心工具。

边界 任意逐点极限未必是特征函数; 在 0 处连续这一条件不可省略。

扩展阅读: 弱收敛观点

依分布收敛等价于对所有有界连续函数 g 有 $E[g(X_n)] \rightarrow E[g(X)]$ 。这里只能推出这类测试函数的期望收敛, 不能不加条件地推出 $E[X_n] \rightarrow E[X]$ 。

4.3 大数定律

均值为什么稳定

平均会稀释单个观测的随机波动。大数定律给出的是收敛结论, 不是“有限样本已经等于总体均值”, 也不直接给出误差的正态形状。

4.3.1 伯努利大数定律

4.3 大数定律

伯努利大数定律

条件 n 次试验独立同分布, 每次事件 A 发生的概率为 p 。

结论 若 N_n 为前 n 次中 A 的发生次数, 则

$$\frac{N_n}{n} \xrightarrow{P} p.$$

用途 说明重复试验频率可作为概率的相合估计。

边界 它是渐近结论; 有限样本频率仍有随机误差。

4.3.2 切比雪夫大数定律

切比雪夫大数定律

条件 $X_1, X_2, \dots$ 两两不相关, 具有有限期望与方差, 且存在常数 C 使 $\text{Var}(X_i) \leq C$ 。

结论

$$\frac{1}{n} \sum_{i=1}^n (X_i - E[X_i]) \xrightarrow{P} 0.$$

用途 用方差控制证明不必同分布的平均值依概率稳定。

边界 若相关性使方差不能相消, 或方差增长过快, 该结论不能直接使用。

其证明来自

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \leq \frac{C}{n}$$

和切比雪夫不等式。

4.3.3 辛钦大数定律

辛钦大数定律

条件 $X_1, X_2, \dots$ 独立同分布, 且 $E|X_1| < \infty$; 记 $E[X_1] = \mu$ 。

结论

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu.$$

用途 在不要求方差有限时证明样本均值的弱相合性。

边界 只要求一阶绝对矩, 但不提供有限样本误差率, 也不保证经典 $\sqrt{n}$ -CLT。

例 4.3.1 (芯片缺陷率的误差界). 设每片芯片是否有缺陷相互独立, 缺陷概率 $p = 0.02$. 抽检 $n = 10000$ 片, 样本缺陷率为 $\hat{p}$. 则

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

由切比雪夫不等式,

$$P(|\hat{p} - p| \geq 0.01) \leq \frac{0.02 \times 0.98}{10000 \times 0.01^2} = 0.0196.$$

该界保证偏差至少一个百分点的概率不超过 1.96%; 实际概率通常更小。

扩展阅读: 强大数定律

在独立同分布且 $E|X_1| < \infty$ 的条件下, Kolmogorov 强大数定律给出

$$\bar{X}_n \xrightarrow{\text{a.s.}} \mu.$$

它比辛钦大数定律的依概率收敛更强。

4.4 中心极限定理与正态近似

放大误差而不是放大均值

大数定律说明 $\bar{X}_n - \mu \rightarrow 0$; 中心极限定理研究 $\sqrt{n}(\bar{X}_n - \mu)$ 的极限形状。 $\sqrt{n}$ 是典型有限方差模型中的误差尺度, 而不是对所有重尾模型都适用的万能标准化。

4.4.1 独立同分布中心极限定理

Lindeberg-Lévy 中心极限定理

条件 $X_1, X_2, \dots$ 独立同分布, $E[X_1] = \mu$, 且 $0 < \text{Var}(X_1) = \sigma^2 < \infty$ 。

结论

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

用途 近似独立同分布和或样本均值的中央区域概率, 并构造大样本统计推断。

边界 独立性、同分布或有限非零方差被破坏时, 必须检查其他 CLT 条件; 有限样本尾部近似可能较差。

4.4 中心极限定理与正态近似

特征函数证明的核心. 令 $Z_i = (X_i - \mu)/\sigma$, 其特征函数记为 φ . 由 $E[Z_i] = 0$, $E[Z_i^2] = 1$,

$$\varphi(s) = 1 - \frac{s^2}{2} + o(s^2), \quad s \rightarrow 0.$$

独立性给出

$$\varphi_{\frac{1}{\sqrt{n}} \sum Z_i}(t) = \left[\varphi\left(\frac{t}{\sqrt{n}}\right) \right]^n = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n \rightarrow e^{-t^2/2}.$$

极限是标准正态特征函数, 故由 Lévy 连续性定理得到结论。□

4.4.2 二项分布的正态近似

De Moivre–Laplace 定理

条件 $X_n \sim B(n, p)$, 其中固定 $0 < p < 1$ 。

结论

$$\frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1).$$

用途 把二项概率近似为正态概率。

边界 有限样本中若 np 或 $n(1-p)$ 太小, 分布偏斜明显; 离散到连续的近似应使用连续性修正。

二项正态近似的计算链

1. 先检查 np 与 $n(1-p)$ 。常用经验规则是二者均不小于 10; 这是经验标准, 不是定理条件。
2. 对整数区间做连续性修正:

$$P(a \leq X \leq b) \approx P(a - 0.5 < Y < b + 0.5), \quad Y \sim N(np, np(1-p)).$$

3. 标准化后查 Φ 表。
4. 尾部、小概率或强偏态问题要谨慎, 必要时计算精确二项概率。

例 4.4.1 (带连续性修正的二项近似). 设 $X \sim B(100, 0.3)$, 近似计算 $P(25 \leq X \leq 35)$ 。有

$$\mu = 30, \quad \sigma = \sqrt{21}.$$

作连续性修正后

$$\begin{aligned} P(25 \leq X \leq 35) &\approx P\left(\frac{24.5 - 30}{\sqrt{21}} < Z < \frac{35.5 - 30}{\sqrt{21}}\right) \\ &= 2\Phi(1.20) - 1 \approx 0.7699. \end{aligned}$$

这里 $np = 30$ 、 $n(1 - p) = 70$ ，中央区间的正态近似较为合适。精确二项概率为

$$\sum_{k=25}^{35} \binom{100}{k} 0.3^k 0.7^{100-k} \approx 0.77035,$$

与连续性修正近似的绝对误差约为 0.00045。

4.4.3 独立不同分布的情形

Lyapunov 条件下的中心极限定理

条件 X_i 相互独立, $E[X_i] = \mu_i$, $\text{Var}(X_i) = \sigma_i^2$, 令 $B_n^2 = \sum_{i=1}^n \sigma_i^2$, 并设 $B_n \rightarrow \infty$ 。若存在 $\delta > 0$ 使

$$\frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E|X_i - \mu_i|^{2+\delta} \rightarrow 0,$$

则条件成立。

结论

$$\frac{\sum_{i=1}^n (X_i - \mu_i)}{B_n} \xrightarrow{d} N(0, 1).$$

用途 处理独立但不同分布的随机变量和。

边界 该条件排除单个变量对总波动的支配；仅有独立而无矩条件并不足以保证正态极限。

扩展阅读：重尾极限


若方差无穷，经典 $\sqrt{n}$ 标准化的 CLT 可能失效。在额外吸引域条件下，适当归一化的和可能趋于 α -稳定分布。柯西分布的独立和经线性缩放后仍为柯西分布，是典型例子。

4.4.4 数值表：均值稳定与形状稳定

以 $X_i \sim \text{Bern}(0.3)$ 为例。样本均值标准差为 $\sqrt{0.21/n}$ ；标准化和的偏度为 $0.4/\sqrt{0.21n}$ ，超额峰度为 $-0.26/(0.21n)$ ：

n	10	100	1000
$\text{sd}(\bar{X}_n)$	0.1449	0.0458	0.0145
标准化和的偏度	0.2760	0.0873	0.0276
标准化和的超额峰度	-0.1238	-0.0124	-0.0012

第一行趋于 0 展示 LLN 意义下的集中；后两行趋近正态分布的偏度 0、超额峰度 0，展示 CLT 的形状稳定。



左图使用一条固定的伯努利样本路径，其累计成功比例依次为

$$(0.40, 0.333, 0.310, 0.303, 0.300).$$

右图使用固定分箱高度

$$(0.06, 0.24, 0.40, 0.24, 0.06)$$

与标准正态轮廓作对照。前者展示数值趋稳，后者展示标准化分布形状趋近，二者对应 LLN 与 CLT 的不同结论。

4.5 章末总结与 432 训练

知识关系图

矩条件与独立结构 $\xrightarrow{\text{LLN}} \bar{X}_n \rightarrow \mu$,

中心化、按 $\sqrt{n}$ 标准化 $\xrightarrow{\text{CLT}} N(0, 1) \xrightarrow{\text{Slutsky}} \text{渐近统计推断}$.

特征函数把“独立求和”变成“函数乘积”，从而连接随机变量和与分布极限。

方法选择表

目标	首选工具
证明依概率收敛	马尔可夫/切比雪夫不等式或更强收敛
证明依分布收敛	分布函数、特征函数、CLT 或 Slutsky
独立同分布均值趋于期望	辛钦大数定律
独立同分布和的中央近似	Lindeberg-Lévy CLT
二项概率中央区域	连续性修正后的正态近似
独立不同分布之和	检查 Lyapunov/Lindeberg 条件

易错清单

1. 依分布收敛一般不推出依概率收敛，极限为常数时例外；
2. LLN 说明均值误差趋零，CLT 说明标准化误差的形状；
3. CLT 的方差必须有限且严格为正；
4. 特征函数乘法需要独立性；
5. 二项正态近似要检查 $np, n(1-p)$ 并做连续性修正；
6. 正态近似在尾部可能比中央区域误差更大；
7. 不能把任何特征函数极限都断言为 $e^{-t^2/2}$ 。

432 常见题型

收敛方式辨析、用不等式证明依概率收敛、LLN 条件判断、CLT 标准化、二项与泊松近似、连续性修正、Slutsky 定理和特征函数识别分布。

A 级：标准化

题目：若 X_i i.i.d., $E[X_i] = 2$, $\text{Var}(X_i) = 9$, 写出 CLT 标准化式。

简解：

$$\frac{\sqrt{n}(\bar{X}_n - 2)}{3} \xrightarrow{d} N(0, 1).$$

B 级：正态近似

题目：设 $X \sim B(200, 0.4)$, 写出 $P(X \leq 70)$ 的连续性修正近似。

简解：

$$P(X \leq 70) \approx \Phi\left(\frac{70.5 - 80}{\sqrt{48}}\right).$$

C 级：特殊逆命题

题目：证明 $X_n \xrightarrow{d} c$ 蕴含 $X_n \xrightarrow{P} c$ 。

简解：对任意 $\varepsilon > 0$ ，退化分布函数在 $c - \varepsilon$ 、 $c + \varepsilon$ 处连续，故

$$P(|X_n - c| > \varepsilon) \leq P(X_n \leq c - \varepsilon) + P(X_n > c + \varepsilon) \rightarrow 0.$$

第三部分

数理统计初步

第 5 章

统计量及其分布

直觉与动机

从本章起，视角由概率论的“已知分布求数据规律”转向数理统计的“由数据反推分布与参数”。总体分布中含有未知信息，而抽样给出可观测数据；统计量则把原始样本压缩为可以分析的随机对象。本章先分清“抽样前的随机变量”和“抽样后的数值”，再建立样本矩、次序统计量和三大抽样分布，最后用充分统计量说明何时压缩不会损失关于参数的信息。

本章路线与层次

432/数三主线：

总体与随机样本 $\longrightarrow$ 统计量及其抽样分布 $\longrightarrow \bar{X}, S^2, A_k, X_{(k)},$
 $\bar{X}, S^2, A_k, X_{(k)} \longrightarrow \chi^2, t, F \longrightarrow$ 第六、七章的估计与检验.

结构理解：正态样本的平方和分解对应正交投影与自由度分解。**扩展阅读：**充分性与完备性用于连接 Rao-Blackwell 与 UMVUE，不应打断抽样分布主线。

5.1 总体与样本

5.1.1 总体与个体

总体：研究对象的某个数量指标 X 的全体，以 X 的分布来描述。**个体：**总体中的每个成员。

5.1.2 样本

定义 5.1.1 (简单随机样本). 若 $X_1, X_2, \dots, X_n$ 满足:

- 1. 与总体 X 同分布;
- 2. 相互独立;

则称 $(X_1, \dots, X_n)$ 为来自总体 X 的**容量为 n 的简单随机样本** (i.i.d. 样本)。

条件与易错点

抽样前, $(X_1, \dots, X_n)$ 是一组 i.i.d. 随机变量; 抽样后, $(x_1, \dots, x_n)$ 是它的一次实现。统计推导研究前者, 实际计算把后者代入统计量。不要把“样本”和“样本值”混写, 也不要把大写、希腊字母机械地绑定为某一类对象; 符号角色必须由定义和上下文决定。

结构与证明		
统计对象辨析表		
对象	本质	例子
随机变量 X	从样本空间到实数轴的可测函数	把试验结果映射为寿命、误差、0/1 指标
分布函数 F_X	X 在实数轴上的概率规律	$F_X(x) = P(X \leq x)$
样本 $X_1, \dots, X_n$	抽样前的一组 i.i.d. 随机变量	理论推导中的随机样本
样本值 $x_1, \dots, x_n$	抽样后的具体观测数字	实验记录或数据表中的数值
统计量 $T(X)$	不含未知参数的样本函数	$\bar{X}, S^2, X_{(1)}$
估计量 $\hat{\theta}(X)$	用于估计参数的统计量	$\hat{\lambda} = 1/\bar{X}$
估计值 $\hat{\theta}(x)$	代入样本值后的数字	某次计算得到的 0.37

5.2 样本数据的整理与显示

5.2.1 经验分布函数

定义 5.2.1 (经验分布函数). 对随机样本 $(X_1, \dots, X_n)$, 定义随机经验分布函数

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

观测到 $(x_1, \dots, x_n)$ 后, 其实现为

$$\hat{F}_n(x; x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{x_i \leq x\}},$$

是右连续的非降阶梯函数。

Glivenko–Cantelli 定理

条件 $(X_1, X_2, \dots)$ 为来自分布函数 F_X 的 i.i.d. 样本。

结论

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_X(x)| \xrightarrow{\text{a.s.}} 0.$$

用途 说明经验分布函数在全实轴上一致逼近总体分布函数。

边界 这是渐近结论; 有限样本仍有随机误差, 也不等于恢复了全部数据生成机制。

结构与证明

对每个固定 x , $\hat{F}_n(x)$ 是 Bernoulli 指示变量的样本均值; Glivenko–Cantelli 定理进一步把逐点收敛加强为关于 x 的一致收敛。这里应称“几乎必然的一致收敛”, 不要与“几乎处处收敛”混为一谈。

5.2.2 频数频率表与图形显示

频率直方图、茎叶图、箱线图等是探索性数据分析 (EDA) 的基本工具, 用于在建模前直观了解数据的分布形状、中心位置和离散程度。

5.3 统计量及其分布

5.3.1 统计量与抽样分布

定义 5.3.1 (统计量). 设 $(X_1, \dots, X_n)$ 为样本, 若 $T = T(X_1, \dots, X_n)$ 是可测的样本函数, 且其函数形式不含未知参数, 则称 T 为**统计量**。统计量的分布称为**抽样分布**。

结构与证明

例如, $\bar{X} - \mu$ 在 μ 未知时不是统计量; 它的分布通常还含有 σ , 也不自动是枢轴量。标准化后若分布不含未知参数, 例如正态总体中

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1),$$

才成为可用于区间估计的枢轴量 (见第六章)。

5.3.2 样本均值及其分布

定义 5.3.2 (样本均值). $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

若总体 $E[X] = \mu$, $\text{Var}(X) = \sigma^2$, 则 $E[\bar{X}] = \mu$, $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ 。

若总体为正态分布, 则 $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ (精确结论); 一般 i.i.d. 总体在 $0 < \sigma^2 < \infty$ 时, 由中心极限定理有

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1),$$

故大样本下可作正态近似。

5.3.3 样本方差与样本标准差

定义 5.3.3 (样本方差). 当 $n \geq 2$ 时, 定义

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad S = \sqrt{S^2}.$$

计算与建模

为什么分母是 $n-1$ 而非 n ？若 $E(X^2) < \infty$ ，由恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

取期望得 $E[\sum (X_i - \bar{X})^2] = (n-1)\sigma^2$ ，因此 $E(S^2) = \sigma^2$ 。几何上，中心化后的数据向量位于与全 1 向量正交的 $n-1$ 维子空间中； $n-1$ 正是剩余自由度。

5.3.4 样本矩及其函数

定义 5.3.4 (样本原点矩与样本中心矩). 对正整数 k ，定义

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k.$$

其中 $A_1 = \bar{X}$ ，且 $B_2 = \frac{n-1}{n} S^2$ 。样本矩的函数仍是统计量，并将在第六章用于矩估计。

样本矩的相合性

条件 (X_i) 为 i.i.d. 样本，且 $E|X|^k < \infty$ 。

结论 $A_k \xrightarrow{\text{a.s.}} E(X^k)$ 。若参数可由所用总体矩唯一识别，且反解映射在真值处连续，则相应矩估计相合。

用途 为“用样本矩替换总体矩”提供大数定律依据。

边界 所需总体矩不存在或矩不能识别参数时，不能机械使用矩法。

例 5.3.1 (样本矩的直接计算). 观测值为 1, 2, 2, 5。则

$$A_1 = \bar{x} = \frac{10}{4} = 2.5, \quad A_2 = \frac{1^2 + 2^2 + 2^2 + 5^2}{4} = 8.5,$$

从而

$$B_2 = A_2 - A_1^2 = 8.5 - 6.25 = 2.25, \quad s^2 = \frac{n}{n-1} B_2 = 3.$$

这个例子也说明： B_2 与无偏样本方差 S^2 的分母不同。

5.3.5 次序统计量及其分布

定义 5.3.5 (次序统计量). 将样本 $X_1, \dots, X_n$ 从小到大排列, 得到 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$, 称为次序统计量。

定理 5.3.1 (第 k 个次序统计量的密度函数)。设总体为连续型, 密度为 $f_X(x)$, 分布函数为 $F_X(x)$, 则

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F_X(x)]^{k-1} [1 - F_X(x)]^{n-k} f_X(x).$$

微分元与多项分布推导. 设 $\Delta x > 0$ 很小. 事件 $x \leq X_{(k)} < x + \Delta x$ 近似要求: 恰有 $k-1$ 个样本落在 $(-\infty, x)$, 恰有 1 个样本落在 $[x, x + \Delta x)$, 其余 $n-k$ 个样本落在 $(x + \Delta x, \infty)$. 由多项分布,

$$P(x \leq X_{(k)} < x + \Delta x) = \frac{n!}{(k-1)! 1! (n-k)!} [F_X(x)]^{k-1} \times (F_X(x + \Delta x) - F_X(x)) [1 - F_X(x + \Delta x)]^{n-k} + o(\Delta x).$$

连续密度下

$$F_X(x + \Delta x) - F_X(x) = f_X(x) \Delta x + o(\Delta x), \quad 1 - F_X(x + \Delta x) = 1 - F_X(x) + o(1).$$

两边除以 Δx 并令 $\Delta x \downarrow 0$, 即得

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F_X(x)]^{k-1} [1 - F_X(x)]^{n-k} f_X(x).$$

□

直觉与动机

发生学推导 (微元法): 要让 $X_{(k)}$ 落在 x 处的小区间 $[x, x + dx)$ 内, 需要:

- n 个样本中, 恰好有 $k-1$ 个落在 $(-\infty, x)$ (概率 $F_X(x)$);
- 恰好有 1 个落在 $[x, x + dx)$ (概率 $f_X(x) dx$);
- 剩下 $n-k$ 个落在 $(x + dx, +\infty)$ (一阶近似概率 $1 - F_X(x)$).

按多项分布乘组合数 $\frac{n!}{(k-1)! 1! (n-k)!}$, 即得上述密度。

用这种物理图景推导, 比单纯死记公式更稳。

5.3.6 五数概括与箱线图

定义 5.3.6 (样本分位数与样本中位数). 对 $0 < p < 1$, 本书采用经验分位数约定

$$\hat{q}_p = \inf\{x : \hat{F}_n(x) \geq p\} = X_{(\lceil np \rceil)}.$$

$\hat{q}_{1/2}$ 称为样本中位数。软件对偶数样本的插值约定可能不同, 计算题必须先声明所用约定; 若题目指定“中间两数平均”, 则按题意执行。

五数概括由最小值、下四分位数 Q_1 、中位数 Q_2 、上四分位数 Q_3 和最大值组成。令 $IQR = Q_3 - Q_1$ 。Tukey 箱线图的内围栏为

$$Q_1 - 1.5IQR, \quad Q_3 + 1.5IQR.$$

“须”延伸到围栏内最远的观测值, 围栏外观测单独标记为潜在异常值; 因此箱线图的须不必等于样本最小值和最大值。

例 5.3.2 (五数概括与 Tukey 箱线图). 数据按升序为 1, 2, 3, 4, 5, 6, 7, 20。采用“上下半组中位数”为四分位数的约定,

$$Q_1 = 2.5, \quad Q_2 = 4.5, \quad Q_3 = 6.5, \quad IQR = 4.$$

内围栏为 $[-3.5, 12.5]$, 故下须为 1、上须为 7, 而 20 单独标记为潜在异常值。这也说明“五数概括中的最大值”与“箱线图的上须”不是同一概念。

5.4 三大抽样分布

直觉与动机

三大抽样分布不是彼此孤立的查表公式。它们都由独立标准正态变量生成, 并把正态总体中的未知参数消去, 成为第六章区间估计和第七章假设检验的枢轴量。

计算与建模

三大抽样分布生成机制

分布	生成方式	主要用途
$\chi^2(n)$	n 个独立标准正态平方和	方差推断、平方和分解
$t(n)$	标准正态除以独立 $\chi^2(n)/n$ 的平方根	方差未知时的均值推断
$F(m, n)$	两个独立 χ^2 除以自由度后的比	方差比较、ANOVA、回归显著性检验

三大抽样分布生成树

从相互独立的标准正态变量出发：

$$\begin{aligned}
 Z_1, \dots, Z_\nu &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \implies V = \sum_{i=1}^{\nu} Z_i^2 \sim \chi^2(\nu), \\
 Z \perp V &\implies \frac{Z}{\sqrt{V/\nu}} \sim t(\nu), \\
 U \sim \chi^2(m), V \sim \chi^2(n), U \perp V &\implies \frac{U/m}{V/n} \sim F(m, n).
 \end{aligned}$$

正态样本的均值方向给出 Z ，中心化后的 $n-1$ 维残差方向给出 V 。

5.4.1 χ^2 分布（卡方分布）

定义 5.4.1 (χ^2 分布). 若 $Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$ ，则 $\chi^2 = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ 。密度函数： $f(x) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}$ ($x > 0$)。 $E[\chi^2(n)] = n$ ， $\text{Var}[\chi^2(n)] = 2n$ 。

结构与证明

几何视角： $\chi^2(n)$ 是 n 维欧式空间中标准正态随机向量 $Z = (Z_1, \dots, Z_n)^T$ 的模长的平方 $\|Z\|^2$ 。自由度 n 就是空间的维数。

正态样本基本定理

条件 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ ， $n \geq 2$ 。

结论

1. $\bar{X} \sim N(\mu, \sigma^2/n)$;
2. $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$;
3. $\bar{X}$ 与 S^2 相互独立。

用途 构造未知均值、未知方差以及两正态总体参数的精确枢轴量。

边界 均值与样本方差的独立性是正态总体的特殊性质；非正态总体不能直接照搬。

正交矩阵变换证明. 令

$$Z = \frac{1}{\sigma} \begin{pmatrix} X_1 - \mu \\ \vdots \\ X_n - \mu \end{pmatrix}.$$

则 $Z \sim N_n(0, I_n)$ 。取正交矩阵 Q ，其第一行为

$$q_1^T = \frac{1}{\sqrt{n}}(1, 1, \dots, 1).$$

令 $Y = QZ$ 。由于标准多元正态分布在正交变换下不变，

$$Y \sim N_n(0, I_n),$$

所以 $Y_1, \dots, Y_n$ 相互独立且均服从 $N(0, 1)$ 。第一坐标为

$$Y_1 = q_1^T Z = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma},$$

故 $\bar{X} \sim N(\mu, \sigma^2/n)$ 。

另一方面，正交变换保持欧氏范数：

$$\begin{aligned} \sum_{i=1}^n Z_i^2 &= \sum_{i=1}^n Y_i^2, \\ \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 &= \sum_{i=1}^n Z_i^2 - Y_1^2 = \sum_{i=2}^n Y_i^2. \end{aligned}$$

因此

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 = \sum_{i=2}^n Y_i^2 \sim \chi^2(n-1).$$

最后， $\bar{X}$ 只依赖 Y_1 ，而 S^2 只依赖 $Y_2, \dots, Y_n$ 。标准正态坐标相互独立，所以 $\bar{X}$ 与 S^2 相互独立。□

结构与证明

正交变换证明思路 (Cochran 定理思想)：构造正交矩阵 Q ，其第一行为 $\frac{1}{\sqrt{n}}(1, 1, \dots, 1)$ ，令 $Y = QZ$ ，其中 $Z = ((X_1 - \mu)/\sigma, \dots, (X_n - \mu)/\sigma)^T$ 。

由于正交变换保持标准正态性和向量模长，可以发现：

- $Y_1 = \sqrt{n}(\bar{X} - \mu)/\sigma$ 捕获均值信息；

5.4 三大抽样分布

- $Y_2^2 + \dots + Y_n^2 = (n-1)S^2/\sigma^2$ 捕获剩余 $n-1$ 维波动;

Y_1 与 $(Y_2, \dots, Y_n)$ 独立, 故 $\bar{X}$ 与 S^2 独立, 自由度为 $n-1$ (损失了一个维度给 Y_1)。

能手推出这个结论, 就能把线性代数与概率论真正连起来。

5.4.2 F 分布

定义 5.4.2 (F 分布). 设 $U \sim \chi^2(m)$, $V \sim \chi^2(n)$, 且 U, V 独立, 则 $F = \frac{U/m}{V/n} \sim F(m, n)$ (m, n 为自由度)。

结构与证明

F 分布是两个独立标准化卡方变量的比。若两组正态样本相互独立, 则

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

此外, 若 $F \sim F(m, n)$, 则 $1/F \sim F(n, m)$ 。这些性质用于两方差比较、ANOVA 和回归显著性检验。

5.4.3 t 分布

定义 5.4.3 (t 分布 (学生氏分布)). 设 $X \sim N(0, 1)$, $V \sim \chi^2(n)$, 且 X, V 独立, 则 $t = \frac{X}{\sqrt{V/n}} \sim t(n)$ 。

结构与证明

t 分布关于 0 对称、尾部比标准正态更厚, 当 $n \rightarrow \infty$ 时趋于标准正态分布。用于处理“方差未知”时的均值推断——这是 t 分布被发明的核心动机。对正态样本, 正态样本基本定理立即给出

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

例 5.4.1 (从正态样本生成三个枢轴量). 设 $X_1, \dots, X_{10} \stackrel{\text{i.i.d.}}{\sim} N(3, 4)$ 。不需要知道具体观测值, 就有

$$\bar{X} \sim N\left(3, \frac{4}{10}\right), \quad \frac{9S^2}{4} \sim \chi^2(9), \quad \frac{\bar{X} - 3}{S/\sqrt{10}} \sim t(9).$$

若另有与其独立的样本 $Y_1, \dots, Y_{12} \sim N(\mu_Y, \sigma_Y^2)$, 则

$$\frac{S_X^2/4}{S_Y^2/\sigma_Y^2} \sim F(9, 11).$$

做题时先辨认“标准正态”“标准化卡方”及其独立性, 再选择 t 或 F , 比直接背结论可靠。

5.5 充分统计量

直觉与动机

原始样本常有许多排列和细节, 但似然中关于参数的部分可能只依赖一个低维函数。充分统计量回答: 保留这个函数以后, 是否还丢失了关于参数的信息?

5.5.1 充分性的概念

定义 5.5.1 (充分统计量). 设样本分布族为 $\{P_\theta : \theta \in \Theta\}$, $T = T(X_1, \dots, X_n)$ 为统计量。若在给定 $T = t$ 后, 样本的条件分布不依赖 θ , 则称 T 为关于参数 θ 的充分统计量。

直觉与动机

充分性不是说原始数据的其余部分“没有任何用途”, 而是说: 在指定模型族内, 给定 T 后其余随机性不再携带关于 θ 的信息。模型检查、异常诊断等任务仍可能需要原始数据。

5.5.2 因子分解定理 (Neyman-Fisher 定理)

Neyman-Fisher 因子分解定理

条件 分布族关于同一控制测度有联合密度或分布列 $f_\theta(x)$ 。

结论 $T(X)$ 关于 θ 充分, 当且仅当存在非负函数 g_θ, h , 使

$$f_\theta(x) = g_\theta(T(x))h(x),$$

其中 h 与 θ 无关。

用途 把条件分布判定转化为联合密度或分布列的代数分解。

边界 必须保留支撑集中的参数限制; 不能先删去含参数的指示函数再分解。

结构与证明

解读：

- $g_\theta(T(x))$ ：参数通过统计量 $T(x)$ 与样本发生联系；
- $h(x)$ ：不含参数，但仍可能描述样本排列和模型诊断所需的信息。

解题顺序：写全联合密度及支撑集，收集含参数的项，再识别它们通过哪个样本函数进入。

经典例子（泊松分布）：

$$\prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \underbrace{\lambda^{\sum x_i} e^{-n\lambda}}_{g(T(x), \lambda)} \cdot \underbrace{\frac{1}{\prod x_i!}}_{h(x)},$$


故 $T = \sum X_i$ 是 λ 的充分统计量。

条件与易错点

“指数族”本身不自动推出完备性。常用的充分条件是：正则、满秩指数族的自然参数空间包含一个非空开集，此时相应自然统计量可得完备性。具体题目必须核对参数空间、统计量和分布族；完备性的正式使用放在第六章 Lehmann–Scheffé 定理处。

5.6 备考指导

知识关系图



方法选择表

目标	首选对象	先检查
总体矩的样本替代	A_k, B_k	所需总体矩是否存在
最小值、最大值、分位数	次序统计量	连续/离散及分位数约定
正态总体方差相关量	χ^2	正态性与自由度
正态均值且方差未知	t	$\bar{X} \perp S^2$ 依赖正态性
两个独立方差或均方之比	F	两个卡方量是否独立
判断统计量是否充分	因子分解定理 ⁶⁵	联合密度和完整支撑集

条件与易错点

- 随机样本 (X_i) 、观测值 (x_i) 、统计量 $T(X)$ 和统计值 $T(x)$ 是四个不同对象。
- S^2 的分母为 $n-1$ ； B_2 的分母为 n 。
- $\bar{X}$ 与 S^2 独立不是一般 i.i.d. 样本的结论，而是正态样本的特殊性质。
- t 、 F 的构造必须核对分子分母独立；只看边缘分布不够。
- 箱线图的须通常不是最小值和最大值；不同软件的四分位数约定可能不同。
- 指数族并不自动给出完备充分统计量。

432 高频题型

1. 由正态样本基本定理识别统计量的精确分布和自由度。
2. 求极值、次序统计量或样本分位数的分布。
3. 写联合密度并用因子分解定理找充分统计量。
4. 区分样本二阶中心矩与无偏样本方差。

分层练习与简解

A. 直接计算：若 $X_1, \dots, X_6 \sim N(\mu, 9)$ ，写出 $\sqrt{6}(\bar{X} - \mu)/3$ 与 $5S^2/9$ 的分布。

简解：分别为 $N(0, 1)$ 与 $\chi^2(5)$ ；二者独立。

B. 综合辨析：若 $X_1, \dots, X_n \sim U(0, \theta)$ ，证明 $X_{(n)}$ 对 θ 充分。

简解：联合密度为 $\theta^{-n} \mathbf{1}_{\{0 \leq x_{(1)}, x_{(n)} \leq \theta\}}$ 。其中含参数部分只通过 $x_{(n)}$ 进入，按因子分解定理得证。

C. 结构证明：设正态样本容量为 n ，说明为何残差平方和的自由度是 $n-1$ 。

简解：中心化矩阵 $I_n - \mathbf{1}\mathbf{1}^T/n$ 是秩为 $n-1$ 的正交投影；标准正态向量投影后的平方范数服从 $\chi^2(n-1)$ 。

第四部分

统计推断与模型优化

第 6 章

参数估计

直觉与动机

参数估计要依次回答四个问题：怎样构造估计量，怎样评价它，怎样改进它，以及怎样用区间表达抽样误差。点估计给出一个随机中心，区间估计进一步量化不确定性。

本章路线与层次



数三主线是矩估计、MLE、评价标准与正态总体区间；432 主线进一步包括充分完备性、UMVUE、两总体区间和样本量。EM 与贝叶斯决策作为扩展阅读，不打断频率学推断链。

6.1 估计问题与评价标准 (B)

6.1.1 点估计及无偏性

定义 6.1.1 (估计量与估计值). 用样本 $(X_1, \dots, X_n)$ 构造一个统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, 作为未知参数 θ 的估计, 称 $\hat{\theta}$ 为 θ 的**估计量**; 代入样本观测值得到的数值称为**估计值**。

定义 6.1.2 (无偏性). 若对所有 $\theta \in \Theta$ 都有 $E_{\theta}(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为 θ 的**无偏估计量**。

结构与证明

无偏性控制的是重复抽样下的系统偏差, 不保证一次估计接近真值; 还必须结合方差或 MSE 评价。

6.1.2 有效性

定义 6.1.3 (有效性). 对同一参数的两个无偏估计量, 若一个估计量的方差对所有 θ 都不大于另一个, 则称前者至少同样有效。若某无偏估计量在所有参数值下都比任意其他无偏估计量方差不大, 则它是一**致最小方差无偏估计 (UMVUE)**。若某无偏估计量达到 Cramér-Rao 下界, 也常称为**有效估计量**。

6.1.3 均方误差与偏差-方差分解

定义 6.1.4 (均方误差).

$$\text{MSE}_{\theta}(\hat{\theta}) = E_{\theta}(\hat{\theta} - \theta)^2 = \text{Var}_{\theta}(\hat{\theta}) + \{E_{\theta}(\hat{\theta}) - \theta\}^2.$$

不同估计量的偏差与方差可能互有优劣, 因此不能只凭“无偏”判断整体好坏。

6.1.4 相合性与渐近观点

定义 6.1.5 (相合性). 若对每个 $\theta \in \Theta$, $\hat{\theta}_n \xrightarrow{P_{\theta}} \theta$, 则称 $(\hat{\theta}_n)$ 为 θ 的**相合估计量**。

无偏性是有限样本性质, 相合性是样本量趋于无穷时的性质; 二者互不推出。

6.2 矩估计 (A)

6.2.1 矩法估计

定义 6.2.1 (矩估计 (替换原理)). 设参数 $\theta = (\theta_1, \dots, \theta_r)$, 选择 r 个存在的总体矩 $m_k(\theta) = E_\theta(X^k)$, 用样本矩 $A_k = n^{-1} \sum X_i^k$ 替换并解方程 $A_k = m_k(\theta)$, 所得解称为矩估计量。

结构与证明

矩法计算直接、通常易于证明相合, 但不保证无偏或最有效。在某些模型中矩估计恰好也是 MLE 或充分统计量的函数, 因此不能笼统说它 “一定没有充分利用信息”。

6.2.2 相合性

矩估计相合性的常用充分条件

条件 所需总体矩有限; 矩方程在真参数处可识别; 由矩到参数的反解映射连续。

结论 由强大数定律和连续映射定理, 相应矩估计量依概率收敛于真参数。

用途 快速检查矩估计是否具有大样本合理性。

边界 矩不存在、多个参数给出相同矩, 或反解在真值处不连续时, 结论可能失效。

例 6.2.1 (指数分布的矩估计). 约定 $X \sim \text{Exp}(\lambda)$ 中 $\lambda > 0$ 为率参数, 则 $E(X) = 1/\lambda$ 。令 $\bar{X} = 1/\lambda$, 得到

$$\hat{\lambda}_{\text{MM}} = \frac{1}{\bar{X}}.$$

因 $E|X| < \infty$ 、 $\lambda \mapsto 1/\lambda$ 可识别且反解 $x \mapsto 1/x$ 在 $1/\lambda > 0$ 处连续, 故 $\hat{\lambda}_{\text{MM}} \xrightarrow{P} \lambda$ 。

6.3 最大似然估计 (A)

6.3.1 最大似然估计 (MLE)

直觉与动机

似然把观测数据固定，把参数看作可变输入；MLE 选择使当前数据的联合密度或分布列最大的参数值。连续型情形比较的是密度，不是“该样本点发生的概率”。

定义 6.3.1 (似然函数与 MLE). 给定 i.i.d. 样本观测值 $x = (x_1, \dots, x_n)$ ，定义

$$L(\theta; x) = \prod_{i=1}^n f_{\theta}(x_i), \quad \ell(\theta; x) = \log L(\theta; x).$$

任一使似然达到上确界的参数值 $\hat{\theta}(x)$ 称为最大似然估计值；抽样前相应的随机函数 $\hat{\theta}(X)$ 称为最大似然估计量。若极大值不唯一，应说明所取版本。

结构与证明

信息论/KL 散度观点：设真实分布为 P_* ，密度为 $p_*(x)$ ；模型族为 P_{θ} ，密度为 $p_{\theta}(x)$ 。则

$$\begin{aligned} \text{KL}(P_* \parallel P_{\theta}) &= \int p_*(x) \log \frac{p_*(x)}{p_{\theta}(x)} \, dx \\ &= \int p_*(x) \log p_*(x) \, dx - \int p_*(x) \log p_{\theta}(x) \, dx. \end{aligned}$$

第一项与 θ 无关，所以

$$\arg \min_{\theta} \text{KL}(P_* \parallel P_{\theta}) = \arg \max_{\theta} E_*[\log p_{\theta}(X)].$$

真实期望不可直接计算时，用经验分布 $\hat{P}_n = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}$ 代替 P_* ，便得到

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x_i).$$

在大数定律与可识别性等条件下，经验平均对数似然逼近期望对数似然；因此 KL 投影是解释 MLE 相合性的渐近观点，而不是有限样本下的额外等式。

支撑依赖参数时的检查

- 支撑集不依赖参数且极值位于参数空间内部时，可先求驻点，再核对边界与最大性；
- 遇到均匀分布 $U(0, \theta)$ 这类支撑依赖参数的问题，不能机械求导。似然函数含有指示函数 $I(x_{(n)} \leq \theta)$ ，是阶梯函数。通过画图 and 单调性得出 $\hat{\theta}_{\text{MLE}} = X_{(n)}$ （最大次序统计量）。这类题的关键是先看参数是否进入支撑集。

定理 6.3.1 (MLE 的不变性)。若 $\hat{\theta}$ 是 θ 的 MLE，则在以剖面似然定义 $g(\theta)$ 的似然时， $g(\hat{\theta})$ 是 $g(\theta)$ 的一个 MLE。非一一变换或 MLE 不唯一时，像集中的极大值也可能不唯一。

例 6.3.1 (支撑依赖参数：均匀分布)。设 $X_1, \dots, X_n \sim U(0, \theta)$, $\theta > 0$ 。联合似然为

$$L(\theta; x) = \theta^{-n} \mathbf{1}_{\{0 \leq x_{(1)}, x_{(n)} \leq \theta\}}.$$

可行域是 $\theta \geq x_{(n)}$ ，且 θ^{-n} 在该区间递减，故

$$\hat{\theta}_{\text{MLE}} = X_{(n)}.$$

这里对数似然在可行域内部没有给出所需驻点；先写支撑集是计算链的关键。

6.3.2 扩展阅读：EM 算法

直觉与动机

动机：面对“残缺数据”或有“隐变量”时，似然函数含积分或求和，连求导都无法实现，怎么办？

令 X 为观测数据、 Z 为潜变量。给定当前值 $\theta^{(t)}$ ，E 步计算

$$Q(\theta \mid \theta^{(t)}) = E_{\theta^{(t)}}[\log p(X, Z \mid \theta) \mid X],$$

M 步取

$$\theta^{(t+1)} \in \arg \max_{\theta} Q(\theta \mid \theta^{(t)}).$$

在通常条件下，观测数据对数似然沿迭代不减；但算法可能停在局部极大点或鞍点，参数序列的全局收敛不能仅由单调性保证。

结构与证明

E 步求的是完全数据对数似然的条件期望，不等同于简单地用 $E(Z | X)$ 填补缺失值；只有某些特殊模型才可作这种直观解释。

6.3.3 MLE 的渐近正态性

MLE 的渐近正态性 (标量参数)

条件 模型可识别，真参数为参数空间内点，支撑集和微分交换满足常用正则条件，且单个观测 Fisher 信息 $0 < I_1(\theta) < \infty$ 。

结论

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{d} N(0, I_1(\theta)^{-1}).$$

用途 构造 Wald 型大样本区间，并说明正则模型中 MLE 的渐近效率。

边界 支撑依赖参数、边界参数、不可识别模型等非正则情形不能直接套用。

结构与证明

MLE 不必在有限样本下无偏或达到 CRLB；上述结论仅说明正则模型中的渐近正态与渐近效率。

6.4 估计量的改进 (C)

直觉与动机

在无偏估计类中，可用条件期望把任意估计量改造成充分统计量的函数，再用完备性保证唯一性；Cramér-Rao 不等式则从信息量给出方差下界。

6.4.1 一致最小方差无偏估计

定义 6.4.1 (UMVUE). 若无偏估计量 $\hat{\theta}^*$ 满足：对任意其他无偏估计量 $\hat{\theta}$ ，均有 $\text{Var}(\hat{\theta}^*) \leq \text{Var}(\hat{\theta})$ (对所有 θ)，则称 $\hat{\theta}^*$ 为 θ 的一致最小方差无偏估计 (UMVUE)。

6.4.2 充分性原则 (Rao-Blackwell 定理)

Rao-Blackwell 定理

条件 $\delta(X)$ 是 $g(\theta)$ 的无偏估计且 $E_\theta \delta^2 < \infty$, T 对 θ 充分。

结论 令 $\delta^*(T) = E_\theta[\delta(X) | T]$, 则 δ^* 仍无偏, 并且 $\text{Var}_\theta(\delta^*) \leq \text{Var}_\theta(\delta)$; 等号当且仅当条件方差几乎处处为零。

用途 把任意无偏估计改进为充分统计量的函数。

边界 若原估计量无二阶矩, 方差比较没有意义; 仅有充分性还不能自动保证所得估计是唯一 UMVUE。

条件期望“提纯”公式. 把原估计量记为 $\delta(X_1, \dots, X_n)$ 。Rao-Blackwell 化后的估计量为

$$\tilde{\delta}(T) = E_\theta[\delta(X_1, \dots, X_n) | T].$$

离散情形下, 对 $T = t$,

$$\tilde{\delta}(t) = \sum_x \delta(x) P_\theta(X = x | T = t);$$

连续情形下,

$$\tilde{\delta}(t) = \int \delta(x) f_\theta(x | T = t) dx.$$

若 T 对 θ 充分, 则条件分布 $P_\theta(X \in \cdot | T = t)$ 不依赖 θ , 所以 $\tilde{\delta}(T)$ 是只由统计量 T 决定的合法估计量。

无偏性由全期望公式给出:

$$E_\theta[\tilde{\delta}(T)] = E_\theta[E_\theta(\delta | T)] = E_\theta[\delta] = \theta.$$

方差由条件方差分解给出:

$$\begin{aligned} \text{Var}_\theta(\delta) &= \text{Var}_\theta(E_\theta[\delta | T]) + E_\theta[\text{Var}_\theta(\delta | T)] \\ &\geq \text{Var}_\theta(E_\theta[\delta | T]) = \text{Var}_\theta(\tilde{\delta}). \end{aligned}$$

因此, 对充分统计量取条件期望会保留无偏性并降低方差。□

结构与证明

条件方差分解说明减少量恰为 $E_\theta[\text{Var}_\theta(\delta | T)]$ 。因此 Rao-Blackwell 化是 L^2 中向由 T 生成的子空间作投影, 而不是经验性的“平滑”。

Lehmann–Scheffé 定理

条件 T 对模型族完备且充分，且 $\phi(T)$ 是 $g(\theta)$ 的无偏估计。

结论 $\phi(T)$ 是 $g(\theta)$ 的唯一 UMVUE (在几乎处处相等意义下)。

用途 将“寻找 UMVUE”化为“寻找完备充分统计量的无偏函数”。

边界 完备性必须单独证明或引用满足条件的定理；指数族并不无条件自动完备。

结构与证明

完备性 (Completeness) 的定义：若对任意函数 h ， $E_\theta[h(T)] = 0$ ($\forall \theta$) 能推出 $h(T) \equiv 0$ 几乎处处，则称 T 是**完备的**。

UMVUE 四步路线：

1. 找充分统计量 T ，常用因子分解定理；
2. 判断 T 是否完备，并核对所引用指数族定理的参数空间条件；
3. 先构造某个 $g(\theta)$ 的无偏估计量 $\delta(X)$ ；
4. 计算 $E[\delta(X) | T]$ ，得到 T 的函数，再用 Lehmann-Scheffé 定理收尾。

也就是

$$\delta(X) \longrightarrow E[\delta(X) | T] \longrightarrow \text{UMVUE}.$$

例 6.4.1 (Rao–Blackwell 与 Lehmann–Scheffé 的完整链). 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$ ，目标是估计 $g(\lambda) = e^{-\lambda}$ 。 $\delta = \mathbf{1}_{\{X_1=0\}}$ 满足 $E_\lambda \delta = e^{-\lambda}$ 。又 $T = \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda)$ 是完备充分统计量，且给定 $T = t$ ， $X_1 | T = t \sim \text{Binomial}(t, 1/n)$ 。故

$$E(\delta | T = t) = P(X_1 = 0 | T = t) = \left(1 - \frac{1}{n}\right)^t.$$

因此

$$\hat{g}(T) = \left(1 - \frac{1}{n}\right)^T$$

是 $e^{-\lambda}$ 的唯一 UMVUE。

6.4.3 克拉默-拉奥不等式 (CRLB)

直觉与动机

动机： 方差能小到什么程度？能否给出理论下界？

定义 6.4.2 (得分、观测信息与 Fisher 信息). 设单个观测的对数密度为 $\ell_1(\theta; X)$, 样本对数似然为 ℓ_n . 定义

$$U_n(\theta) = \frac{\partial \ell_n(\theta)}{\partial \theta}, \quad J_n(\theta) = -\frac{\partial^2 \ell_n(\theta)}{\partial \theta^2}, \quad I_n(\theta) = E_\theta[J_n(\theta)].$$

在可交换微分与积分等正则条件下, $E_\theta U_n = 0$ 且

$$I_n(\theta) = E_\theta[U_n(\theta)^2] = nI_1(\theta).$$

结构与证明

观测信息 J_n 随样本变化, Fisher 信息 I_n 是其期望。似然峰附近曲率越大, 参数局部可辨识程度通常越高, 但两个对象不能混写。

Cramér–Rao 不等式

条件 标量参数模型满足常用正则条件, $0 < I_n(\theta) < \infty$, 且 δ 是可微函数 $g(\theta)$ 的无偏估计并有有限方差。

结论

$$\text{Var}_\theta(\delta) \geq \frac{[g'(\theta)]^2}{I_n(\theta)} = \frac{[g'(\theta)]^2}{nI_1(\theta)}.$$

用途 给所有正则无偏估计的方差提供统一下界；达到下界者必为 UMVUE。

边界 支撑依赖参数或正则条件失败时, 该形式可能不适用；未达到下界不代表估计量不是 UMVUE。

6.5 贝叶斯估计 (A, 扩展)

直觉与动机

- **频率学派：** 参数 θ 是客观存在的未知常数；
- **贝叶斯建模：** 用先验分布描述观测数据前关于 θ 的不确定性, 再由似然更新为后验分布。

6.5.1 统计推断的基础

贝叶斯推断框架：

- **先验分布** $\pi(\theta)$ ：观测数据前的信息、经验或建模约束；
- **似然** $f(x|\theta)$ ：数据给出的现实证据；
- **后验分布** $\pi(\theta|x)$ ：结合先验与数据更新后的认知。

6.5.2 贝叶斯公式的密度函数形式

定理 6.5.1 (贝叶斯公式 (密度形式))。

$$\pi(\theta|x) = \frac{f(x|\theta) \pi(\theta)}{\int f(x|\theta) \pi(\theta) d\theta} \propto f(x|\theta) \cdot \pi(\theta).$$

6.5.3 贝叶斯估计

给定损失函数 $L(\theta, a)$ ，观测 x 后选择动作 a 的后验风险为

$$\rho(a | x) = E[L(\theta, a) | x].$$

使后验风险最小的动作称为贝叶斯估计。常见对应关系为

损失	贝叶斯估计
$(a - \theta)^2$	$E(\theta x)$
$ a - \theta $	后验中位数
0-1 损失 (离散参数)	后验众数 MAP

连续参数下通常用小邻域的 0-1 损失极限解释 MAP，不能只凭“求出后验”就称已完成估计决策。

6.5.4 共轭先验分布

定义 6.5.1 (共轭先验). 若先验分布与后验分布属于同一分布族，则称该先验为共轭先验。

例 6.5.1. 常见共轭先验对：

- 二项似然 $\leftrightarrow$ Beta 先验 (后验也是 Beta)；
- 泊松似然 $\leftrightarrow$ Gamma 先验；

6.6 区间估计与样本量 (D)

- 正态似然 (均值未知) $\leftrightarrow$ 正态先验 (后验也是正态)。

共轭先验保证了贝叶斯更新在代数结构上的**封闭性 (Closure)**。

例 6.5.2 (Beta-Binomial 后验与平方损失估计). 先验 $p \sim \text{Beta}(2, 2)$ 。进行 $n = 10$ 次 Bernoulli 试验, 观察到 $x = 7$ 次成功, 则

$$p \mid x \sim \text{Beta}(2 + 7, 2 + 3) = \text{Beta}(9, 5).$$

平方损失下的贝叶斯估计为后验均值

$$\hat{p}_B = \frac{9}{9 + 5} = \frac{9}{14}.$$

若改用其他损失函数, 最优动作一般会改变。

6.6 区间估计与样本量 (D)

直觉与动机

点估计只给出中心位置; 置信区间用随机端点表达抽样误差, 并保证重复抽样下的覆盖率。本节统一采用“枢轴量分布确定区间概率, 再反解参数”的计算链。

6.6.1 区间估计的概念

定义 6.6.1 (置信区间). 若随机区间 $[L(X), U(X)]$ 满足

$$\inf_{\theta \in \Theta} P_{\theta}\{L(X) \leq \theta \leq U(X)\} \geq 1 - \alpha,$$

则称其为置信水平至少为 $1 - \alpha$ 的置信区间; 若对每个 θ 都取等号, 则称为精确置信区间。频率学解释中参数固定、区间随机, $1 - \alpha$ 描述同一构造方法在重复抽样中的长期覆盖率。

条件与易错点

本书统一使用**上侧临界值**: z_{γ} 满足 $P(Z > z_{\gamma}) = \gamma$; $t_{\gamma, \nu}$ 、 $\chi_{\gamma, \nu}^2$ 、 $F_{\gamma; \nu_1, \nu_2}$ 同理。若另需一般下侧 p 分位数, 则专门记为 q_p 。查表时必须核对表头, 不能只看下标照抄。

6.6.2 枢轴量法

定义 6.6.2 (枢轴量). 若 $G = G(X_1, \dots, X_n, \theta)$ 既含样本又含参数 θ , 但其分布不含任何未知参数, 则称 G 为枢轴量。

结构与证明

枢轴量的作用是消去未知参数, 使区间概率可由已知分布分位数确定; 它不是拓扑不变量, 也不要求统计量本身不含参数。

枢轴量法四步

1. 写明总体、独立性、正态性及已知/未知参数;
2. 选择分布不含未知量的枢轴量;
3. 用统一分位数写出概率为 $1 - \alpha$ 的不等式;
4. 反解目标参数, 并在观测后代入样本值。

6.6.3 单个正态总体参数的置信区间

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ 。

$$\begin{aligned} \sigma \text{ 已知: } \quad \mu &\in \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right], \\ \sigma \text{ 未知: } \quad \mu &\in \left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right], \\ \sigma^2 &\in \left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right]. \end{aligned}$$

在上侧临界值记法下, $\chi_{\alpha/2, n-1}^2$ 是较大的临界值, $\chi_{1-\alpha/2, n-1}^2$ 是较小的临界值, 所以上述端点次序正确。前两式的精确性以及第三式都依赖正态总体; 不能仅因样本量小就默认成立。

例 6.6.1 (单正态总体均值的完整区间计算). 正态样本容量 $n = 16$, 观测到 $\bar{x} = 10$ 、 $s = 2$ 。求 μ 的 95% 置信区间。因总体方差未知, 使用

$$T = \frac{\bar{X} - \mu}{S/\sqrt{16}} \sim t(15).$$

查上侧临界值 $t_{0.025, 15} = 2.131$, 于是

$$10 \pm 2.131 \frac{2}{4} = 10 \pm 1.0655,$$

故区间约为 $[8.935, 11.066]$ 。结论是该构造方法的长期覆盖率为 95%, 不是“ μ 有 95% 概率落在本次区间内”。

6.6.4 大样本置信区间

对 i.i.d. 总体, 若 $E(X^2) < \infty$, 则

$$\mu \in \left[\bar{X} - z_{\alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{S}{\sqrt{n}} \right]$$

是大样本近似区间。对 Bernoulli 比例 p , 记 $\hat{p} = X/n$, 在 $n\hat{p}$ 与 $n(1-\hat{p})$ 均不太小时, Wald 近似区间为

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

当样本小或比例接近 0, 1 时, Wald 区间可能越界且覆盖率差, 应改用 Wilson 或精确二项区间。

6.6.5 两个正态总体下的置信区间

设两正态样本相互独立, 记 $D = \bar{X} - \bar{Y}$ 。

1. 方差已知:

$$\mu_1 - \mu_2 \in D \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}.$$

2. 方差未知但假定相等: 令

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2},$$

则

$$\mu_1 - \mu_2 \in D \pm t_{\alpha/2, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}.$$

3. 方差未知且不假定相等 (Welch):

$$\mu_1 - \mu_2 \in D \pm t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}},$$

其中 Satterthwaite 自由度

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{(S_1^2/n_1)^2/(n_1 - 1) + (S_2^2/n_2)^2/(n_2 - 1)}.$$

若两组数据一一配对, 先构造 $D_i = X_i - Y_i$, 再对差值样本应用单样本 t 区间:

$$\mu_D \in \bar{D} \pm t_{\alpha/2, n-1} \frac{S_D}{\sqrt{n}}.$$

把配对数据误当作独立样本会丢失协方差信息。

对两个独立正态总体的方差比, 令 $\nu_i = n_i - 1$, 则

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[\frac{S_1^2/S_2^2}{F_{\alpha/2; \nu_1, \nu_2}}, \frac{S_1^2/S_2^2}{F_{1-\alpha/2; \nu_1, \nu_2}} \right].$$

这里同样按上侧临界值反解: 分母 $F_{\alpha/2}$ 较大, 形成区间下 endpoint。

例 6.6.2 (两独立正态总体均值差: 合并方差). 两独立样本满足 $n_1 = 10, n_2 = 12$, $\bar{x} - \bar{y} = 1.2$, $s_1^2 = 4, s_2^2 = 5$, 并接受等方差模型。则

$$s_p^2 = \frac{9 \times 4 + 11 \times 5}{20} = 4.55, \quad \text{SE} = \sqrt{4.55 \left(\frac{1}{10} + \frac{1}{12} \right)} \approx 0.913.$$

取 $t_{0.025, 20} = 2.086$, 95% 区间为

$$1.2 \pm 2.086(0.913) \approx [-0.705, 3.105].$$

区间包含 0, 与第七章相应双侧 pooled t 检验“不拒绝均值相等”一致。

6.6.6 样本量确定

若正态总体方差 σ^2 已知, 希望双侧 $1 - \alpha$ 区间的半宽不超过 d , 则

$$n \geq \left(\frac{z_{\alpha/2} \sigma}{d} \right)^2, \quad n = \left\lceil \left(\frac{z_{\alpha/2} \sigma}{d} \right)^2 \right\rceil.$$

估计比例时若已有先验估计 p_* , 可用 $n \geq z_{\alpha/2}^2 p_*(1 - p_*)/d^2$; 完全未知时取最保守的 $p_* = 1/2$ 。

例 6.6.3 (均值区间的样本量). 已知 $\sigma = 3$, 要求 95% 置信区间半宽不超过 1。则

$$n \geq (1.96 \times 3)^2 = 34.5744,$$

必须向上取整, 故至少抽取 35 个观测。

6.7 备考指导

知识关系图

$$\text{样本} \rightarrow \begin{cases} \text{矩方程} \rightarrow \hat{\theta}_{\text{MM}}, \\ \text{似然极大化} \rightarrow \hat{\theta}_{\text{MLE}}, \\ \text{先验} + \text{似然} + \text{损失} \rightarrow \hat{\theta}_B, \end{cases}$$

偏差、方差、MSE、相合性 $\rightarrow$ 评价, 充分 + 完备 + 条件期望 $\rightarrow$ UMVUE,

抽样分布 $\rightarrow$ 枢轴量 $\rightarrow$ 置信区间与样本量.

方法选择表

任务	首选方法	关键检查
快速构造点估计	矩估计	矩存在、可识别、连续反解
利用完整分布模型	MLE	支撑、边界、驻点最大性
比较估计量	MSE/方差/相合性	是否限定无偏类
寻找 UMVUE	充分统计量条件化	充分性与完备性
给方差下界	Cramér–Rao	正则条件与信息量口径
正态均值区间	Z 或 t	方差已知/未知
两独立均值区间	已知方差/pooled/Welch	独立性与方差假设
配对数据区间	差值的单样本 t	配对关系不可拆散

条件与易错点

- 无偏不等于误差小；相合也不保证有限样本无偏。
- 连续型 MLE 最大化的是密度，不是样本点发生的概率；支撑依赖参数时先写指示函数。
- $g(\hat{\theta}_{\text{MLE}})$ 有 MLE 不变性，但 $g(\hat{\theta}_{\text{UMVUE}})$ 一般不保持无偏，更不自动是 UMVUE。
- J_n 是随样本变化的观测信息， $I_n = E(J_n)$ 才是 Fisher 信息。
- 置信水平是区间构造方法的长期覆盖率，不是固定参数的后验概率。
- pooled t 需要等方差假设；方差不齐时使用 Welch，配对数据则先作差。
- 方差区间两端的卡方分位数顺序与直觉相反，必须从枢轴不等式反解。

432 高频题型

1. 矩估计与 MLE 的构造、偏差、MSE 和相合性。
2. 支撑依赖参数或边界参数的 MLE。
3. 因子分解、Rao–Blackwell 条件期望与 UMVUE。
4. 单总体、两总体、配对样本及方差比的置信区间。
5. 由允许误差和置信水平反求样本量。

分层练习与简解

A. 直接计算: $X_1, \dots, X_n \sim U(0, \theta)$, 求 $X_{(n)}$ 的期望, 并把 MLE 修正为无偏估计。

简解: $P(X_{(n)} \leq x) = (x/\theta)^n$, 故 $E[X_{(n)}] = n\theta/(n+1)$, 无偏修正为 $(n+1)X_{(n)}/n$ 。

B. 综合计算: 正态样本 $n = 25, \bar{x} = 12, s = 5$, 求 μ 的 95% 区间。

简解: 方差未知, 用 $t_{0.025, 24}$; 区间为 $12 \pm t_{0.025, 24}(5/5)$ 。

C. 结构证明: 证明若 T 完备充分, $\phi_1(T)$ 与 $\phi_2(T)$ 都无偏估计 $g(\theta)$, 则二者几乎处处相等。

简解: 对所有 θ , $E_\theta[\phi_1(T) - \phi_2(T)] = 0$; 由完备性得差几乎处处为零。

第 7 章

假设检验

直觉与动机

参数估计试图回答“参数是多少”，假设检验则回答“数据是否已经给出足够证据反对某个参数约束”。统一流程是：提出假设、选择统计量、确定零假设分布、控制检验水平、计算拒绝域或 p 值、解释结论。所有结论都必须同时说明适用条件和备择方向。

本章路线与层次

$H_0, H_1 \rightarrow T(X)$ 及其零假设分布 $\rightarrow$ 拒绝域或 p 值 $\rightarrow$ 统计结论,
 α 控制 $\rightarrow \pi(\theta)$ 功效 $\rightarrow$ 效应大小与样本量.

数三主线是两类错误、正态总体参数检验与置信区间反演；432 主线进一步包括 LRT、拟合优度、列联表与非参数检验。Wilks 定理等渐近理论放在扩展层。

7.1 假设检验的基本思想与概念

7.1.1 假设检验问题

定义 7.1.1 (原假设与备择假设). 将参数空间分为不交集合 Θ_0 与 Θ_1 : $H_0: \theta \in \Theta_0$ 称为原假设, $H_1: \theta \in \Theta_1$ 称为备择假设。原假设不一定是“无效果”，而是检验设计中需要控制误拒概率的参数集合。

条件与易错点

检验只能“拒绝 H_0 ”或“没有足够证据拒绝 H_0 ”。不拒绝不等于证明 H_0 为真，还可能源于效应很小、样本量不足或检验功效低。

7.1.2 假设检验的基本步骤

1. 建立假设 H_0 和 H_1 ;
2. 选取检验统计量 $T = T(X_1, \dots, X_n)$, 在 H_0 成立时分布已知;
3. 给定水平上界 α , 选择拒绝域 W , 使 $\sup_{\theta \in \Theta_0} P_\theta(T \in W) \leq \alpha$;
4. 由样本计算 T 的观测值, 若落在 W 内则拒绝 H_0 , 否则不拒绝。

定义 7.1.2 (检验水平、两类错误与势函数). 拒绝域为 W 时, 定义势函数

$$\pi(\theta) = P_\theta(X \in W).$$

第一类错误概率是 $\theta \in \Theta_0$ 时的 $\pi(\theta)$; 检验的大小为 $\sup_{\theta \in \Theta_0} \pi(\theta)$, 不超过给定上界 α 时称为水平 α 的检验。对 $\theta \in \Theta_1$, 第二类错误概率为 $\beta(\theta) = 1 - \pi(\theta)$, $\pi(\theta)$ 即该参数点处的功效。

结构与证明

在样本量固定时, 降低第一类错误通常会牺牲某些备择参数下的功效; 增加样本量、增大效应或降低噪声通常会提高功效。 α 是设计上界, 实际第一类错误概率在离散或复合原假设下可以严格小于它。

7.1.3 检验的 p 值

定义 7.1.3 (p 值). 给定检验统计量及“更不利于 H_0 ”的排序, p 值是: 在 H_0 下, 得到当前观测或更极端结果的尾概率。简单原假设下常见形式为

$$H_1 : \theta > \theta_0 : \quad p = P_{\theta_0}(T \geq t_{\text{obs}}),$$

$$H_1 : \theta < \theta_0 : \quad p = P_{\theta_0}(T \leq t_{\text{obs}}),$$

$$\text{零分布关于0 对称的双侧检验: } p = P_{\theta_0}(|T| \geq |t_{\text{obs}}|).$$

复合原假设常取各参数点尾概率的上确界, 或使用最不利参数构造有效 p 值。若 $p \leq \alpha$, 则在水平 α 下拒绝 H_0 。

直觉与动机

抽样前, $p(X)$ 是随机变量; 观测后, $p(x)$ 是一个数。简单原假设与连续精确检验下, $p(X) \sim U(0, 1)$; 离散检验或复合原假设下, 有效 p 值通常只满足 $P_\theta\{p(X) \leq u\} \leq u$, 即可能保守。

条件与易错点

p 值与置信区间常见误解

误解	正确说法
p 值是 H_0 为真的概率	p 值是在 H_0 为真时，样本落入同样或更极端区域的概率。
$p > 0.05$ 就接受 H_0	只能说没有足够证据拒绝 H_0 。
p 值不需要看备择方向	p 值必须由备择方向和拒绝域定义。
95% 置信区间表示本次区间有 95% 概率含真值	频率派中参数固定，随机区间的长期覆盖率为 95%。

7.1.4 功效函数与样本量

例 7.1.1 (单侧正态均值检验的水平与功效). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ 已知, 检验 $H_0: \mu \leq \mu_0$ 对 $H_1: \mu > \mu_0$. 水平 α 的拒绝域为

$$\bar{X} > \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}}.$$

对任意真实均值 μ , 功效为

$$\begin{aligned} \pi(\mu) &= P_\mu \left(\bar{X} > \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}} \right) \\ &= 1 - \Phi \left(z_\alpha - \frac{\sqrt{n}(\mu - \mu_0)}{\sigma} \right). \end{aligned}$$

它在原假设边界 $\mu = \mu_0$ 处等于 α ; 固定效应 $\mu - \mu_0 > 0$ 时, 增加 n 会提高功效. 若希望在备择值 $\mu_1 > \mu_0$ 处功效至少为 $1 - \beta$, 可取

$$n \geq \left[\frac{(z_\alpha + z_\beta)\sigma}{\mu_1 - \mu_0} \right]^2$$

并向上取整。

7.2 正态总体参数假设检验

正态总体检验选择表

问题	统计量	零假设分布
单均值, σ 已知	Z	$N(0, 1)$
单均值, σ 未知	T	$t(n-1)$
两独立均值, 方差已知	Z	$N(0, 1)$
两独立均值, 未知但相等	pooled T	$t(n_1 + n_2 - 2)$
两独立均值, 方差不等	Welch T	近似 $t(\nu)$
配对均值差	差值单样本 T	$t(n-1)$
单总体方差	Q	$\chi^2(n-1)$
两总体方差比	F	$F(n_1-1, n_2-1)$

7.2.1 单个正态总体均值的检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 。

- σ^2 已知 (Z 检验): 检验统计量 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$;
- σ^2 未知 (t 检验): 检验统计量 $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。

对于关于 0 对称的 Z 或 T 统计量, 本书以 c_γ 表示上侧概率为 γ 的临界值, 则

$$\begin{array}{l|l} H_1: \mu > \mu_0 & T > c_\alpha \\ H_1: \mu < \mu_0 & T < -c_\alpha \\ H_1: \mu \neq \mu_0 & |T| > c_{\alpha/2} \end{array}$$

其中 Z 检验取 $c_\gamma = z_\gamma$, t 检验取 $c_\gamma = t_{\gamma, n-1}$ 。

7.2.2 假设检验与置信区间的关系

由同一族水平 α 双侧检验反演得到的 $1 - \alpha$ 置信区间满足: $H_0: \theta = \theta_0$ 不被拒绝, 当且仅当 θ_0 落入该区间。若检验与区间不是相互反演构造, 或使用单侧/近似方法, 则不能无条件声称完全等价。

7.2.3 两个正态总体均值差的检验

设 $X_i \sim N(\mu_1, \sigma_1^2)$, $Y_j \sim N(\mu_2, \sigma_2^2)$, 独立, 检验 $H_0: \mu_1 = \mu_2$ (或 $\mu_1 - \mu_2 = \delta_0$)。

令 $D = \bar{X} - \bar{Y} - \delta_0$:

$$\sigma_1^2, \sigma_2^2 \text{ 已知: } Z = \frac{D}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}},$$

$$\sigma_1^2 = \sigma_2^2 \text{ 未知: } T_p = \frac{D}{S_p \sqrt{1/n_1 + 1/n_2}}, \quad S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2},$$

$$\sigma_1^2 \neq \sigma_2^2 \text{ 且均未知: } T_W = \frac{D}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}.$$

前两者在 H_0 下分别服从 $N(0, 1)$ 与 $t(n_1 + n_2 - 2)$; Welch 统计量近似服从 $t(\nu)$, 其中

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{(S_1^2/n_1)^2/(n_1 - 1) + (S_2^2/n_2)^2/(n_2 - 1)}.$$

拒绝域按备择方向使用相应 z 或 t 分位数。

7.2.4 成对数据检验

结构与证明

同一批芯片高温前后测漏电流, 问高温有无影响。同一对象上的两个观测相关, 不能使用独立双样本检验。令 $D_i = X_i - Y_i$, 将问题化为差值的单样本检验: $H_0: \mu_D = 0$, 统计量 $t = \frac{\bar{D}}{S_D/\sqrt{n}} \sim t(n-1)$ 。精确小样本结论要求差值总体正态, 而不是要求两列数据各自独立。

7.2.5 正态总体方差的检验

检验 $H_0: \sigma^2 = \sigma_0^2$, 取

$$Q = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1).$$

右侧、左侧、双侧备择分别在

$$Q > \chi_{\alpha, n-1}^2, \quad Q < \chi_{1-\alpha, n-1}^2, \quad Q < \chi_{1-\alpha/2, n-1}^2 \text{ 或 } Q > \chi_{\alpha/2, n-1}^2$$

时拒绝。这里的下标均为上侧概率: $\chi_{\alpha/2}^2$ 是右侧较大临界值, $\chi_{1-\alpha/2}^2$ 是左侧较小临界值。

两个独立正态总体检验 $H_0: \sigma_1^2/\sigma_2^2 = r_0$ 时, 取

$$F = \frac{S_1^2/S_2^2}{r_0} \sim F(n_1 - 1, n_2 - 1).$$

双侧拒绝域为 $F < F_{1-\alpha/2; n_1-1, n_2-1}$ 或 $F > F_{\alpha/2; n_1-1, n_2-1}$; 单侧检验只取相应一端。这也是上侧临界值记法下的左、右两端。

例 7.2.1 (单总体均值：统计量、 p 值与区间反演). 正态样本 $n = 25$, $\bar{x} = 102$, $s = 10$ 。在 $\alpha = 0.05$ 下检验 $H_0: \mu = 100$ 对 $H_1: \mu \neq 100$ 。因方差未知,

$$t_{\text{obs}} = \frac{102 - 100}{10/\sqrt{25}} = 1, \quad \nu = 24.$$

由于 $|1| < t_{0.025, 24} \approx 2.064$, 不拒绝 H_0 ; 双侧 p 值约为 0.327。相应 95% 置信区间为

$$102 \pm 2.064 \frac{10}{5} = [97.872, 106.128],$$

其中包含 100, 与检验结论一致。

7.3 其他分布参数的假设检验

7.3.1 指数分布参数的假设检验

约定 $X \sim \text{Exp}(\lambda)$ 中 λ 为率参数, 即 $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{\{x>0\}}$ 。检验 $H_0: \lambda = \lambda_0$ 时,

$$Q = 2\lambda_0 \sum_{i=1}^n X_i \sim \chi^2(2n).$$

拒绝域必须按备择方向确定: λ 增大时样本和倾向变小, 因此 $H_1: \lambda > \lambda_0$ 对应 Q 的左尾, 而不是右尾。

7.3.2 比率 p 的检验

设 $X \sim \text{Binomial}(n, p)$, $\hat{p} = X/n$ 。检验 $H_0: p = p_0$ 时, 大样本统计量为

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}} \sim N(0, 1).$$

标准误必须在 H_0 下使用 p_0 ; 当 np_0 或 $n(1 - p_0)$ 过小时, 改用精确二项检验。

7.3.3 大样本检验

对 i.i.d. 非正态总体, 若有关矩有限, 可由 CLT 与 Slutsky 定理构造大样本 Z 统计量。“样本量大”不是唯一条件; 重尾无有限方差、强依赖或极端不平衡比例下需另作分析。

7.4 似然比检验与分布拟合检验

直觉与动机

当没有现成的 Z, t, χ^2, F 枢轴量时，可比较原假设约束下与全参数空间下的最大似然值。似然比检验提供一般构造框架，但有限样本分布和正则性仍需逐题检查。

7.4.1 似然比检验的思想

定义 7.4.1 (似然比统计量).

$$\Lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta | x)}{\sup_{\theta \in \Theta} L(\theta | x)}.$$

其中 Θ_0 是 H_0 对应的参数空间， Θ 是全参数空间。显然 $0 \leq \Lambda(x) \leq 1$ 。若记全参数空间下的 MLE 为 $\hat{\theta}$ ，约束空间 Θ_0 下的 MLE 为 $\hat{\theta}_0$ ，对数似然为 $\ell(\theta) = \log L(\theta | x)$ ，则

$$-2 \log \Lambda(x) = 2\{\ell(\hat{\theta}) - \ell(\hat{\theta}_0)\}.$$

若 $\Lambda(x)$ 非常小，说明即使在 H_0 约束下找到最优参数，也远不如在全空间找的参数好——拒绝 H_0 。

结构与证明

简单假设 P_0 对简单假设 P_1 时，密度比可解释为相对于共同控制测度的密度之比，在绝对连续条件下也可联系 Radon–Nikodym 导数；Neyman–Pearson 引理给出最强检验。广义似然比 Λ 则是两个极大化后的似然值之比，不能笼统称为两个测度之间的 RN 导数。

Wilks 定理

条件 $\Theta_0 \subset \Theta$ 为嵌套正则模型，真参数是相应参数空间的内点，约束局部光滑且可识别。

结论 在 H_0 下，

$$-2 \log \Lambda \xrightarrow{d} \chi_r^2, \quad r = \dim(\Theta) - \dim(\Theta_0).$$

用途 用约束个数确定广义似然比统计量的大样本零分布。

边界 边界参数、不可识别、混合模型或模型错设等非正则情形可能不服从该卡方极限。

结构与证明

在局部光滑参数化下, r 是原假设子模型在全模型中的余维, 即独立约束减少的局部自由方向数; 这属于参数空间的局部几何, 不宜泛称为拓扑学结论。

计算与建模**LRT 标准计算链:**

1. 求全空间 Θ 下的 MLE $\hat{\theta}$, 代入似然函数得分母;
2. 求 H_0 约束下的 MLE (有时就是 θ_0 本身), 代入得分子;
3. 写出似然比 $\Lambda(x)$;
4. **化简不等式**: 把 $\Lambda(x) \leq c$ 通过单调性化简, 剥离出检验统计量 (如 $\bar{X}$ 或 $\sum X_i$);
5. 利用三大抽样分布或 CLT, 找出统计量的分布, 由 α 确定临界值。

7.4.2 分类数据的 χ^2 拟合优度检验

设 n 个观测值落入 k 个类别, O_i 为观测频数, $E_i = np_i^{(0)}$ 为 H_0 下的期望频数。

定理 7.4.1 (皮尔逊 χ^2 拟合优度检验)。 统计量

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \xrightarrow{d} \chi^2(k-1-r),$$

其中 r 是用同一批数据估计并进入期望频数的独立参数个数; 完全指定分布时 $r = 0$ 。

自由度中的 “-1” 来自 $\sum_i O_i = \sum_i E_i = n$ 的总数约束, “- r ” 来自参数估计约束。期望频数过小时卡方近似较差, 应按事先合理的相邻类别合并, 或采用精确/模拟方法; 不能根据观测偏差任意合并以追求显著性。

结构与证明

在多项分布的大样本框架下, Pearson χ^2 、似然比检验统计量 G^2 与 Score 检验有密切关系, 并且具有相同的一阶渐近卡方极限; 但三者不是同一个统计量。

7.4.3 分布的 χ^2 拟合优度检验

检验连续分布族时先固定分组, 用样本估计 r 个参数, 再计算各组拟合概率与期望频数; 在常用正则条件下自由度为 $k-1-r$ 。

7.4.4 列联表的独立性检验

$r \times c$ 列联表中，独立性原假设下的拟合期望频数为

$$\hat{e}_{ij} = \frac{n_{i.}n_{.j}}{n},$$

统计量

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - \hat{e}_{ij})^2}{\hat{e}_{ij}} \sim \chi^2((r-1)(c-1)).$$

仍需检查观测独立性和期望频数；配对分类数据不能机械使用该独立性检验。

例 7.4.1 (拟合优度检验的自由度). 把 $n = 200$ 个观测分成 $k = 6$ 组，并由同一数据估计正态分布的 μ, σ^2 两个参数。若各拟合期望频数足够大，则 Pearson 统计量的渐近自由度为

$$\nu = k - 1 - r = 6 - 1 - 2 = 3.$$

不是 5；若合并一组后只剩 5 组，自由度还要同步改为 $5 - 1 - 2 = 2$ 。

7.5 正态性检验

7.5.1 正态概率纸

用正态概率纸 (Normal Probability Paper) 直观检验样本是否来自正态总体，若点列近似成直线，说明没有明显偏离正态形状；这是诊断图，不给出“正态为真”的证明。

7.5.2 W 检验 (Shapiro-Wilk 检验)

利用次序统计量与正态分布理论值之间的线性相关性构造统计量 W ， W 较小表示偏离正态。应结合相应样本量下的临界值或 p 值判断，不能只凭“接近 1”作结论。

7.5.3 EP 检验

基于经验分布函数与正态分布函数偏差构造统计量 T_{EP} ，用于正态性检验。使用时必须按教材所给定义和分位数表保持参数估计方式一致；不同正态性检验的统计量不可混用临界值。

7.6 非参数检验

直觉与动机

非参数检验通常不指定完整参数分布族，但并非“没有假设”。独立性、连续性、对称性或同分布等条件仍决定零分布和结论含义。其功效不必总低于参数检验；应按数据结构和目标参数选择方法。

7.6.1 游程检验

将观测按原顺序记为两类符号，连续相同符号构成一个游程。给定两类个数 n_1, n_2 ，在“排列次序随机”的原假设下，以游程数 R 为统计量。大样本且无特殊并列处理时，

$$E_0 R = 1 + \frac{2n_1 n_2}{n_1 + n_2},$$

$$\text{Var}_0(R) = \frac{2n_1 n_2 (2n_1 n_2 - n_1 - n_2)}{(n_1 + n_2)^2 (n_1 + n_2 - 1)}.$$

R 过小表示聚集、过大表示过度交替；小样本使用精确分布，大样本可作正态近似。

7.6.2 符号检验

检验连续总体的中位数 $M = M_0$ 时，计算 $D_i = X_i - M_0$ ，删去 $D_i = 0$ 的观测，设剩余容量为 n^* ，正号个数为 B 。在 H_0 下

$$B \sim \text{Binomial}(n^*, 1/2).$$

右侧备择用上尾、左侧备择用下尾；双侧精确 p 值按两端同样或更极端结果计算。该检验只用符号，对异常值稳健，但没有利用差值大小。

7.6.3 Wilcoxon 符号秩检验

对配对差值或单样本中心问题，假定非零差值独立、来自关于 0 对称的连续分布。删去零差，按 $|D_i|$ 从小到大排秩，将正差秩相加得 W^+ 。无并列时，在 H_0 下

$$E_0 W^+ = \frac{n^*(n^* + 1)}{4}, \quad \text{Var}_0(W^+) = \frac{n^*(n^* + 1)(2n^* + 1)}{24}.$$

小样本查精确分布；大样本可正态近似。并列绝对值取平均秩并作方差修正。它与只数正负号的符号检验不同，也不是两独立样本的秩和检验。

7.6.4 Wilcoxon 秩和检验与 Mann-Whitney 检验

设两独立连续样本容量为 m, n 。在“两个总体分布相同”的原假设下，合并数据排秩，令第一组秩和为 W ，并定义

$$U = W - \frac{m(m+1)}{2}.$$

无并列时

$$E_0 U = \frac{mn}{2}, \quad \text{Var}_0(U) = \frac{mn(m+n+1)}{12}.$$

小样本用精确置换分布，大样本用含并列修正的正态近似。若要把结论解释为“位置差异”，还需两总体形状相同、仅有位置平移等附加假设。

结构与证明

秩和检验的精确零分布来自组标签在所有固定容量分配中的等可能性，而不是说数值本身或所有排列无条件服从均匀分布。并列值会减少可能秩型，必须修正或用置换方法。

例 7.6.1 (符号检验的完整计算). 检验连续总体中位数是否为 M_0 。去掉零差后有 $n^* = 10$ 个观测，其中 9 个大于 M_0 。在 H_0 下 $B \sim \text{Binomial}(10, 1/2)$ 。双侧精确 p 值为

$$2P(B \geq 9) = 2 \frac{\binom{10}{9} + \binom{10}{10}}{2^{10}} = \frac{22}{1024} \approx 0.0215.$$

故在 0.05 水平下拒绝 H_0 。若有零差，必须先删除再把新的 n^* 代入二项分布。

7.7 备考指导

知识关系图

$$H_0, H_1 \longrightarrow \text{统计量与零分布} \longrightarrow \begin{cases} \text{拒绝域,} \\ p \text{ 值} \end{cases} \longrightarrow \text{拒绝或不拒绝,}$$

$$\text{水平 } \alpha \longleftrightarrow \text{第一类错误,} \quad \pi(\theta) = 1 - \beta(\theta) \longleftrightarrow \text{功效与样本量,}$$

$$\text{双侧检验族} \longleftrightarrow \text{置信区间反演.}$$

方法选择表

数据结构	首选检验	关键检查
单正态均值	Z 或单样本 t	方差已知/未知
两独立正态均值	Z /pooled/Welch	独立与等方差
同一对象前后	配对 t	对差值建模
正态方差/方差比	χ^2/F	正态性、分位数方向
二项比例	精确二项或大样本 Z	期望成功/失败数
分类频数	Pearson χ^2	自由度、期望频数
配对中心且对称	Wilcoxon 符号秩	零差、并列与对称性
两独立总体分布	秩和/Mann-Whitney	独立、并列、结论含义

条件与易错点

- 复合原假设下检验水平是第一类错误概率的上确界，通常不是处处等于 α 。
- p 值不是 $P(H_0 \mid \text{数据})$ ，也不是效应大小或重复成功概率。
- 备择方向决定尾部；指数率参数增大对应样本和减小，是常见反向陷阱。
- pooled t 、Welch t 、配对 t 针对三种不同设计，不能只按样本量选择。
- 广义似然比是极大似然值之比，不等同于简单假设密度比的 RN 导数解释。
- 拟合优度自由度为 $k - 1 - r$ ；估计参数或合并类别后必须同步修改。
- 符号检验、符号秩检验和秩和检验的原假设、数据结构与统计量均不同。

432 高频题型

1. 给定备择方向写拒绝域、计算 p 值并解释结论。
2. 正态总体八分支选择与统计量、自由度计算。
3. 由拒绝域求势函数、第二类错误及样本量。
4. 似然比统计量化简与 Wilks 自由度。
5. 拟合优度/列联表的期望频数、自由度和合并规则。
6. 三类非参数检验的精确或渐近计算。

分层练习与简解

A. 直接计算： $Z_{\text{obs}} = 2.1$ ，检验 $H_0 : \mu = \mu_0$ 对 $H_1 : \mu > \mu_0$ ，求 p 值表达式并在 0.05 水平判断。

简解： $p = 1 - \Phi(2.1) \approx 0.0179 < 0.05$ ，拒绝 H_0 。

B. 综合选择：两独立小样本来自正态总体，方差未知且无充分依据认为相等，应选何检验？

简解：选择 Welch t ，使用 $S_1^2/n_1 + S_2^2/n_2$ 的标准误和 Satterthwaite 自由度。

C. 结构证明：说明由水平 α 双侧检验族反演所得集合为何具有至少 $1 - \alpha$ 的覆盖率。

简解：真参数 θ 不落入反演集合，当且仅当检验在 θ 为真时拒绝；该概率不超过 α ，故覆盖概率至少为 $1 - \alpha$ 。

第 8 章

方差分析与回归分析

直觉与动机

本章把统计推断落到模型层面：方差分析比较多个总体均值，回归分析刻画变量之间的线性关系。两者都可写成线性模型 $Y = X\beta + \varepsilon$ ，但教学上先从单因子 ANOVA 和一元线性回归的标量计算开始，再用正交投影解释平方和、自由度和 F 检验的统一结构。

本章路线与层次

ANOVA: 模型假设 $\rightarrow$ SS 分解 $\rightarrow$ MS $\rightarrow$ F $\rightarrow$ 多重比较与诊断,

回归建模: 模型假设 $\rightarrow$ OLS $\rightarrow$ 估计量分布,

回归推断: t/F $\rightarrow$ 参数区间 $\rightarrow$ 预测 $\rightarrow$ 残差诊断.

432 主线要求能从原始数据填完整 ANOVA 表，并完成一元回归的估计、检验、区间与预测。矩阵投影、稳健标准误和非线性模型比较置于结构理解或扩展层。

8.1 方差分析 (ANOVA)

直觉与动机

动机：有 k 种不同的处理（如 k 种光刻机工艺、 k 种药物），想知道它们对结果（芯片线宽、疗效）的影响是否有显著差异。

若直接进行许多未经校正的两两 t 检验，全族至少一次第一类错误的概率会升高。需要把它们放在一个全局模型下同时比较——这就是方差分析。

8.1.1 问题的提出

单因子方差分析：考察一个因子 (Factor) 的 k 个水平 (Level) 对响应变量 Y 的影响。数据结构：第 i 组 (第 i 个水平) 有 n_i 个观测值 $Y_{i1}, Y_{i2}, \dots, Y_{in_i}$, $i = 1, \dots, k$ 。

8.1.2 单因子方差分析的统计模型

定义 8.1.1 (单因子方差分析模型).

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad \varepsilon_{ij} \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2),$$

其中因子水平视为固定, μ 是加权总均值, α_i 是第 i 个水平的固定效应, 采用可识别约束 $\sum_{i=1}^k n_i \alpha_i = 0$ 。

原假设 $H_0: \alpha_1 = \alpha_2 = \cdots = \alpha_k = 0$ (各组均值相等)。

经典精确 F 检验依赖: 各观测相互独立、各组误差正态、共同方差 σ^2 , 且模型均值结构设定正确。若改用约束 $\sum_i \alpha_i = 0$, μ 与 α_i 的参数含义会改变, 但各组均值和“是否全部相等”的检验不变。

计算与建模

既然检验的是均值, 为何称“方差分析”? 因为组均值差异会体现为组间平方和相对于组内平方和增大。若各组真实均值不同, 组间的样本均值就波动很大 (**组间方差大**); 而组内的个体差异纯粹是随机噪声 (组内方差)。检验统计量正是 $F = MS_A / MS_E$; 在 H_0 下两者都估计同一 σ^2 , 备择下 MS_A 倾向增大。

8.1.3 平方和分解

总样本量 $n = \sum_{i=1}^k n_i$, 总均值 $\bar{Y} = \frac{1}{n} \sum_{i,j} Y_{ij}$, 组均值 $\bar{Y}_i = \frac{1}{n_i} \sum_j Y_{ij}$ 。

定理 8.1.1 (平方和分解)。

$$S_T = S_A + S_E,$$

其中:

$$S_T = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y})^2 \quad (\text{总平方和, 自由度 } n-1),$$

$$S_A = \sum_{i=1}^k n_i (\bar{Y}_i - \bar{Y})^2 \quad (\text{组间平方和, 自由度 } k-1),$$

$$S_E = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2 \quad (\text{组内 (误差) 平方和, 自由度 } n-k).$$

代数证明. 对每个观测使用恒等分解

$$Y_{ij} - \bar{Y} = (Y_{ij} - \bar{Y}_i) + (\bar{Y}_i - \bar{Y}).$$

平方后求和，交叉项为

$$2 \sum_{i=1}^k (\bar{Y}_i - \bar{Y}) \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i) = 0,$$

因为每一组内离差之和均为零。剩余两项正是 S_E 与 S_A ，故 $S_T = S_A + S_E$ 。 $\square$

正交投影证明。把全部观测按组堆成向量

$$y = (Y_{11}, \dots, Y_{1n_1}, Y_{21}, \dots, Y_{kn_k})^T \in \mathbb{R}^n.$$

令 $\mathbf{1} = (1, \dots, 1)^T$ ，总均值投影矩阵为

$$P_0 = \frac{\mathbf{1}\mathbf{1}^T}{n}.$$

设 $G \in \mathbb{R}^{n \times k}$ 为组指示矩阵：若第 m 个观测属于第 i 组，则 $G_{mi} = 1$ ，否则为 0。组均值子空间的正交投影为

$$P_A = G(G^T G)^{-1} G^T.$$

由于常数向量属于组均值子空间，有 $\text{Col}(P_0) \subset \text{Col}(P_A)$ ，从而 $P_A P_0 = P_0$ ，且 $P_A - P_0$ 与 $I - P_A$ 是正交投影到互相正交的子空间。

三类平方和可写为

$$\begin{aligned} S_T &= \|(I - P_0)y\|^2, \\ S_A &= \|(P_A - P_0)y\|^2, \\ S_E &= \|(I - P_A)y\|^2. \end{aligned}$$

又有正交分解

$$(I - P_0)y = (P_A - P_0)y + (I - P_A)y,$$

且

$$\langle (P_A - P_0)y, (I - P_A)y \rangle = 0.$$

由欧式空间勾股定理，

$$S_T = \|(I - P_0)y\|^2 = \|(P_A - P_0)y\|^2 + \|(I - P_A)y\|^2 = S_A + S_E.$$

$\square$

结构与证明

把所有观测看作 $\mathbb{R}^n$ 中的向量。三个正交投影的秩为

$$\text{rank}(P_0) = 1, \quad \text{rank}(P_A - P_0) = k - 1, \quad \text{rank}(I - P_A) = n - k.$$

因此：

8.1 方差分析 (ANOVA)

- $S_A = \|(P_A - P_0)Y\|^2$ 位于去掉总均值方向后的 $k - 1$ 维组间对比子空间；
- $S_E = \|(I - P_A)Y\|^2$ 位于 $n - k$ 维组内残差子空间。

二者正交，所以平方和分解就是欧式空间中的勾股定理。 S_A 不是投向完整 k 维组均值空间后的模长平方。

8.1.4 检验方法

单因子 ANOVA 的 F 检验

条件 固定效应模型成立，误差相互独立且服从 $N(0, \sigma^2)$ ，检验 $H_0: \mu_1 = \cdots = \mu_k$ 。

结论 在 H_0 下，

$$\frac{S_A}{\sigma^2} \sim \chi^2(k-1), \quad \frac{S_E}{\sigma^2} \sim \chi^2(n-k),$$

二者独立，因而

$$F = \frac{S_A/(k-1)}{S_E/(n-k)} \sim F(k-1, n-k).$$

若 $F_{\gamma; u, v}$ 表示上侧概率为 γ 的临界值，则水平 α 拒绝域为 $F > F_{\alpha; k-1, n-k}$ 。

用途 检验多个正态总体均值是否全部相等，并填写 ANOVA 表。

边界 拒绝只说明至少一个均值不同；方差不齐、相关观测或明显非正态小样本下，经典精确分布不再成立。

结构与证明

几何解释：由 Cochran 定理，正交的正态投影给出独立卡方平方和，因此 S_A 和 S_E 独立，各平方和除以相应自由度后形成均方，其比值服从相应 F 分布。

方差分析表 (ANOVA Table):

来源	平方和	自由度	均方	F 值
因子 A	S_A	$k - 1$	$MS_A = S_A/(k - 1)$	$F = MS_A/MS_E$
误差 E	S_E	$n - k$	$MS_E = S_E/(n - k)$	
总计	S_T	$n - 1$		

例 8.1.1 (从原始数据填写 ANOVA 表). 三组观测分别为

$$A: (4, 5, 6), \quad B: (6, 7, 8), \quad C: (8, 9, 10).$$

组均值为 5, 7, 9，总均值为 7。于是

$$S_A = 3\{(5-7)^2 + (7-7)^2 + (9-7)^2\} = 24,$$

8.2 多重比较

每组组内平方和均为 2，故 $S_E = 6$ ， $S_T = S_A + S_E = 30$ 。完整表为

来源	SS	df	MS	F
A	24	2	12	12
E	6	6	1	
T	30	8		

在 $\alpha = 0.05$ 下， $F_{0.05;2,6} \approx 5.14$ ，故 $12 > 5.14$ ，拒绝三组均值全部相等。

8.1.5 参数估计

各组均值估计为 $\hat{\mu}_i = \bar{Y}_i$ ，加权约束下 $\hat{\mu} = \bar{Y}$ 、 $\hat{\alpha}_i = \bar{Y}_i - \bar{Y}$ ； $\hat{\sigma}^2 = MS_E$ 是误差方差的无偏估计。

8.1.6 重复数不等情形

各组样本量不等时， $S_A = \sum_i n_i (\bar{Y}_i - \bar{Y})^2$ 与自由度公式仍成立，但总均值必须按 n_i 加权，多重比较的标准误也必须保留 $1/n_i + 1/n_j$ ；不能把平衡设计公式中的共同重复数直接套用。

8.2 多重比较

直觉与动机

动机： F 检验拒绝了 H_0 ，告诉我们“这 k 种处理不一样”，但**到底哪些组之间有差异**？需要进一步的两两比较。

若有 $k = 10$ 组，两两比较需做 $m = \binom{10}{2} = 45$ 次检验。FWER 定义为“整个比较族中至少出现一个第一类错误”的概率。若 m 个检验相互独立且每个水平为 α ，则 FWER 为 $1 - (1 - \alpha)^m$ ；成对均值比较共享数据、彼此相关，该式只能作独立近似的直觉说明，不能当作精确结果。

8.2.1 水平均值差的置信区间

单独考虑某一对 (i, j) 时，未校正的 $1 - \alpha$ 区间为

$$(\bar{Y}_i - \bar{Y}_j) \pm t_{\alpha/2, n-k} \sqrt{MS_E \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}.$$

同时报告许多此类区间并不能保证联合覆盖率仍为 $1 - \alpha$ 。

8.2.2 多重比较问题

同时对所有均值差做推断，需要控制全族错误率 (FWER)。Bonferroni 方法对 m 个预先指定比较把每个双侧区间改用 $t_{\alpha/(2m), n-k}$ ，不要求检验独立，但通常较保守。

8.2.3 重复数相等场合的 T 法 (Tukey 法)

用学生化极差统计量 q 代替 t 统计量，从而更严格地控制全族错误率。平衡设计每组容量为 n_0 时，拒绝 $\mu_i = \mu_j$ 的条件为

$$|\bar{Y}_i - \bar{Y}_j| > q_{\alpha; k, n-k} \sqrt{MS_E / n_0}.$$

不等重复数时可使用 Tukey-Kramer 标准误 $\sqrt{MS_E(1/n_i + 1/n_j)/2}$ ，并保持相同学生化极差分位数口径。

8.2.4 任意线性对比的 Scheffé 法

用 F 分布构造同时置信区间，控制对所有均值线性对比的 FWER。对任意对比 $\sum c_i \mu_i$ ($\sum c_i = 0$)，同时置信区间为

$$\sum c_i \bar{Y}_i \pm \sqrt{(k-1)F_{\alpha; k-1, n-k}} \sqrt{MS_E \sum \frac{c_i^2}{n_i}}.$$

8.3 方差齐性检验

直觉与动机

经典单因子 ANOVA 假定各组误差方差相等。几何上，共同方差使误差协方差矩阵为 $\sigma^2 I$ ，标准化误差具有各向同性；正交投影平方和才得到经典独立卡方分布。若有的组噪声大有的小，球变成椭球，投影后的平方和分布不再给出经典精确 F 检验；此时错误率可能失控，应考虑 Welch ANOVA、稳健方差方法或非参数替代。

条件与易错点

ANOVA 与回归公式使用条件

方法	主要条件	条件不稳时的处理
经典单因子 ANOVA	组间独立、组内正态、方差齐性	方差不齐考虑 Welch ANOVA；重尾或小样本考虑稳健/非参数方法。
回归 F/t 检验	线性均值结构、独立误差、同方差、常用正态误差或大样本近似	异方差时使用稳健标准误；非线性结构先改模型。
多重比较	先明确要控制的错误率，如 FWER	同时区间或校正方法要与比较族匹配。

8.3.1 哈特利检验

统计量 $H = \max_i S_i^2 / \min_i S_i^2$ 。其经典临界值要求各组独立正态且样本量相等，对非正态和异常值敏感，宜作为传统方法了解。

8.3.2 巴特利特检验

令

$$S_p^2 = \frac{\sum_{i=1}^k (n_i - 1) S_i^2}{n - k}, \quad C = 1 + \frac{1}{3(k-1)} \left(\sum_{i=1}^k \frac{1}{n_i - 1} - \frac{1}{n - k} \right).$$

使用自然对数时，Bartlett 统计量为

$$B = \frac{(n - k) \log S_p^2 - \sum_{i=1}^k (n_i - 1) \log S_i^2}{C} \sim \chi^2(k - 1).$$

较大的 B 反对方差齐性。该检验对非正态十分敏感，显著结果可能来自重尾或异常值而非方差差异。

8.3.3 修正的巴特利特检验

小样本修正仍依赖正态性。实际诊断中可把 Levene 检验或以组中位数为中心的 Brown–Forsythe 检验作为更稳健的扩展方法；不要把“先做方差检验，再机械选择模型”当作唯一流程，还应结合残差图、设计背景和稳健方法。

8.4 一元线性回归

直觉与动机

回归分析用条件均值 $E(Y | x)$ 描述响应随解释变量的系统变化，并把未解释部分归入误差。相关性本身不等于因果关系，斜率解释必须结合研究设计和变量单位。

8.4.1 变量间的两类关系

- **函数关系**： $Y = f(X)$ （确定性）；
- **统计关系（相关关系）**： Y 随 X 变化有一定规律，但不完全确定——回归分析的对象。

8.4.2 一元线性回归模型

定义 8.4.1 (一元线性回归模型).

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n.$$

其中 x_i 视为固定设计点，且 $L_{xx} = \sum_i (x_i - \bar{x})^2 > 0$ ； $\beta_0, \beta_1, \sigma^2$ 未知。

正态性用于有限样本精确 t/F 推断；只要求 $E(\varepsilon_i | x_i) = 0$ 、同方差且不相关时，OLS 的无偏性和方差公式仍成立。随机解释变量情形通常在给定观测到的 x_i 条件下分析。

8.4.3 回归系数的最小二乘估计 (OLS)

定义 8.4.2 (最小二乘估计). 最小化残差平方和 $Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ ，得到最小二乘估计值

$$\hat{\beta}_1 = \frac{L_{xy}}{L_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$

其中 $L_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ 。

对 Q 分别求偏导，得到正规方程

$$\sum_{i=1}^n e_i = 0, \quad \sum_{i=1}^n x_i e_i = 0, \quad e_i = y_i - \hat{y}_i.$$

第一式推出回归直线经过 $(\bar{x}, \bar{y})$ ，联立两式即得上述 OLS 公式。

结构与证明

令 $\mathbf{Y} = (Y_1, \dots, Y_n)^T$, $\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$, $\boldsymbol{\beta} = (\beta_0, \beta_1)^T$ 。当 $\mathbf{X}$ 满列秩时,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}, \quad \hat{\mathbf{Y}} = H \mathbf{Y}, \quad H = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T.$$

H 是到 $\text{Col}(\mathbf{X})$ 的正交投影, 残差 $\mathbf{e} = (I - H)\mathbf{Y}$ 满足 $\mathbf{X}^T \mathbf{e} = 0$ 。

条件与易错点

正态误差下, β_0, β_1 的 MLE 与 OLS 相同, 但误差方差的 MLE 与无偏估计不同:

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{SSE}{n}, \quad S^2 = \frac{SSE}{n-2}.$$

因此不能笼统说 “OLS 与 MLE 完全等价”。

8.4.4 估计量分布与标准误

正态一元线性回归的抽样分布

条件 固定设计满足 $L_{xx} > 0$, 误差独立同分布为 $N(0, \sigma^2)$ 。

结论

$$\begin{aligned} \hat{\beta}_1 &\sim N\left(\beta_1, \frac{\sigma^2}{L_{xx}}\right), \\ \hat{\beta}_0 &\sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{L_{xx}}\right)\right), \\ \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) &= -\frac{\bar{x}\sigma^2}{L_{xx}}, \\ \frac{(n-2)S^2}{\sigma^2} &= \frac{SSE}{\sigma^2} \sim \chi^2(n-2), \end{aligned}$$

且 $\hat{\boldsymbol{\beta}}$ 与 S^2 独立。

用途 构造回归系数的 t 检验、置信区间和回归 F 检验。

边界 异方差、相关误差或模型非线性会破坏这些经典标准误和精确分布。

8.4.5 回归方程的显著性检验

平方和分解: $S_T = S_R + S_E$ (总变差 = 回归平方和 + 残差平方和), 其中

$$S_T = \sum (y_i - \bar{y})^2, \quad df_T = n - 1,$$

$$S_R = \hat{\beta}_1^2 L_{xx}, \quad df_R = 1,$$

$$S_E = S_T - S_R, \quad df_E = n - 2.$$

记 $MSE = S_E/(n - 2) = S^2$ 。检验 $H_0: \beta_1 = b_1$ 时,

$$T = \frac{\hat{\beta}_1 - b_1}{S/\sqrt{L_{xx}}} \sim t(n - 2),$$

故 β_1 的 $1 - \alpha$ 置信区间为

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} \frac{S}{\sqrt{L_{xx}}}.$$

检验 $H_0: \beta_1 = 0$ 时, 也可使用

$$F = \frac{S_R/1}{S_E/(n - 2)} \sim F(1, n - 2).$$

含截距模型的决定系数为 $R^2 = S_R/S_T = 1 - S_E/S_T$, 表示样本总离差中由线性拟合解释的比例; 高 R^2 不保证模型条件满足, 也不说明因果关系。

定理 8.4.1 (一元回归中 F 检验与 t 检验的等价性)。在一元线性回归中, 用 F 检验整个回归方程是否显著, 与用 t 检验斜率 β_1 是否为 0, 在同一正态线性模型下等价, 且 $F = t^2$ (t 统计量的平方等于 F 统计量)。

结构与证明

这是因为 $t(\nu)^2 \sim F(1, \nu)$, 并且一元回归的回归平方和只有一个自由度。

8.4.6 估计与预测

给定 x_0 , 记

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0, \quad h_0 = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{L_{xx}}.$$

必须区分三个对象:

1. 拟合的平均响应点估计: $\hat{y}_0$;
2. 平均响应 $E(Y | x_0)$ 的 $1 - \alpha$ 置信区间:

$$\hat{y}_0 \pm t_{\alpha/2, n-2} S \sqrt{h_0};$$

3. 独立新观测 $Y_{\text{new}}(x_0)$ 的 $1 - \alpha$ 预测区间:

$$\hat{y}_0 \pm t_{\alpha/2, n-2} S \sqrt{1 + h_0}.$$

预测区间多出的 1 来自新观测自身不可约误差，而不是单纯“多估计了一个参数”。当 x_0 远离 $\bar{x}$ 时 h_0 增大；超出设计点范围的外推尤其需要谨慎。

例 8.4.1 (一元回归的完整计算链). 观测为 $(x_i, y_i) = (1, 2), (2, 3), (3, 5), (4, 4)$ 。有

$$\bar{x} = 2.5, \quad \bar{y} = 3.5, \quad L_{xx} = 5, \quad L_{xy} = 4,$$

故 $\hat{\beta}_1 = 0.8$ 、 $\hat{\beta}_0 = 1.5$ 。进一步

$$S_T = 5, \quad S_R = \hat{\beta}_1^2 L_{xx} = 3.2, \quad S_E = 1.8, \quad S^2 = \frac{1.8}{2} = 0.9.$$

斜率检验统计量与回归 F 统计量为

$$t = \frac{0.8}{\sqrt{0.9/5}} \approx 1.886, \quad F = \frac{3.2}{0.9} \approx 3.556 = t^2.$$

取 $\alpha = 0.05$, $t_{0.025, 2} \approx 4.303$ (上侧临界值), 斜率区间为

$$0.8 \pm 4.303 \sqrt{0.9/5} \approx [-1.026, 2.626],$$

包含 0, 故不拒绝 $H_0: \beta_1 = 0$ 。在 $x_0 = \bar{x} = 2.5$ 处, $\hat{y}_0 = 3.5$ 、 $h_0 = 1/4$ 。相应 95% 平均响应区间与预测区间约为

$$3.5 \pm 4.303 \sqrt{0.9} \sqrt{1/4} \approx [1.459, 5.541],$$

$$3.5 \pm 4.303 \sqrt{0.9} \sqrt{1 + 1/4} \approx [-1.064, 8.064].$$

8.4.7 残差诊断与影响点

拟合后应检查模型，而不是只报告 R^2 和 p 值:

诊断目标	常用图或量	典型信号
线性关系	残差-拟合值图	系统弯曲
方差齐性	残差-拟合值图	扇形扩散
正态性	正态 Q-Q 图	尾部明显偏离
独立性	按时间/次序的残差图	周期、趋势、成串同号
高杠杆点	$h_{ii} = 1/n + (x_i - \bar{x})^2/L_{xx}$	远离 $\bar{x}$ 的设计点
异常与强影响	学生化残差、Cook 距离	大残差且删除后拟合明显改变

高杠杆不等于异常，异常也不必然强影响。发现可疑点后先核对记录、研究设计和模型形式，不能仅因其影响结论就删除；异方差可考虑变换、加权最小二乘或稳健标准误。

8.5 一元非线性回归

直觉与动机

若散点图和残差图显示条件均值不是直线，可考虑变量变换、加入多项式项或直接拟合非线性模型。

8.5.1 确定可能的函数形式

通过散点图的形状，选择可能的函数模型：指数型、幂函数型、对数型等。

8.5.2 参数估计（变量替换线性化）

例 8.5.1. 若模型为 $Y = Ae^{BX} \cdot \varepsilon$ (乘性误差), 两边取对数: $\ln Y = \ln A + BX + \ln \varepsilon$, 令 $Y' = \ln Y$, $\beta_0 = \ln A$, $\beta_1 = B$, 立即化为一元线性回归!

结构与证明

变换后必须重新检查误差结构。原始模型若是加性正态误差 ($Y = f(X) + \varepsilon$), 则取对数后误差不再满足正态假设; 若是乘性对数正态误差, 取对数后才能得到正态误差。从对数尺度反变换回原尺度时, $\exp\{E(\log Y \mid X)\}$ 通常是条件中位数而非条件均值, 需要考虑反变换偏差修正。

8.5.3 曲线回归方程的比较

只有响应尺度相同、样本相同且平方和定义相同的模型， R^2 才可作辅助比较。不同响应变换后的 R^2 不可直接排序。模型比较应优先考察原尺度预测误差、残差结构、交叉验证表现，以及在同一概率模型下的似然或信息准则；同时兼顾可解释性和外推风险。

8.6 备考指导

知识关系图

$$Y = X\beta + \varepsilon \longrightarrow \hat{Y} = P_X Y, \quad e = (I - P_X)Y, \quad \hat{Y} \perp e,$$
$$\text{ANOVA: 组指示设计矩阵} \longrightarrow S_T = S_A + S_E \longrightarrow F = MS_A/MS_E,$$
$$\text{回归: 连续解释变量} \longrightarrow S_T = S_R + S_E \longrightarrow t, F, \text{区间与预测}.$$

方法选择表

任务	首选方法	关键检查
多个独立正态均值	单因子 ANOVA	独立、正态、齐性
确定哪些均值不同	多重比较法	比较族与 FWER
方差不齐多组均值	Welch ANOVA (扩展)	不套经典精确 F
线性条件均值	一元 OLS	$L_{xx} > 0$ 、残差结构
斜率推断	t 或等价 F	正态误差或适当近似
平均响应	均值置信区间	使用 h_0
单个未来响应	预测区间	使用 $1 + h_0$
比较变换模型	原尺度误差/CV/似然	不跨尺度比较 R^2

条件与易错点

- ANOVA 的组间效应空间维数是 $k - 1$ ，不是完整组均值空间的 k 。
- 全局 F 拒绝只说明至少一个均值不同；定位差异必须控制多重比较错误率。
- $1 - (1 - \alpha)^m$ 只在独立检验下精确；成对比较通常相关。
- Bartlett 检验对非正态敏感，方差不齐时应考虑 Welch 或稳健方法。
- 正态回归中只有回归系数的 OLS 与 MLE 相同； SSE/n 与 $SSE/(n - 2)$ 作用不同。

- 平均响应区间使用 h_0 ，新观测预测区间使用 $1 + h_0$ 。
- 高杠杆、异常和强影响是不同概念；不能仅因数据点改变结论就删除。
- 不同响应尺度上的 R^2 不可直接比较。

432 高频题型

1. 由原始分组数据或残缺表补齐 SS, df, MS, F 。
2. 证明 $S_T = S_A + S_E$ 并解释自由度分解。
3. OLS 系数、残差平方和、 R^2 与斜率 t/F 检验。
4. 回归系数区间、平均响应区间和新观测预测区间。
5. 根据残差图识别非线性、异方差、相关和影响点。

分层练习与简解

A. 直接计算：单因子 ANOVA 中 $k = 4, n = 20, S_A = 30, S_E = 40$ ，求 MS_A, MS_E, F 。

简解：自由度为 3, 16，故 $MS_A = 10, MS_E = 2.5, F = 4$ 。

B. 综合辨析：为何新观测预测区间总比同一点的平均响应区间宽？

简解：两者共同含估计均值的不确定性 $h_0\sigma^2$ ；新观测还含独立误差 σ^2 ，因而方差因子由 h_0 变为 $1 + h_0$ 。

C. 结构证明：证明含截距一元回归的残差与常数向量、解释变量向量都正交。

简解：OLS 正规方程为 $\mathbf{X}^T \mathbf{e} = 0$ ； $\mathbf{X}$ 的两列正是 $\mathbf{1}$ 与 $(x_1, \dots, x_n)^T$ 。

附录 A

常用分布卡

本附录只记录需要反复调用的参数化。使用分布表或其他教材前，应先检查支撑、参数含义以及分位数的上下侧约定。

A.1 离散分布

分布卡：伯努利分布 $\text{Bern}(p)$

支撑 $x \in \{0, 1\}$ 。

参数化 $\mathbb{P}(X = x) = p^x(1-p)^{1-x}$, $0 < p < 1$ 。

矩 $\mathbb{E}X = p$, $\text{Var}(X) = p(1-p)$ 。

分布卡：二项分布 $B(n, p)$

支撑 $k = 0, 1, \dots, n$ 。

参数化 $\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$; n 次独立同分布伯努利试验中的成功次数。

矩 $\mathbb{E}X = np$, $\text{Var}(X) = np(1-p)$ 。

分布卡：超几何分布 $H(N, M, n)$

支撑 $\max\{0, n - (N - M)\} \leq k \leq \min\{n, M\}$, k 为整数。

参数化 总体含 N 个对象，其中 M 个具有目标属性；不放回抽取 n 个，

$$\mathbb{P}(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}.$$

矩 $\mathbb{E}X = nM/N$, $\text{Var}(X) = n \frac{M}{N} (1 - \frac{M}{N}) \frac{N-n}{N-1}$ 。

A.2 连续分布

分布卡：泊松分布 $P(\lambda)$

支撑 $k = 0, 1, 2, \dots$ 。

参数化 $\mathbb{P}(X = k) = e^{-\lambda} \lambda^k / k!$, $\lambda > 0$; λ 是给定区间内的平均发生次数。

矩 $\mathbb{E}X = \lambda$, $\text{Var}(X) = \lambda$ 。

分布卡：几何分布 $G(p)$

支撑 $k = 1, 2, \dots$; X 表示首次成功所需的试验次数。

参数化 $\mathbb{P}(X = k) = (1 - p)^{k-1} p$, $0 < p < 1$ 。若改记“首次成功前的失败数”，支撑和均值均相差 1。

矩 $\mathbb{E}X = 1/p$, $\text{Var}(X) = (1 - p)/p^2$ 。

分布卡：负二项分布 $NB(r, p)$

支撑 $k = r, r + 1, \dots$; X 表示第 r 次成功所需的试验次数。

参数化 $\mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1 - p)^{k-r}$, $r \in \mathbb{N}_+$, $0 < p < 1$ 。

矩 $\mathbb{E}X = r/p$, $\text{Var}(X) = r(1 - p)/p^2$ 。

A.2 连续分布

分布卡：均匀分布 $U(a, b)$

支撑 $a < x < b$ 。

参数化 $f(x) = 1/(b - a)$, $a < b$ 。

矩 $\mathbb{E}X = (a + b)/2$, $\text{Var}(X) = (b - a)^2/12$ 。

分布卡：指数分布 $\text{Exp}(\lambda)$

支撑 $x > 0$ 。

参数化 $f(x) = \lambda e^{-\lambda x}$, $\lambda > 0$ 为 rate; $\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$ 。

矩 $\mathbb{E}X = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$ 。

A.3 统计推断中的三个分布

分布卡：Gamma 分布 $\Gamma(\alpha, \lambda)$

支撑 $x > 0$ 。

参数化 本书固定使用 rate 参数：

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad \alpha, \lambda > 0.$$

当 $\alpha = n \in \mathbb{N}_+$ 时，它描述速率为 λ 的泊松过程中等待第 n 次到达的总时间。

矩 $\mathbb{E}X = \alpha/\lambda$, $\text{Var}(X) = \alpha/\lambda^2$ 。

分布卡：Beta 分布 $\text{Beta}(a, b)$

支撑 $0 < x < 1$ 。

参数化 $f(x) = x^{a-1}(1-x)^{b-1}/B(a, b)$, $a, b > 0$ 。

矩 $\mathbb{E}X = a/(a+b)$, $\text{Var}(X) = ab/[(a+b)^2(a+b+1)]$ 。

分布卡：正态分布 $N(\mu, \sigma^2)$

支撑 $x \in \mathbb{R}$ 。

参数化 $f(x) = (\sqrt{2\pi}\sigma)^{-1} \exp[-(x-\mu)^2/(2\sigma^2)]$, $\sigma > 0$; $(X-\mu)/\sigma \sim N(0, 1)$ 。

矩 $\mathbb{E}X = \mu$, $\text{Var}(X) = \sigma^2$; 所有奇数阶中心矩为 0。

A.3 统计推断中的三个分布

分布卡：卡方分布 $\chi^2(\nu)$

支撑 $x > 0$ 。

参数化 $Z_1, \dots, Z_\nu$ 独立且服从 $N(0, 1)$ 时, $\sum_{i=1}^\nu Z_i^2 \sim \chi^2(\nu)$; 等价地为 $\Gamma(\nu/2, 1/2)$ (rate 参数)。

矩 $\mathbb{E}X = \nu$, $\text{Var}(X) = 2\nu$ 。

分布卡：Student t 分布 $t(\nu)$

支撑 $x \in \mathbb{R}$ 。

参数化 $T = Z/\sqrt{U/\nu}$, 其中 $Z \sim N(0, 1)$ 、 $U \sim \chi^2(\nu)$ 且相互独立。

矩 $\mathbb{E}T = 0$ ($\nu > 1$); $\text{Var}(T) = \nu/(\nu-2)$ ($\nu > 2$)。低自由度时相应矩不存在。

分布卡: F 分布 $F(m, n)$

支撑 $x > 0$ 。

参数化 $F = (U/m)/(V/n)$, 其中 $U \sim \chi^2(m)$ 、 $V \sim \chi^2(n)$ 且相互独立; 并有 $1/F \sim F(n, m)$ 。

矩 $\mathbb{E}F = n/(n-2)$ ($n > 2$); 方差仅在 $n > 4$ 时存在。

参数化核对

几何与负二项分布既可记录试验次数, 也可记录失败次数; Gamma 分布的第二参数既可能是 rate, 也可能是 scale。答题时先写支撑与密度 (或分布列), 可以从源头消除歧义。

附录 B

常用枢轴量

若统计量 $G(X_1, \dots, X_n; \theta)$ 的分布不依赖未知参数，则称其为枢轴量。区间估计的基本步骤是：选取枢轴量，截取概率为 $1 - \alpha$ 的区间，再对参数解不等式。

B.1 单个总体

正态总体均值：方差已知

条件 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ ，且 σ^2 已知。

结论 $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0, 1)$ 。

用途 μ 的 $1 - \alpha$ 置信区间为 $\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$ 。

边界 总体非正态时，该结论通常依赖大样本近似；小样本下不能仅凭“方差已知”得到精确正态枢轴量。

正态总体均值：方差未知

条件 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ ， σ^2 未知。

结论 $T = (\bar{X} - \mu)/(S/\sqrt{n}) \sim t(n - 1)$ 。

用途 μ 的 $1 - \alpha$ 置信区间为 $\bar{X} \pm t_{\alpha/2}(n - 1)S/\sqrt{n}$ 。

边界 精确 t 分布使用了正态样本中 $\bar{X}$ 与 S^2 的独立性。

正态总体方差

条件 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ ，均值可以未知。

结论 $U = (n - 1)S^2/\sigma^2 \sim \chi^2(n - 1)$ 。

B.2 两个总体

用途 σ^2 的 $1 - \alpha$ 置信区间为

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right].$$

边界 卡方枢轴量对总体正态性敏感；上式使用附录 A 的上侧临界值约定。

单总体比例的大样本标准化

条件 $X \sim B(n, p)$, $\hat{p} = X/n$; $n\hat{p}$ 与 $n(1 - \hat{p})$ 足够大。

结论 $Z = (\hat{p} - p)/\sqrt{p(1-p)/n} \sim N(0, 1)$ 。

用途 Wald 区间为 $\hat{p} \pm z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})/n}$ ；靠近 0 或 1 时应优先采用更稳健的比例区间。

边界 这是渐近结论而非精确枢轴量；小样本或稀有事件场景不宜直接使用 Wald 区间。

B.2 两个总体

两个正态均值之差：方差已知

条件 两组样本独立，分别来自 $N(\mu_1, \sigma_1^2)$ 与 $N(\mu_2, \sigma_2^2)$ ，且两个方差已知。

结论 $Z = [(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)]/\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2} \sim N(0, 1)$ 。

用途 将 $z_{\alpha/2}$ 乘标准误即可得到 $\mu_1 - \mu_2$ 的双侧区间。

边界 两组观测配对时不能使用独立样本标准误，应先转化为差值样本。

两个正态均值之差：未知但等方差

条件 两组独立正态样本， $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知。令

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

结论 $T = [(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)]/[S_p\sqrt{1/n_1 + 1/n_2}] \sim t(n_1 + n_2 - 2)$ 。

用途 用于合并方差的两样本 t 区间及其反演检验。

边界 “方差相近”不能仅由两个样本方差数值接近来断言；等方差假设不可信时使用 Welch 方法。

两个均值之差：Welch 近似

条件 两组样本独立，方差未知且不假定相等；正态小样本或一般总体大样本。

结论

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{S_1^2/n_1 + S_2^2/n_2}} \sim t(\nu),$$

其中

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{(S_1^2/n_1)^2/(n_1 - 1) + (S_2^2/n_2)^2/(n_2 - 1)}.$$

用途 用 $t_{\alpha/2}(\nu)$ 与未合并标准误构造 $\mu_1 - \mu_2$ 的近似区间。

边界 ν 由样本估计，所得分布为近似；不要同时使用 Welch 标准误和合并方差自由度。

配对样本均值差

条件 成对观测 (X_i, Y_i) 独立抽取，令 $D_i = X_i - Y_i$ ；差值总体正态，或样本量足够大。

结论 $T = (\bar{D} - \mu_D)/(S_D/\sqrt{n}) \sim t(n-1)$ （正态差值总体下为精确结论）。

用途 先逐对求差，再将问题化为单样本均值推断。

边界 不能把同一对象的前后测量误当作两组独立样本；正态性要求针对差值而不是两列原始数据分别提出。

两个正态总体方差比

条件 两组独立正态样本，自由度 $\nu_1 = n_1 - 1$ 、 $\nu_2 = n_2 - 1$ 。

结论 $F = (S_1^2/S_2^2)/(\sigma_1^2/\sigma_2^2) \sim F(\nu_1, \nu_2)$ 。

用途 σ_1^2/σ_2^2 的 $1 - \alpha$ 区间为

$$\left[\frac{S_1^2/S_2^2}{F_{\alpha/2}(\nu_1, \nu_2)}, \frac{S_1^2/S_2^2}{F_{1-\alpha/2}(\nu_1, \nu_2)} \right].$$

边界 交换分子分母会同时交换自由度；该方法对非正态总体较敏感。

两个总体比例之差的大样本标准化

条件 两个独立二项样本， $\hat{p}_i = X_i/n_i$ ，各组成功与失败数均足够大。

结论 $[(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)]/\sqrt{p_1(1-p_1)/n_1 + p_2(1-p_2)/n_2} \sim N(0, 1)$ 。

用途 区间估计使用分别代入 $\hat{p}_1, \hat{p}_2$ 的未合并标准误。

边界 检验 $H_0 : p_1 = p_2$ 时使用零假设下的合并比例；区间估计与检验的标准误不能机械互换。

枢轴量生成树

正态样本平方和给出 χ^2 ；标准正态除以独立卡方均方的平方根给出 t ；两个独立卡方均方之比给出 F 。因此使用 t 或 F 前，应先检查构成它们的正态性与独立性条件。

附录 C

统计推断决策表

本附录默认显著性水平为 α ，临界值采用上侧概率约定。双侧检验卡写作 $H_1: \theta \neq \theta_0$ ；若备择为右侧或左侧，只保留相应尾部，并把 $\alpha/2$ 改为 α 。

C.1 先判断数据结构，再选择方法

目标	数据与条件	统计量或区间核心	关键核对
单个均值	正态且 σ 已知，或大样本	$Z = (\bar{X} - \mu_0)/(\sigma/\sqrt{n})$	已知的是总体方差，不是样本方差
单个均值	正态且 σ 未知	$T = (\bar{X} - \mu_0)/(S/\sqrt{n})$	自由度 $n - 1$
两个独立均值	方差未知但可假定相等	合并方差两样本 t	独立、正态、等方差
两个独立均值	方差未知且不等	Welch t	不合并方差，自由度为近似值
配对均值差	同一对象前后测或自然匹配	对差值作单样本 t	正态性针对差值
单个方差	正态总体	$(n - 1)S^2/\sigma_0^2$	卡方检验对非正态较敏感
两个方差比	两个独立正态总体	S_1^2/S_2^2	分子、分母与自由度顺序一致
单个或两个比例	独立二项样本且计数充分	大样本 Z	检验等比例时用合并比例

C.2 正态总体八类标准检验卡

问题	方法	自由度或限制
给定分类概率是否与数据相符	Pearson χ^2 拟合优度检验	类数减 1 再减去由数据估计的参数个数
两个分类变量是否独立	$r \times c$ 列联表 χ^2 检验	$(r-1)(c-1)$; 期望频数不能过小
多个正态总体均值是否相等	单因子 ANOVA F 检验	组间 $k-1$, 组内 $n-k$
线性回归斜率是否为零	回归 t 或 F 检验	一元回归中 $F = t^2$
连续分布位置的稳健推断	符号、符号秩或秩和检验	三者针对的设计和假设不同

C.2 正态总体八类标准检验卡

检验卡：单个均值，方差已知

假设 $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$ 。

条件 正态样本且 σ^2 已知；一般总体时仅在大样本下近似使用。

统计量 $Z = (\bar{X} - \mu_0)/(\sigma/\sqrt{n})$ 。

零假设分布 H_0 下 $Z \sim N(0, 1)$ 。

拒绝域 $|Z| \geq z_{\alpha/2}$ 。

p 值 $p = 2[1 - \Phi(|z_{\text{obs}}|)]$ 。

结论 $p \leq \alpha$ 时拒绝 H_0 ；否则只能说证据不足以拒绝 H_0 。

检验卡：单个均值，方差未知

假设 $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$ 。

条件 来自 $N(\mu, \sigma^2)$ 的简单随机样本， σ^2 未知。

统计量 $T = (\bar{X} - \mu_0)/(S/\sqrt{n})$ 。

零假设分布 H_0 下 $T \sim t(n-1)$ 。

拒绝域 $|T| \geq t_{\alpha/2}(n-1)$ 。

p 值 $p = 2\mathbb{P}\{t(n-1) \geq |t_{\text{obs}}|\}$ 。

结论 按 p 值与 α 比较；不把“不拒绝”表述成“证明均值等于 μ_0 ”。

检验卡：单个方差

假设 $H_0: \sigma^2 = \sigma_0^2$, $H_1: \sigma^2 \neq \sigma_0^2$ 。

条件 简单随机样本来自正态总体。

统计量 $U = (n-1)S^2/\sigma_0^2$ 。

零假设分布 H_0 下 $U \sim \chi^2(n-1)$ 。

拒绝域 $U \leq \chi_{1-\alpha/2}^2(n-1)$ 或 $U \geq \chi_{\alpha/2}^2(n-1)$ 。

p 值 $p = \min\{1, 2 \min[\mathbb{P}(U \leq u_{\text{obs}}), \mathbb{P}(U \geq u_{\text{obs}})]\}$ 。

结论 拒绝时说明样本对给定方差值不相容；检验方向应由研究问题事先确定。

检验卡：两个独立均值，方差已知

假设 $H_0: \mu_1 - \mu_2 = \Delta_0$, $H_1: \mu_1 - \mu_2 \neq \Delta_0$ 。

条件 两组独立正态样本， σ_1^2, σ_2^2 已知；或满足大样本近似条件。

统计量 $Z = [(\bar{X} - \bar{Y}) - \Delta_0] / \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}$ 。

零假设分布 H_0 下 $Z \sim N(0, 1)$ 。

拒绝域 $|Z| \geq z_{\alpha/2}$ 。

p 值 $p = 2[1 - \Phi(|z_{\text{obs}}|)]$ 。

结论 结合差值方向和置信区间解释，不能只报告“显著”二字。

检验卡：两个独立均值，未知但等方差

假设 $H_0: \mu_1 - \mu_2 = \Delta_0$, $H_1: \mu_1 - \mu_2 \neq \Delta_0$ 。

条件 两组独立正态样本， $\sigma_1^2 = \sigma_2^2$ 未知。

统计量 $T = [(\bar{X} - \bar{Y}) - \Delta_0] / [S_p \sqrt{1/n_1 + 1/n_2}]$ ，其中 S_p^2 见附录 B。

零假设分布 H_0 下 $T \sim t(n_1 + n_2 - 2)$ 。

拒绝域 $|T| \geq t_{\alpha/2}(n_1 + n_2 - 2)$ 。

p 值 $p = 2\mathbb{P}\{t(n_1 + n_2 - 2) \geq |t_{\text{obs}}|\}$ 。

结论 仅在等方差条件有依据时采用合并方差结论。

检验卡：两个独立均值，Welch 方法

假设 $H_0: \mu_1 - \mu_2 = \Delta_0$, $H_1: \mu_1 - \mu_2 \neq \Delta_0$ 。

条件 两组独立样本，方差未知且不假定相等；正态小样本或一般总体大样本。

统计量 $T = [(\bar{X} - \bar{Y}) - \Delta_0] / \sqrt{S_1^2/n_1 + S_2^2/n_2}$ 。

零假设分布 近似服从 $t(\nu)$ ， ν 用附录 B 的 Welch-Satterthwaite 公式计算。

拒绝域 $|T| \geq t_{\alpha/2}(\nu)$ 。

p 值 $p \approx 2\mathbb{P}\{t(\nu) \geq |t_{\text{obs}}|\}$ 。

结论 报告未合并标准误、近似自由度和差值的方向。

检验卡：配对均值差

假设 令 $D_i = X_i - Y_i$ ； $H_0: \mu_D = \Delta_0$, $H_1: \mu_D \neq \Delta_0$ 。

条件 各对之间独立，差值总体正态；大样本时可用近似。

统计量 $T = (\bar{D} - \Delta_0) / (S_D / \sqrt{n})$ 。

零假设分布 H_0 下 $T \sim t(n-1)$ （正态差值总体）。

拒绝域 $|T| \geq t_{\alpha/2}(n-1)$ 。

p 值 $p = 2\mathbb{P}\{t(n-1) \geq |t_{\text{obs}}|\}$ 。

结论 结论针对平均配对差；不能改用两个独立样本的标准误。

检验卡：两个正态总体方差比

假设 $H_0: \sigma_1^2/\sigma_2^2 = R_0$, $H_1: \sigma_1^2/\sigma_2^2 \neq R_0$ 。

条件 两组样本相互独立且分别来自正态总体。

统计量 $F = (S_1^2/S_2^2)/R_0$ 。

零假设分布 H_0 下 $F \sim F(n_1-1, n_2-1)$ 。

拒绝域 $F \leq F_{1-\alpha/2}(n_1-1, n_2-1)$ 或 $F \geq F_{\alpha/2}(n_1-1, n_2-1)$ 。

p 值 $p = \min\{1, 2 \min[\mathbb{P}(F \leq f_{\text{obs}}), \mathbb{P}(F \geq f_{\text{obs}})]\}$ 。

结论 报告方差比的方向；若交换样本顺序，应同时交换自由度。

C.3 比例、分类数据与样本量

检验卡：单总体比例的大样本检验

假设 $H_0: p = p_0$, $H_1: p \neq p_0$ 。

条件 $X \sim B(n, p)$, 且 np_0 、 $n(1 - p_0)$ 足够大。

统计量 $Z = (\hat{p} - p_0) / \sqrt{p_0(1 - p_0)/n}$ 。

零假设分布 H_0 下近似服从 $N(0, 1)$ 。

拒绝域 $|Z| \geq z_{\alpha/2}$ 。

p 值 $p\text{-value} = 2[1 - \Phi(|z_{\text{obs}}|)]$ ；离散小样本应计算二项精确尾概率。

结论 近似条件不满足时，不以正态近似替代精确或其他稳健方法。

对 Pearson 拟合优度和列联表检验，统一计算

$$X^2 = \sum \frac{(O - E)^2}{E}.$$

拟合优度检验的自由度为“类别数 -1 - 由样本估计的参数数”； $r \times c$ 列联表独立性检验的自由度为 $(r - 1)(c - 1)$ 。若期望频数过小，应合并有实际意义的类别或采用适合小样本的方法，不能只为凑条件任意合并。

给定双侧置信区间半宽不超过 d ，均值 (σ 已知) 的保守样本量为

$$n \geq \left(\frac{z_{\alpha/2} \sigma}{d} \right)^2;$$

比例在有先验值 p_* 时取 $n \geq z_{\alpha/2}^2 p_*(1 - p_*)/d^2$ ，完全未知时用 $p_*(1 - p_*) \leq 1/4$ 得到保守值。计算结果一律向上取整。

若还要求在真实偏离量 δ 下达到功效 $1 - \beta$ ，已知方差单样本均值检验常用近似设计式为

$$n \geq \left[\frac{(z_{\alpha/2} + z_{\beta}) \sigma}{\delta} \right]^2$$

(单侧检验将 $z_{\alpha/2}$ 改为 z_{α})。

检验结论的边界

显著性水平控制的是零假设成立时的长期误拒概率； p 值不是“零假设为真的概率”。统计显著也不等于实际效应重要，因此应同时报告效应量、区间估计和方法条件。

附录 D

高频反例

反例的作用不是否定定理，而是标出定理不能被反向使用或不能删去条件的边界。每个反例都应能回答“错误推理发生在哪一步”。

D.1 事件与随机变量

互斥不等于独立

若 $A \cap B = \emptyset$ 且 $\mathbb{P}(A), \mathbb{P}(B) > 0$ ，则 $\mathbb{P}(A \cap B) = 0$ ，而 $\mathbb{P}(A)\mathbb{P}(B) > 0$ ，所以二者不独立。互斥意味着一个发生会排除另一个；独立意味着一个是否发生不改变另一个的概率。

两两独立不推出相互独立

令 U, V 为独立公平比特，取 $A = \{U = 0\}$ 、 $B = \{V = 0\}$ 、 $C = \{U = V\}$ 。三事件两两独立，但

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

验证多个事件相互独立时，必须检查所有有限子族的交。

不相关不推出独立

令 $X \sim U(-1, 1)$ ， $Y = X^2$ 。由对称性 $\text{Cov}(X, Y) = \mathbb{E}X^3 - \mathbb{E}X\mathbb{E}X^2 = 0$ ，但 Y 完全由 X 决定，显然不独立。联合正态是“零协方差推出独立”的重要特殊情形。

同分布不推出独立

令 $Y = X$ 。则 X 与 Y 同分布，却具有完全依赖关系。同分布只比较边际分布，独立性则是联合分布的性质。

密度在一点为零或为正都不能决定单点概率

连续型随机变量对每个 x 都有 $\mathbb{P}(X = x) = 0$ ，即使 $f_X(x) > 0$ 。密度不是单点概率，只有区间上的积分才给出概率；因此“概率为零”也不等同于逻辑上的不可能。

不是每个分布都只有分布列或密度

令 X 以概率 $1/2$ 取 0 ，并以概率 $1/2$ 在 $(0, 1)$ 上均匀分布。它同时含有原子和连续部分，不能用一个普通密度描述全部概率质量。

D.2 收敛与近似

依分布收敛不推出依概率收敛

在同一概率空间上取相互独立的 $X, X_1, X_2, \dots \sim \text{Bern}(1/2)$ 。因为每个 X_n 与 X 同分布，故 $X_n \xrightarrow{d} X$ ；但 $\mathbb{P}(|X_n - X| > 1/2) = 1/2$ ，所以不依概率收敛到 X 。

依概率收敛不推出几乎处处收敛

在 $[0, 1)$ 上按层依次枚举长度为 2^{-m} 的所有二进区间，并令 X_n 为当前区间的示性变量。区间长度趋于 0 ，故 $X_n \xrightarrow{P} 0$ ；但每个样本点在每一层恰落入一个区间，因而序列取值 1 无穷多次，也取值 0 无穷多次，几乎处处不收敛。

中心极限定理不保证任意尾部近似都准确

CLT 描述标准化和在固定位置的极限分布。小样本、极端尾部、严重偏态或二项分布中 np 、 $n(1-p)$ 过小时，正态近似可能较差；离散变量还需考虑连续性修正。

D.3 估计与检验

无偏不等于有效或相合

对均值为 μ 、方差为 σ^2 的独立同分布样本， $\hat{\mu}_n = X_1$ 对每个 n 都无偏，但方差恒为 σ^2 ，通常也不依概率收敛到 μ 。相比之下， $\bar{X}$ 的方差为 σ^2/n 。

有偏不等于不可用

正态总体方差的最大似然估计 $\hat{\sigma}_{\text{MLE}}^2 = n^{-1} \sum_i (X_i - \bar{X})^2$ 有偏，但偏差随 n 消失且估计相合。评价估计量时应同时考察偏差、方差、均方误差和相合性。

p 值大不证明零假设为真

大 p 值只说明当前数据没有提供足够强的反对证据，也可能源于样本量小或检验功效低。等效性或非劣效性问题需要专门的假设与界值，不能由传统检验“不显著”替代。

多重检验的独立公式不能无条件使用

若 m 个零假设都成立、各检验的误拒概率恰为 α ，且拒绝事件相互独立，则至少一次误拒的概率为 $1 - (1 - \alpha)^m$ 。无独立性时该等式通常不成立；始终可用并集上界得到 $\text{FWER} \leq m\alpha$ ，这正是 Bonferroni 校正的基础。

D.4 方差分析与回归

拒绝 ANOVA 总体假设不能定位具体差异

ANOVA 的 F 检验拒绝 $H_0 : \mu_1 = \cdots = \mu_k$ ，只说明至少一个均值不同。具体哪些组不同需要预先对比或带有多重性控制的事后比较。

高 R^2 不保证模型有效

高 R^2 既不能证明因果关系，也不能排除非线性、异方差、异常点或外推失效。回归结论还需结合残差诊断、设计背景和预测范围。

SSE/n 与 $SSE/(n-2)$ 的角色不同

在含截距的一元正态线性回归中，误差方差常见两种估计：

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{SSE}{n}, \quad MSE = \frac{SSE}{n-2}.$$

前者是最大似然估计，后者是无偏估计； t 、 F 推断使用后者。

附录 E

432 题型索引

本索引按“题面信号—方法入口—作答链”组织。它用于定位知识点，不能替代条件核对和完整推导。

E.1 概率模型与分布计算

题型	识别信号	标准作答链	回看
事件运算与概率	至少一个、恰有、都不发生	集合翻译 $\rightarrow$ 对立/容斥 $\rightarrow$ 代入概率	第 1 章
古典与几何概型	等可能有限结果；区域内均匀取点	确定样本空间 $\rightarrow$ 计数或测度比	第 1 章
条件概率	“已知”“在……条件下”	确认条件事件概率 $> 0 \rightarrow$ 交事件除以条件概率	第 1 章
全概率与 Bayes	多来源、检测更新、原因反推	完备事件组 $\rightarrow$ 全概率求分母 $\rightarrow$ Bayes 更新	第 1 章
独立性判断	重复试验、联合概率可分解	写出定义 $\rightarrow$ 检查所有所需子族 $\rightarrow$ 区分互斥	第 1 章、附录 D
示性变量计数	计数对象多但逐项概率易求	写 $N = \sum \mathbf{1}_{A_i} \rightarrow$ 用期望线性性	第 1 章

E.1 概率模型与分布计算

题型	识别信号	标准作答链	回看
由分布函数求概率	给出 F_X 或含跳点分段式	检查单调、右连续与极限 → 用端点差	第 2 章
识别常用分布	独立重复、无放回、计数或等待	先写支撑与参数含义 → 再写分布列/密度	第 2 章、附录 A
混合型分布	同时有点质量与连续部分	分开列原子与密度 → 概率质量总和为 1	第 2 章
一维函数分布	$Y = g(X)$	分布函数法；单调时逆变换，多分支时分段求和	第 2 章
联合与边缘	给出联合表或联合密度区域	先画/写支撑 → 对另一变量求和或积分	第 3 章
条件分布	已知 $Y = y$ 或落在某层	联合除以边缘 → 检查条件密度积分为 1	第 3 章
和、最大最小	独立变量函数	卷积或分布函数法 → 分段确定积分界	第 3 章
二维变量变换	$(U, V) = g(X, Y)$	求逆映射 → 新支撑 → 乘逆 Jacobian 绝对值	第 3 章
条件期望与全方差	分层、随机参数、两阶段试验	先求条件矩 → 外层取期望或方差分解	第 3 章

E.2 极限定理、样本与点估计

题型	识别信号	标准作答链	回看
收敛方式判断	几乎处处、概率、分布函数收敛	对照定义 → 使用正确蕴含方向 → 必要时给反例	第 4 章、附录 D
特征函数	独立和、识别极限分布	求单变量特征函数 → 独立时相乘 → 用唯一性	第 4 章
大数定律	样本均值趋近常数	核对独立同分布及矩条件 → 说明收敛方式	第 4 章
中心极限定理	大量独立项之和或均值的误差	中心化 → 除以标准差 → 正态近似	第 4 章
二项正态近似	$B(n, p)$ 区间概率	检查 $np, n(1-p)$ → 连续性修正 → 标准化	第 4 章
样本数字特征	原始数据、次序统计量、箱线图	排序 → 均值/无偏方差/分位数 → 解释异常值规则	第 5 章
正态样本抽样分布	出现 $\bar{X}, S^2$	由 χ^2 生成 t, F → 核对独立性和自由度	第 5 章、附录 B
充分统计量	似然是否可压缩样本	写似然 → 因子分解 → 指出与参数有关部分	第 5 章
矩估计	让样本矩匹配总体矩	列矩方程 → 解参数 → 检查参数空间	第 6 章
最大似然估计	给定分布族与样本	写支撑和似然 → 取对数 → 内点/边界比较	第 6 章
估计量评价	无偏、有效、MSE、相合	分别求偏差和方差 → 比 MSE → 判断极限	第 6 章

E.3 区间估计与假设检验

题型	识别信号	标准作答链	回看
单总体均值区间	正态/大样本, 方差已知或未知	选择 Z 或 t 枢轴 $\rightarrow$ 写自由度 $\rightarrow$ 解不等式	第 6 章、附录 B
两个均值差区间	独立、配对、等方差或异方差	先判数据结构 $\rightarrow$ 合并 t /Welch/差值 t	第 6 章、附录 B
方差与方差比区间	正态总体	选 χ^2 或 $F \rightarrow$ 核对上下侧临界值顺序	第 6 章、附录 B
比例区间与样本量	二项计数、大样本、误差限	核对成功/失败数 $\rightarrow$ 标准误 $\rightarrow$ 向上取整	第 6 章、附录 C
检验基本概念	水平、两类错误、功效、 p 值	写 $H_0, H_1 \rightarrow$ 统计量及零假设分布 $\rightarrow$ 结论	第 7 章
单双侧检验	“增大/减小/不同”	由备择确定尾部 $\rightarrow$ 临界值或 p 值保持同向	第 7 章、附录 C
区间与检验反演	同一参数、同一水平的双侧问题	检查假设值是否落在 $1 - \alpha$ 区间内	第 7 章
拟合优度	观测频数与理论概率	求期望频数 $\rightarrow$ 合理合并 $\rightarrow$ 扣除估计参数数	第 7 章
列联表独立性	两个分类变量交叉频数	行列边际求期望 $\rightarrow \chi^2 \rightarrow$ 自由度 $(r - 1)(c - 1)$	第 7 章
非参数检验	中位数、配对差、两个独立样本	先辨设计 $\rightarrow$ 符号/符号秩/秩和 $\rightarrow$ 处理并列与零差	第 7 章

E.4 方差分析与回归

题型	识别信号	标准作答链	回看
单因子 ANOVA	k 组独立样本比较均值	写模型条件 $\rightarrow$ $SST = SSA + SSE \rightarrow$ 均 方与 F	第 8 章
自由度核对	总体均值、组均值、残 差空间	总计 $n - 1$, 组间 $k - 1$, 组 内 $n - k$	第 8 章
多重比较	总检验后定位组间差异	选择 Tukey/Scheffé 等 $\rightarrow$ 控制整体错误率	第 8 章
方差齐性	比较多个总体方差	核对正态性与稳健性 $\rightarrow$ Bartlett 或 Levene/Brown-Forsythe	第 8 章
一元回归 OLS	给定 (x_i, y_i)	求 $S_{xx}, S_{xy} \rightarrow$ 斜率、截距 $\rightarrow$ 残差平方和	第 8 章
回归显著性	检验斜率或总体回归	t 或 $F \rightarrow$ 一元回归核对 $F = t^2$	第 8 章
均值响应与预测	给定新点 x_0	分清平均响应与新观测 $\rightarrow$ 后者标准误多一个 1	第 8 章
残差诊断	线性、齐方差、正态、 异常点	画残差图/正态图 $\rightarrow$ 定位 违反的假设 $\rightarrow$ 再解释模型	第 8 章

E.5 考场作答检查表

六步计算链

1. 写清随机对象、参数和待求目标；
2. 列出独立性、总体分布、方差已知性及样本量等条件；
3. 选择分布、枢轴量或检验统计量，并写明零假设下分布；
4. 代入前先核对支撑、自由度和临界值方向；
5. 完成计算，并用区间、概率或 p 值给出量化结果；
6. 用题目语境解释结论，同时说明近似或方法边界。

三个终检问题

公式中的方差究竟是总体方差、样本方差还是均方误差？数据是独立样本还是配对样本？当前结论是精确分布、渐近近似，还是只在零假设下成立？这三项通常能发现最具代价的模型选择错误。